

Методы современной прикладной статистики

1. Введение

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

- Будет 11 (одно сдвоенное) домашних заданий, в каждом из них будет ≤ 6 задач (в том числе ≤ 2 теоретических) с общей суммой в 12 баллов.
- В конце семестра будет практический экзамен, за который можно получить максимум 50 баллов.
- В начале каждого семинара будет проводиться тест по материалу лекции, за который можно получить максимум 1 балл.
- Оценка за курс: $\min([(A + B + C)/12], 10)$, где A – количество баллов за ДЗ, B – оценка за экзамен, C – сумма баллов за тесты, $[\cdot]$ – округление вниз.

- Экзамен является необязательным.
- Лекции будут по четвергам в 10:45 онлайн.
Семинары будут по четвергам в 12:20.
- ДЗ отсылается семинаристу.
- ДЗ будет выкладываться на странице курса. Там же можно будет найти программу и презентации лекций.
- Дедлайн по сдаче ДЗ – в 10:45 в четверг, т.е. на выполнение ДЗ дается неделя после семинара.
Дедлайн **жесткий**.
- Если студент попадает на списывании, то в первый раз у него аннулируется одно ДЗ, во второй раз – аннулируются все ДЗ.

Рассмотрим основную задачу математической статистики: по данным/наблюдениям сделать выводы о распределении этих данных. Эту задачу можно решать в рамках одной из трех парадигм

- 1 параметрической;
- 2 непараметрической;
- 3 семипараметрической;

и в рамках одного из 2 подходов: частотного или байесовского.

Параметрическая парадигма

В рамках параметрической парадигмы мы считаем, что множество распределений, из которых мы выбираем подходящее, параметризовано: $\mathcal{P} = \{P_\theta, \theta \in \Theta\}$.

Примеры задач и методов:

- 1) Точечное оценивание;
- 2) Доверительное оценивание параметра;
- 3) Линейная регрессия.

Замечание.

Точное распределение, которому подчиняются наши данные, найти невозможно. Мы можем лишь подобрать модель, с какой-то степенью точности приближающую наши данные.

Семипараметрический подход

В рамках семипараметрического (полупараметрического) подхода считаем, что на семействе распределений $\mathcal{P}$ задан параметр, который хорошо описывает данное семейство. Например, семейство распределений типа Вейбулла с функцией распределения

$$F(x) = 1 - \exp(-x^\gamma l(x)), \quad x > 0, \quad \gamma > 0,$$

где $l(x) : \lim_{t \rightarrow \infty} \frac{l(tx)}{l(t)} = 1$ – медленно меняющаяся функция, хорошо описывается параметром γ .

Непараметрический подход

В рамках непараметрической парадигмы мы считаем, что множество распределений, из которых мы выбираем подходящее, невозможно параметризовать с помощью конечномерного параметра.

Примеры задач и методов:

- 1) Ядерные оценки плотности;
- 2) Непараметрическая регрессия;
- 3) Ранговые критерии.

В рамках байесовского подхода мы считаем, что на множестве распределений, из которых мы выбираем подходящее, задана некая вероятностная мера Q (априорное распределение).

Априорное распределение выбирается исходя из имеющихся на текущий момент данных о неизвестном распределении. Если данных нет, априорное распределение полагается неинформативным.

Пусть X – наблюдение из распределения $P \in \mathcal{P}$. Пусть семейство распределений $\mathcal{P}$ параметризовано, $\mathcal{P} = \{P_\theta, \theta \in \Theta\}$, и $q(\theta)$ – априорная плотность на Θ . Формат вывода в рамках байесовского подхода таков:

$$q(\theta|X) = \frac{p(X|\theta)q(\theta)}{\int_{\Theta} p(X|\theta)q(\theta)d\theta},$$

где $p(X|\theta)$ – функция правдоподобия наблюдения X , а $q(\theta|X)$ – апостериорная плотность.

Характеристики распределений


Пусть случайная величина X имеет функцию распределения F . Тогда

- Математическое ожидание: $\mathbb{E}X = \int_{\mathbb{R}} xF(dx)$;
- Дисперсия: $\text{var } X = \mathbb{E}(X - \mathbb{E}X)^2 = \mathbb{E}X^2 - (\mathbb{E}X)^2$;
- Стандартное отклонение: $\sigma_X = \sqrt{\text{var } X}$;
- Квантиль уровня α : $u_\alpha = \inf\{x : F(x) \geq \alpha\}$;
- Медиана: квантиль уровня $1/2$.


Характеристики распределений

- Коэффициент асимметрии (skewness)

$$Sk = \frac{\mathbb{E}(X - \mathbb{E}X)^3}{(\text{var } X)^{3/2}}$$



Left-skewed




Right-skewed

Характеристики распределений

- Коэффициент эксцесса (excess, без вычитания 3 – kurtosis)

$$K = \frac{\mathbb{E}(X - \mathbb{E}X)^4}{(\text{var } X)^2} - 3$$



Нормальное распределение

$X \sim N(a, \sigma^2)$, если плотность

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x-a)^2}{2\sigma^2} \right\}.$$

Свойства:

- 1) Является слабым пределом суммы независимых (слабозависимых) случайных величин;
- 2) $\mathbb{E}X = a$; $\text{var } X = \sigma^2$;
- 3) Обозначим $\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{x^2}{2} \right)$, $\Phi(x) = \int_{-\infty}^x \varphi(y) dy$, тогда $F_X(x) = \Phi \left(\frac{x-a}{\sigma} \right)$.

Распределение хи-квадрат

$X \sim \chi_n^2$, если плотность

$$p_X(x) = \frac{x^{n/2-1}}{2^{n/2}\Gamma(n/2)} \exp(-x/2), \quad x > 0.$$

Свойства:

- 1) Если $\{\xi_i\}_{i=1}^n$ – нез. сл.в., $\forall i \xi_i \sim N(0, 1)$, то $\sum_{i=1}^n \xi_i^2 \sim \chi_n^2$.
- 2) $\mathbb{E}X = n$, $\text{var } X = 2n$.

Распределение Стьюдента

Пусть $X \sim N(0, 1)$, $Y \sim \chi_n^2$, X и Y независимы, тогда случайная величина

$$Z \stackrel{d}{=} \frac{X}{\sqrt{Y/n}}$$

будет иметь распределение Стьюдента с n степенями свободы, $Z \sim St(n)$ (также пишут $Z \sim T_n$).

Свойства:

- 1) При $n \rightarrow \infty$ $T_n \Rightarrow N(0, 1)$.
- 2) При $n = 1$ Z имеет стандартное распределение Коши.

Распределение Фишера

Пусть $X \sim \chi_n^2$, $Y \sim \chi_m^2$, X и Y независимы, тогда случайная величина

$$Z \stackrel{d}{=} \frac{X/n}{Y/m}$$

будет иметь распределение Фишера с n и m степенями свободы, $Z \sim F(n, m)$.

Свойства:

- 1) При $n, m \rightarrow \infty$ $F(n, m) \Rightarrow 1$.
- 2) При $n = 1$ $\sqrt{Z} \sim T_m$.

Другие распределения

- ① $X \sim \text{Exp}(\alpha)$, если $p(x) = \alpha e^{-\alpha x}$, $x > 0$;
- ② $X \sim U[a, b]$, если $p(x) = \frac{1}{b-a} \mathbb{1}\{x \in [a, b]\}$;
- ③ $X \sim \text{Cauchy}(\theta)$, если $p(x) = \frac{\theta}{\pi(x^2 + \theta^2)}$;
- ④ $X \sim \text{Gamma}(\alpha, \gamma)$, если $p(x) = \frac{x^{\alpha-1} \gamma^\alpha}{\Gamma(\alpha)} e^{-\gamma x}$, $x > 0$;
- ⑤ $X \sim \text{Beta}(\alpha, \beta)$, если $p(x) = \frac{x^{\alpha-1} (1-x)^{\beta-1}}{B(\alpha, \beta)} \mathbb{1}(x \in [0, 1])$;
- ⑥ $X \sim \text{Pareto}(\alpha, \kappa)$, если $p(x) = \frac{\alpha \kappa^\alpha}{x^{\alpha+1}} \mathbb{1}(x > \kappa)$.

Популярные дискретные распределения

- 1 $X \sim \text{Bern}(p)$, если $P(X = 0) = p$,
 $P(X = 1) = 1 - p$, $0 < p < 1$;
- 2 $X \sim \text{Bin}(n, p)$, если
 $P(X = k) = C_n^k p^k (1 - p)^{n-k}$, $0 < p < 1$,
 $k \in \{0, \dots, n\}$;
- 3 $X \sim \text{Pois}(\lambda)$, если $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$, $\lambda > 0$,
 $k \in \mathbb{Z}_+$;
- 4 $X \sim \text{Geom}(p)$, если $P(X = k) = p(1 - p)^{k-1}$,
 $k \in \mathbb{N}$, $0 < p < 1$.


Пусть $X = (X_1, \dots, X_n)$ – выборка из распределения P .
Статистикой $T(X)$ называют любую измеримую функцию от выборки. Примеры:

- Выборочные характеристики: $\overline{g(X)} = \frac{1}{n} \sum_{i=1}^n g(X_i)$;
 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ – выборочное среднее,
 $\bar{X}^k = \frac{1}{n} \sum_{i=1}^n X_i^k$ – выборочный k -тый момент;
- Выборочные центральные моменты:
 $M_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$; $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ –
 выборочная дисперсия;

- Порядковые статистики $X_{(1)} = \min(X_1, \dots, X_n)$,
 $X_{(2)} = \min(X_1, \dots, X_n \setminus X_{(1)})$, ...
 $X_{(n)} = \max(X_1, \dots, X_n)$;
- Вариационный ряд: $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$;
- Ранг элемента выборки (в вариационном ряду):
 $R(X_i) = r$, если $X_i = X_{(r)}$;
- Выборочная α -квантиль: $\hat{Z}_\alpha = X_{([n\alpha])}$;
- Выборочная медиана:


$$\hat{\mu} = \begin{cases} X_{(k+1)}, & \text{если } n = 2k + 1; \\ \frac{1}{2}(X_{(k)} + X_{(k+1)}), & \text{если } n = 2k; \end{cases}$$

- $F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}(X_i \leq x)$ – эмпирическая функция распределения.



- Гистограмма распределения:

$$p_n(x) = \sum_{i,j} \mathbb{1}(x \in B_j) \mathbb{1}(X_i \in B_j), \{B_j\}_{j=1}^k$$
 – разбиение выборочного пространства.



Свойства точечных оценок

Рассмотрим параметрическую модель: $F \in \{F_\theta, \theta \in \Theta\}$.

Статистики, имеющие значения в Θ , называются оценками параметра θ . Свойства:

- Несмещенность: $\mathbb{E}_\theta \hat{\theta} = \theta \quad \forall \theta \in \Theta$;
- Состоятельность: $\hat{\theta}_n \xrightarrow{P_\theta} \theta$ при $n \rightarrow \infty \quad \forall \theta \in \Theta$;
- С/к-оптимальность: $\text{var}_\theta(\hat{\theta}) = \min_{\theta^*: \mathbb{E}_{\theta^*} \hat{\theta} = \theta} \text{var}_\theta(\theta^*)$
 $\forall \theta \in \Theta$;
- Асимптотическая нормальность:
 $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d_\theta} N(0, \sigma^2(\theta))$ при $n \rightarrow \infty \quad \forall \theta \in \Theta$;
- Робастность: устойчивость $\hat{\theta}$ относительно отклонений распределения X от модельного семейства и выбросов, содержащихся в выборке.

Методы нахождения оценок

- **Метод моментов.**

1) Пусть $\theta = (\theta_1, \dots, \theta_k)$, выберем k пробных функций $g_1(x), \dots, g_k(x)$. Положим $m_i(\theta) = \mathbb{E}_\theta g(X_1)$.

2) Составим систему уравнений

$$\begin{cases} m_1(\theta) = \overline{g_1(X)}; \\ \vdots \\ m_k(\theta) = \overline{g_k(X)}; \end{cases}$$

где $\overline{g_i(X)}$ – выборочные характеристики.

3) Решение этой системы относительно $(\theta_1, \dots, \theta_k)$ и будет оценкой θ по методу моментов.

Пример.

Пусть $(X_1, \dots, X_n) \sim N(a, \sigma^2)$, найдем оценки a и σ^2 методом моментов. Выберем $g_1(x) = x$, $g_2(x) = x^2$, тогда $\mathbb{E}g_1(X_1) = \mathbb{E}X_1 = a$; $\mathbb{E}g_2(X_1) = \sigma^2 + a^2$. Составим систему:

$$\begin{cases} a = \bar{X}; \\ \sigma^2 + a^2 = \overline{X^2}; \end{cases}$$

откуда $\hat{a} = \bar{X}$ и $\hat{\sigma}^2 = \overline{X^2} - (\bar{X})^2$.

Свойство. Обозначим $m(\theta) = (m_1(\theta), \dots, m_k(\theta))$. Если m^{-1} непрерывна, то оценка методом моментов состоятельна, а если непрерывно дифференцируема, то и асимптотически нормальна.

- **Метод максимального правдоподобия.**
Функция правдоподобия выборки

$$f(X_1, \dots, X_n; \theta) = \prod_{i=1}^n p_{\theta}(X_i),$$

где $p_{\theta}(x)$ – обобщенная плотность X_1 . Тогда оценка методом максимального правдоподобия (ОМП)

$$\hat{\theta} = \arg \max_{\theta} f(X_1, \dots, X_n; \theta).$$

Методы нахождения оценок

Пример.

Пусть $(X_1, \dots, X_n) \sim \text{Exp}(\alpha)$, найдем оценку α методом максимального правдоподобия. Имеем

$$f(X, \alpha) = f(X_1, \dots, X_n; \alpha) = \prod_{i=1}^n \alpha e^{-\alpha X_i} = \alpha^n e^{-\alpha \sum_i X_i}.$$

Продифференцируем по α логарифмическую функцию правдоподобия, чтобы найти точку максимума:

$$L(X, \alpha) = \ln f(X, \alpha) = n \ln \alpha - \alpha \sum_i X_i;$$

$$\frac{\partial}{\partial \alpha} L(X, \alpha) = \frac{n}{\alpha} - \sum_i X_i = 0,$$

откуда ОМП $\hat{\alpha} = 1/\bar{X}$.

Свойство.

При некоторых условиях регулярности (в частности, решение уравнения правдоподобия должно быть единственным) оценка максимального правдоподобия является состоятельной, а при некоторых дополнительных условиях выполнено

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d_\theta} N(0, (i(\theta))^{-1}), \quad n \rightarrow \infty,$$

где $i(\theta) = \mathbb{E}_\theta \left(\frac{d}{d\theta} \ln p_\theta(X_1) \right)^2$ – информация Фишера одного элемента выборки.

Методы нахождения оценок

- **Метод выборочной квантили.**

При некоторых условиях на плотность распределения

$$\sqrt{n}(\hat{Z}_\alpha - u_\alpha) \xrightarrow{d} N\left(0, \frac{\alpha(1-\alpha)}{p^2(u_\alpha)}\right), \quad n \rightarrow \infty;$$

- **Метод спейсингов.**

Положим $D_i(\theta) = F_\theta(X_{(i+1)}) - F_\theta(X_{(i)})$, $i = 0, \dots, n$,
 $X_{(0)} = -\infty$, $X_{(n+1)} = +\infty$. Тогда

$$\hat{\theta} = \arg \max_{\theta} \sum_{i=0}^n \ln D_i(\theta).$$

- **М-оценки.**

$$\hat{\theta} = \arg \min_{\theta} \rho(X, \theta),$$

где $\rho(X, \theta)$ – некая функция потерь.

Доверительные интервалы

Пара статистик $(T_1(X), T_2(X))$ называется доверительным интервалом для параметра θ уровня доверия $1 - \alpha$, если $\forall \theta \in \Theta$

$$P_{\theta}(T_1(X) < \theta < T_2(X)) = 1 - \alpha.$$

Последовательность пар статистик $(T_{1,n}(X), T_{2,n}(X))$ называется асимптотическим доверительным интервалом для параметра θ уровня доверия $1 - \alpha$, если $\forall \theta \in \Theta$

$$P_{\theta}(T_{1,n}(X) < \theta < T_{2,n}(X)) \rightarrow 1 - \alpha, \quad n \rightarrow \infty.$$

Пример.

Пусть $\hat{\theta}_n$ – асимптотически нормальная оценка параметра θ ,

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d_\theta} N(0, \sigma^2(\theta)), \quad n \rightarrow \infty,$$

тогда при $n \rightarrow \infty$

$$P_\theta \left(\hat{\theta}_n - u_{1-\frac{\alpha}{2}} \frac{\sigma(\hat{\theta}_n)}{\sqrt{n}} < \theta < \hat{\theta}_n + u_{1-\frac{\alpha}{2}} \frac{\sigma(\hat{\theta}_n)}{\sqrt{n}} \right) \rightarrow 1 - \alpha,$$


где $u_{1-\frac{\alpha}{2}}$ – $(1 - \frac{\alpha}{2})$ -квантиль $N(0, 1)$.

Ключевой вопрос для практика: как ведет себя оценка при конечных значениях n ?


- Если оценка состоятельна, каково её смещение при конечных n ?
- Если смещение её невелико, каков разброс её значений (т.е. велика ли её дисперсия и MSE)?
- Какой объем выборки нужен, чтобы оценить величину с заданной точностью?

- Смещение: $Bias(\hat{\theta}) = \mathbb{E}_{\theta}\hat{\theta} - \theta$.
- Эмпирическое смещение: $Bias(\hat{\theta}, \theta) = \frac{1}{k} \sum_{i=1}^k \hat{\theta}_i - \theta$,
если у нас есть несколько выборок и известно θ .
- Квадратичное смещение: $MSE(\hat{\theta}) = \mathbb{E}_{\theta}(\hat{\theta} - \theta)^2$,
 $RMSE = \sqrt{MSE}$.
- Эмпирическое квадратичное смещение
 $MSE(\hat{\theta}) = \frac{1}{k} \sum_{i=1}^k (\hat{\theta}_i - \theta)^2$.
- Bias-variance trade-off: $MSE(\hat{\theta}) = \text{var}_{\theta}(\hat{\theta}) + (Bias(\hat{\theta}))^2$.

The Hill plot and fitted Pareto parameter



На графике – 100 траекторий значений оценки Хилла индекса экстремального значения $\hat{\gamma}_H = \frac{1}{k} \sum_{i=0}^{k-1} \ln X_{(n-i)} - \ln X_{(n-k)}$, $n = 500$, $k \in \{1, \dots, 500\}$. Черным выделена медиана значений статистик.



На графике – смещение (bias) и эмпирическое смещение (empirical bias) $\hat{\theta}_n - \theta$ двух оценок методом максимального правдоподобия.






Figure 1: Empirical squared bias as a function of k obtained with $\hat{\theta}_n$ computed on 500 samples of size 500 from $F_{1/2, \tau, \rho}$. Up: $\rho = -1/2$, down: $\rho = -1/4$, solid line: $\tau = 1$, dashed line: $\tau = 1/2$, dotted line: $\tau = 0$.

На графике – эмпирическое квадратичное смещение (empirical MSE) значений оценки вейбулловского индекса для трех разных распределений, $n = 500$, $k \in \{1, \dots, 250\}$, количество выборок – 500.


TAIL ESTIMATION UNDER PARETO-TYPE MODELS





На графике – медиана эмпирического стандартного отклонения $(\hat{\theta} - \theta)^2$ значений оценки Хилла и ОМП индекса экстремального значения, $n = 500$, $k \in \{5, \dots, 250\}$.



На графике – вероятность покрытия доверительным интервалом, построенным с помощью оценки Хилла и ОМП экстремального индекса, истинного значения параметра, $n = 500$, $k \in \{5, \dots, 250\}$.



На графике – выборочная дисперсия значений оценки
вейбулловского индекса для трех разных распределений, $n = 500$,
 $k \in \{1, \dots, 250\}$, количество выборок – 500.



The best RMSE and Bias for the intervals estimator ('Intdis') and K-gaps ('Kdis') estimators with threshold u selected by discrepancy equations (14) and (16); the K-gaps estimator with u selected by the test IMT ('Kimt') and the intervals estimator with the "plateau-finding" algorithm A1 to select u ('IntA1') against the number of processes related to the columns labels in Tables 1 and 2.

Finita!

Методы современной прикладной статистики

2. Основы проверки гипотез

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Постановка задачи

Пусть X (в нашем курсе, как правило, X – это выборка $(X_1, \dots, X_n)$) – наблюдение из неизвестного распределения P_X . Основная задача – по наблюдению X сделать выводы о распределении P_X (= построить модель X).

Предположим, что $P_X \in \mathcal{P}$, где $\mathcal{P}$ – некий класс распределений, которому заведомо принадлежит P_X .

- **Основная гипотеза:** $H_0 : P_X \in \mathcal{P}_0$, где $\mathcal{P}_0 \subset \mathcal{P}$.

Пример. Пусть известно, что выборка имеет нормальное распределение, хотим проверить, что выборка распределена по закону $N(0, 1)$. Тогда $\mathcal{P} = \{N(a, \sigma^2), a \in \mathbb{R}, \sigma^2 > 0\}$, а $\mathcal{P}_0 = \{N(0, 1)\}$.

- **Альтернативная гипотеза (или альтернатива):**
 $H_1 : P_X \in \mathcal{P}_1$, где $\mathcal{P}_1 \subset \mathcal{P} \setminus \mathcal{P}_0$.
- Гипотеза называется **простой**, если $\mathcal{P}_0$ (или $\mathcal{P}_1$) состоит из одного распределения.
- **Статистика критерия:** $T(X)$ – такая статистика, что при $P_X \in \mathcal{P}_0$ мы либо знаем её распределение, либо можем оценить сверху вероятности её редких значений.

- Если правило проверки гипотезы выглядит так:

если $T(X) \in S$, то отвергнуть H_0 ,

то S называется **критическим множеством**, а само правило называют **критерием**.

- Критерии бывают
 - двусторонние,
 $\{T(X) > u_{1-\alpha/2}\} \cup \{T(X) < u_{\alpha/2}\};$
 - односторонние, которые делятся на
правосторонние, $\{T(X) > u_{1-\alpha}\}$, и
левосторонние, $\{T(X) < u_{\alpha}\};$
 - более сложные.

- **Уровень значимости** критерия: такое α , что $P_0(T(X) \in S) \leq \alpha \forall P_0 \in \mathcal{P}_0$.
- **Размером** критерия называется его минимальный уровень значимости, т.е. такое α , что

$$\alpha = \sup_{P_0 \in \mathcal{P}_0} P_0(T(X) \in S).$$

Уровень значимости выбирается исследователем. Его обычные значения – 0.1, 0.05 или 0.01.

Основные понятия

	H_0 верна	H_0 неверна
H_0 принимается	H_0 верно принята	Ошибка второго рода (false positive)
H_0 отвергается	Ошибка первого рода (false negative)	H_0 верно отвергнута

Type I error
(false negative)



Type II error
(false positive)




- **Функция мощности критерия:**
 $Q(S, P) = P(T(X) \in S).$

Тогда $Q(S, P_0)$, $P_0 \in \mathcal{P}_0$, – вероятность ошибки I рода на распределении P_0 , а $1 - Q(S, P_1)$, $P_1 \in \mathcal{P}_1$, – вероятность ошибки II рода на распределении P_1 .


Получаем, что, уменьшая вероятность ошибки I рода (т.е. уменьшая S), мы, как правило, увеличиваем вероятность ошибки II рода, поэтому выбирать слишком низкий уровень значимости не рекомендуется.

Основные понятия



На рисунке – вероятности ошибок I и II родов в задаче различения 2 простых гипотез.

Мощность t-теста при различной величине эффекта (d)



На рисунке – функции мощности t-критерия Стьюдента при различных уровнях значимости, если выборка сделана из распределения $N(d, \sigma^2)$.

- Критерий называется **состоятельным**, если $\forall P \in \mathcal{P}_1$ выполнено

$$P(T_n(X) \in S) \rightarrow 1 \text{ при } n \rightarrow \infty.$$

- Критерий называется **несмещенным**, если

$$\sup_{P \in \mathcal{P}_0} P(T(X) \in S) \leq \inf_{P \in \mathcal{P}_1} P(T(X) \in S).$$

- Критерий S **мощнее** критерия R , если уровни значимости этих критериев совпадают и $\forall P \in \mathcal{P}_1$ выполнено

$$P(T(X) \in S) \geq P(T(X) \in R).$$

- Критерий S называется **равномерно наиболее мощным** критерием (р.н.м.к.) для проверки гипотезы H_0 против альтернативы H_1 , если он мощнее любого другого критерия того же уровня значимости проверки H_0 против H_1 .

Лемма Неймана-Пирсона

Р.н.м. критерии существуют далеко не во всех ситуациях. В задаче различения двух простых гипотез $H_0 : P = P_0$ против $H_1 : P = P_1$ р.н.м.к. существует всегда, как утверждает следующая лемма.

Лемма Неймана-Пирсона.

Пусть $S_\lambda = \{x : p_1(x) - \lambda p_0(x) \geq 0\}$, где p_i – плотность распределения P_i по мере μ , $i = 0, 1$. Пусть критерий R имеет уровень значимости не больше, чем критерий S_λ , т.е. $P_0(X \in R) \leq P_0(X \in S_\lambda)$. Тогда

- 1) $P_1(X \in R) \leq P_1(X \in S_\lambda)$ (т.е. S_λ мощнее R);
- 2) $P_1(X \in S_\lambda) \geq P_0(X \in S_\lambda)$ (т.е. S_λ несмещенный).

Лемма Неймана-Пирсона

Пример. Пусть $X_1, \dots, X_n$ – выборка из $\text{Exp}(\alpha)$. Построим р.н.м. критерий в задаче различения гипотезы $H_0 : \alpha = 2$ против альтернативы $H_1 : \alpha = 3$. Функция правдоподобия равна:

$$f(X, \alpha) = f(X_1, \dots, X_n, \alpha) = \prod_{i=1}^n \alpha e^{-\alpha X_i} = \alpha^n e^{-\alpha \sum_i X_i},$$

тогда р.н.м. критерий

$$S_\lambda = \left\{ \frac{f(X, 3)}{f(X, 2)} \geq \lambda \right\} = \left\{ \frac{3^n}{2^n} e^{-\sum_i X_i} \geq \lambda \right\} = \left\{ \sum_{i=1}^n X_i \leq \lambda_1 \right\},$$

где $\lambda_1 = n \ln(2/3) + \ln \lambda$.

Лемма Неймана-Пирсона

Далее, найдем такое λ , что критерий будет иметь уровень значимости γ . Если гипотеза H_0 верна, то $\sum_{i=1}^n X_i \sim \Gamma(n, 2)$. Отсюда, $\lambda_1 = u_\gamma$, где u_γ – γ -квантиль распределения $\Gamma(n, 2)$. Значит, $\lambda = (3/2)^n e^{u_\gamma}$.

Пусть $X_1, \dots, X_n$ – выборка из $Pois(\lambda)$. Построим критерий проверки гипотезы $H_0 : \lambda = \lambda_0$ против альтернативы $H_1 : \lambda \neq \lambda_0$ с помощью ЦПТ. При выполнении гипотезы H_0 ,

$$\frac{\sum_{i=1}^n X_i - n\lambda_0}{\sqrt{n\lambda_0}} \xrightarrow{d} N(0, 1), \quad n \rightarrow \infty.$$

Тогда критерий будет выглядеть так:

$$\text{если } \left| \frac{\sum_{i=1}^n X_i - n\lambda_0}{\sqrt{n\lambda_0}} \right| > u_{1-\frac{\alpha}{2}}, \text{ то отвергать } H_0,$$

где $u_{1-\frac{\alpha}{2}}$ – $(1 - \alpha/2)$ -квантиль $N(0, 1)$. В отличие от критерия Неймана-Пирсона, данный критерий является **асимптотическим**, т.е. его уровень значимости лишь стремится к α при $n \rightarrow \infty$, а не равен α в точности.

Пусть θ_n^* – асимптотически нормальная оценка параметра θ , т.е. $\sqrt{n}(\theta_n^* - \theta) \xrightarrow{d_\theta} N(0, \sigma^2(\theta))$. Тогда для проверки гипотезы $H_0 : \theta = \theta_0$ против альтернативы $H_1 : \theta \neq \theta_0$ можно применить критерий

$$\text{если } \left| \sqrt{n} \frac{\theta_n^* - \theta_0}{\sigma(\theta_0)} \right| > u_{1-\frac{\alpha}{2}}, \text{ то отвергать } H_0,$$

который называется **критерием Вальда**.

Монотонное отношение правдоподобия

Говорят, что доминируемое семейство распределений $\mathcal{P} = \{P_\theta, \theta \in \Theta\}$ имеет монотонное отношение правдоподобия по статистике $T(X)$, если $\forall \theta_0 < \theta_1$ функция $\frac{f(X, \theta_1)}{f(X, \theta_0)}$ является монотонной функцией от $T(X)$, причем монотонность одна и та же $\forall \theta_0 < \theta_1$.

Теорема(о монотонном отношении правдоподобия)
Пусть в задаче проверки гипотезы $H_0 : \theta \leq \theta_0$ (или $\theta = \theta_0$) против альтернативы $H_1 : \theta > \theta_0$ отношение $\frac{f(X, \theta_2)}{f(X, \theta_1)}$ возрастает по $T(X)$ при $\forall \theta_1 < \theta_2$. Если $\exists c_\alpha$ такое, что $P_{\theta_0}(T(X) \geq c_\alpha) = \alpha$, то $S = \{T(X) \geq c_\alpha\}$ – р.н.м.к. уровня значимости α для проверки H_0 против H_1 .

На практике часто возникает задача различения двух семейств распределений. Для этих целей можно использовать критерий отношения правдоподобия (RML-тест).

Пусть $H_0 : \theta \in \Theta_0$ и $H_1 : \theta \in \Theta_1$, где $\Theta_0 \cap \Theta_1 = \emptyset$ и $\Theta_0 \cup \Theta_1 \subseteq \Theta$. Введем статистику

$$\lambda_n(X, \Theta_0) = \frac{\sup_{\theta \in \Theta_0} f(X, \theta)}{\sup_{\theta \in \Theta} f(X, \theta)},$$

также используется статистика

$$\lambda'_n(X) = \frac{\sup_{\theta \in \Theta_0} f(X, \theta)}{\sup_{\theta \in \Theta_1} f(X, \theta)}.$$

Теорема Уилкса.

Пусть $\Theta \subset \mathbb{R}^k$, $\dim(\Theta) = k$, $\dim(\Theta_0) = s < k$,
тогда при верности гипотезы $H_0 : \theta \in \Theta_0$
выполнено

$$-2 \ln \lambda_n(X, \Theta_0) \xrightarrow{d} \chi_{k-s}^2, \quad n \rightarrow \infty.$$

Кроме того, критерий

$\tilde{S} = \{x : -2 \ln \lambda_n(X, \Theta_0) \geq u_{1-\alpha}\}$, является
состоятельным, где $u_{1-\alpha}$ – $(1 - \alpha)$ -квантиль
распределения χ_{k-s}^2 .

Пусть $H_0 : P \in \mathcal{P}_0 = \{P_\theta, \theta \in \Theta\}$ и $H_1 : P \in \mathcal{P}_1 = \{\tilde{P}_\gamma, \gamma \in \Gamma\}$. Рассмотрим статистику

$$K = \frac{P(\mathcal{P}_0|X)}{P(\mathcal{P}_1|X)} = \frac{\int_{\Theta} f(X, \theta) q(\theta) d\theta}{\int_{\Gamma} \tilde{f}(X, \gamma) \tilde{q}(\gamma) d\gamma},$$

где $q(\theta)$ и $\tilde{q}(\gamma)$ – априорные плотности параметров θ и γ соответственно, а f и $\tilde{f}$ – функции правдоподобия, построенные по семействам $\mathcal{P}_0$ и $\mathcal{P}_1$ соответственно.

Заметим, что распределение статистики K не зависит от параметров θ и γ , поэтому можно найти её распределение при условии верности H_0 и H_1 (или промоделировать его) и в соответствии с этим построить критерий.




Но если нет времени, то есть шкала Джеффри!

K	верна ли H_0 ?
1-3	нельзя определенно сказать
3-10	большие основания принять H_0
10-30	почти наверняка
>30	точно

Пусть значение статистики критерия $T(X)$ на наблюдении X равно t . Тогда p-значение – такая величина, которая является функцией от t и равна вероятности того, что $T(X)$ (на другой реализации наблюдения X) примет значение “экстремальнее”, чем t .

Правило проверки гипотезы с помощью p-значения выглядит так: если $p < \alpha$, где α – уровень значимости критерия, то отвергаем основную гипотезу.

В случае левостороннего критерия
 $p = P(T(X) < t)$, в случае правостороннего критерия
 $p = P(T(X) > t)$, в случае двустороннего критерия
 $p = 2 \min\{P(T(X) < t), P(T(X) > t)\}$.



<u>P-VALUE</u>	<u>INTERPRETATION</u>
0.001	HIGHLY SIGNIFICANT
0.01	
0.02	
0.03	
0.04	SIGNIFICANT
0.049	
0.050	OH CRAP REDO CALCULATIONS.
0.051	ON THE EDGE OF SIGNIFICANCE
0.06	
0.07	HIGHLY SUGGESTIVE, SIGNIFICANT AT THE $P < 0.10$ LEVEL
0.08	
0.09	
0.099	HEY, LOOK AT THIS INTERESTING SUBGROUP ANALYSIS
≥ 0.1	

Примерно так принимают решения о значимости эффекта на основании р-значения (при основной гипотезе, что эффект незначим).

Пример (habrahabr.ru/company/stepic/blog/250527/).

Допустим, мы хотим выяснить, существует ли связь между пристрастием к шутерам и агрессивностью у школьников. Для этого отобрали группу школьников, играющих в шутеры, и группу школьников, не играющих в компьютерные игры.

В качестве показателя агрессивности возьмём количество драк с участием конкретного школьника за месяц, в качестве основной гипотезы – что связи нет. Допустим, мы сравнили показатели 2 этих групп с помощью критерия хи-квадрат на уровне значимости 0.05 и получили p-значение, равное 0.04.

О чем говорит p-значение 0.04 в данном случае?

- 1 Компьютерные игры — причина агрессивного поведения с вероятностью 96%;
- 2 Вероятность того, что агрессивность и компьютерные игры не связаны, равна 0.04;
- 3 Если бы мы получили p-значение больше, чем 0.05, это означало бы, что агрессивность и компьютерные игры никак не связаны между собой;
- 4 Вероятность случайно получить такие различия равняется 0.04.
- 5 Ни один из вариантов не верен.

Ключевой вопрос: Допустим, при проверке некоторой гипотезы двумя критериями p-значение первого критерия оказалось меньше уровня значимости, а p-значение второго критерия больше. Как следует поступить: отвергнуть гипотезу или принять её?

Ключевой вопрос: Допустим, при проверке некоторой гипотезы двумя критериями p-значение первого критерия оказалось меньше уровня значимости, а p-значение второго критерия больше. Как следует поступить: отвергнуть гипотезу или принять её?

Ответ: Нужно применить множественную проверку гипотез.

Table 5. The probability of correct selection (PCS) based on Monte Carlo (MC) simulations and also based on asymptotic results (AS) when the data are from log-normal distribution for different values of p .

	n					
	20	40	60	80	100	200
$p = 0.9$						
MC	0.731	0.814	0.869	0.913	0.931	0.987
AS	0.770	0.852	0.900	0.930	0.951	0.990
$p = 0.8$						
MC	0.693	0.782	0.846	0.877	0.923	0.974
AS	0.739	0.817	0.866	0.899	0.923	0.978
$p = 0.7$						
MC	0.689	0.761	0.810	0.848	0.878	0.948
AS	0.710	0.783	0.831	0.865	0.892	0.960
$p = 0.6$						
MC	0.662	0.728	0.749	0.784	0.826	0.911
AS	0.682	0.748	0.793	0.828	0.829	0.932
$p = 0.5$						
MC	0.617	0.665	0.686	0.749	0.750	0.842
AS	0.655	0.713	0.755	0.787	0.813	0.896
$p = 0.4$						
MC	0.568	0.666	0.663	0.690	0.715	0.786
AS	0.628	0.678	0.714	0.743	0.768	0.849
$p = 0.3$						
MC	0.598	0.647	0.676	0.683	0.717	0.785
AS	0.601	0.641	0.671	0.695	0.716	0.789

Таблица вероятностей правильного принятия решения с помощью RML-теста в задаче различения логнормального и вейбулловского распределений в случае, если выборка имеет логнормальное распределение. p – доля минимальных членов вариационного ряда, взятых для построения теста.

	$n = 100$ $k = 10$	$n = 100$ $k = 20$	$n = 200$ $k = 20$	$n = 200$ $k = 50$	$n = 500$ $k = 50$	$n = 1000$ $k = 50$	$n = 5000$ $k = 50$
log-Pareto(2)	0.28	0.71	0.49	0.98	0.84	0.6	0.19
log-Pareto(1)	0.06	0.12	0.07	0.3	0.09	0.06	0.04
log-Gamma	0.37	0.58	0.62	0.89	0.94	0.97	0.99
Cauchy	0.51	0.8	0.8	0.99	0.99	1	1
Pareto(2)	0.92	1	1	1	1	1	1
LN(0,1)	0.91	0.98	1	1	1	1	1

Таблица эмпирических вероятностей ошибок I рода (первые 2 строчки) и эмпирических мощностей критерия различения распределений с супер-тяжелыми и тяжелыми хвостами. k – количество максимальных членов вариационного ряда, используемых для построения критерия. Количество реализаций $m = 10000$.




Fig. 1. Empirical power (left) and estimated type I error probability (right) of $T_n(k)$ at a nominal level $\alpha = 0.05$, built on 5000 samples of size $n = 1000$ from the prescribed parent distributions, all plotted against $k = 3, 4, \dots, 200$.

Графики эмпирических вероятностей ошибок I рода (справа) и эмпирических мощностей (слева) того же критерия. Количество реализаций $m = 5000$, размер выборок $n = 1000$.





График значений некой оценки параметра θ и его 95%-доверительного интервала, построенного по этой оценке. Судя по этому графику, можно отвергнуть гипотезу о том, что $\theta = 1$, на уровне значимости 0.05.



Ящики с усами (boxplots) эксперимента Майкельсона-Морли по измерению скорости света.

Boxplot – графическое изображение некоторых свойств выборки или распределения. В частности, помогает сравнить между собой несколько наборов данных на предмет несовпадения их распределений.

- 1 Жирная линия в середине ящика - медиана выборки (или распределения, изредка - выборочное среднее или мат. ожидание);
- 2 Верхняя и нижняя границы ящика – верхняя и нижняя квартили выборки соответственно, Q_3 и Q_1 (т.е. выборочные квантили уровня 0.75 и 0.25, или медианы наблюдений левее и правее выборочной медианы соответственно);

- 3 Границы верхнего и нижнего “усов” ящика, как правило, определяются как наибольшее наблюдение, меньшее $Q_3 + 1.5(Q_3 - Q_1)$, и наименьшее наблюдение, большее $Q_1 - 1.5(Q_3 - Q_1)$, соответственно. Разница $Q_3 - Q_1$ называется интерквартильным размахом.
- 4 Кружки выше и ниже границы усов считаются выбросами. Выбросы также могут определяться с помощью статистических тестов.

Violin plot





Figure 1. Common Components of Box Plot and Violin Plot. Total compensation for all academic ranks.

Violin plot является более информативным аналогом box plot. Этот график содержит те же элементы, что и box plot, но его границы представляют собой ядерную оценку плотности распределения выборки.

Finita!

Методы современной прикладной статистики

3. Критерии согласия, проверка нормальности, бутстреп

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Пусть $X_1, \dots, X_n$ – выборка из неизвестного распределения с функцией распределения F .

Рассмотрим гипотезу $H_0 : F = F_0$ против альтернативы $H_1 : F \neq F_0$.

Критерии проверки таких гипотез называются **критериями согласия**.

Критерий Колмогорова-Смирнова

Рассмотрим статистику

$$D_n := \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F_0(x)|,$$

где $\hat{F}_n(x)$ – эмпирическая функция распределения.

Теорема Колмогорова

Если F_0 – непрерывна, то при верной гипотезе H_0

$$P(\sqrt{n}D_n \leq x) \xrightarrow{n \rightarrow \infty} K(x) = \sum_{k \in \mathbb{Z}} (-1)^k e^{-2k^2 x^2}.$$

Критерий Колмогорова-Смирнова

Таким образом, критерий Колмогорова-Смирнова выглядит так:

если $\sqrt{n}D_n > K_{1-\alpha}$, то отвергнуть H_0 ,

где $K_{1-\alpha}$ – $(1 - \alpha)$ -квантиль функции распределения $K(x)$. Если α близко к 0, то

$$K_{1-\alpha} \approx \sqrt{-\frac{1}{2} \ln \frac{\alpha}{2}}.$$

Критерий хи-квадрат Пирсона

По-прежнему проверяем гипотезу $H_0 : F = F_0$. Пусть P_0 – вероятностная мера (на $\mathbb{R}$), соответствующая функции распределения F_0 .

Разобьем $\mathbb{R}$ на k интервалов $\{B_i\}_{i=1}^k$ (обычно k порядка 10) таких, что $nP_0(B_i) \geq 5 \forall i$ (B_i выбираются заранее, вне зависимости от данных!). Обозначим $p_i^0 = P_0(B_i)$, $\mu_i = \#\{j : X_j \in B_i\}$.

Теорема Карла Пирсона.

Пусть гипотеза H_0 верна, тогда

$$\hat{\chi} := \sum_{i=1}^k \frac{(\mu_i - np_i^0)^2}{np_i^0} \xrightarrow{d} \chi_{k-1}^2, \quad n \rightarrow \infty.$$

Критерий хи-квадрат Пирсона

Критерий хи-квадрат выглядит так

если $\hat{\chi} > u_{1-\alpha}$, то отвергнуть H_0 ,

где $u_{1-\alpha}$ – $(1 - \alpha)$ -квантиль распределения χ^2_{k-1} .

Критерий хи-квадрат кажется более грубым, чем критерий Колмогорова, однако он незаменим при работе с дискретными данными и зачастую показывает лучшие результаты, чем критерий Колмогорова, даже в случае “непрерывных” данных.

Другие критерии согласия

- Критерий Смирнова-Крамера-фон Мизеса (ω^2 -критерий) со статистикой

$$\omega^2 = \int (\hat{F}_n(x) - F_0(x))^2 dF_0(x);$$

- Критерий Андерсона-Дарлинга (Ω^2 -критерий) со статистикой

$$\Omega^2 = \int \frac{(\hat{F}_n(x) - F_0(x))^2}{F_0(x)(1 - F_0(x))} dF_0(x);$$

Другие критерии согласия

- Критерий Фроцини

$$\int |\hat{F}_n(x) - F_0(x)| dF_0(x);$$

- Критерий Купера

$$\sup_{x \in \mathbb{R}} (\hat{F}_n(x) - F_0(x)) + \sup_{x \in \mathbb{R}} (F_0(x) - \hat{F}_n(x));$$

- Критерий Ватсона

$$\int \left(\hat{F}_n(x) - F_0(x) - \int (\hat{F}_n(x) - F_0(x)) dF_0(x) \right)^2 dF_0(x).$$

Свойства критериев согласия

- Распределение статистик критериев при верности нулевой гипотезы не зависит от F_0 . Действительно, преобразование $Y_i = F_0(X_i)$ переводит случайные величины X_i в равномерно распределенные на $[0, 1]$. Поэтому при верности нулевой гипотезы статистики критериев всегда сходятся к одному и тому же предельному закону.
- Все перечисленные критерии согласия являются состоятельными.

Свойства критериев согласия

- Однако при ложности нулевой гипотезы критерии ведут себя по-разному. К сожалению, не существует критерия, который являлся бы р.н.м. критерием в данной задаче.
- Критерий Андерсона-Дарлинга показывает наилучшие результаты на большом классе распределений.
- Критерий Колмогорова, как правило, не очень хорошо ведет себя на альтернативе, в частности, плохо различает распределения, не совпадающие на хвостах.

Проверка сложных гипотез

Гораздо более значимой с практической точки зрения является задача определения семейства, к которому принадлежит распределение выборки (например, задача проверки нормальности данных).

Но прежде чем проверять данные на принадлежность какому-то семейству распределений, нужно определить наиболее подходящее семейство, чтобы не перебирать критерии вслепую.

Первоначальная обработка статистических данных, как правило, осуществляется с помощью методов описательной (дескриптивной) статистики, таких, как гистограмма распределения, Box-plot и QQ-plot.

Построение гистограммы выборки, её Box-plot и QQ-plot нужны для определения примерного (модельного) распределения данных, после чего применяются более точные методы и критерии для проверки адекватности выбранной модели.

Параметры сдвига и масштаба

Пусть имеется параметрическое семейство функций распределения $\{F_\theta(x), \theta \in \Theta\}$.


- Параметр θ называется параметром сдвига, если $F_\theta(x) = F_0(x - \theta)$;
- Параметр θ называется параметром масштаба, если $F_\theta(x) = F_1(x/\theta)$;
- Параметр, не являющийся параметром сдвига или масштаба, называется параметром формы.

К примеру, для семейства распределений $N(a, \sigma^2)$ параметр a является параметром сдвига, а σ – параметром масштаба, оба параметра бета-распределения являются параметрами формы.


Допустим, мы хотим проверить гипотезу $H_0 : F(x) = F_0\left(\frac{x-a}{\sigma}\right) \quad \forall x$ (т.е. гипотеза о принадлежности семейству распределений с параметрами сдвига и масштаба).

QQ-plot – это график, на который нанесены точки $\left(F_0^{-1}\left(\frac{i-0.5}{n}\right), X_{(i)}\right)$ (другая нормировка: $\frac{i}{n+1}$ вместо $\frac{i-0.5}{n}$). Если точки примерно лежат на одной прямой, то распределение данных близко к F_0 (с точностью до параметров сдвига и масштаба).



Symmetric distribution





Normal Q-Q Plot



На рисунке: QQ-plot относительно нормального распределения (Normal QQ-plot) для выборки из нормального закона (среднее – 0, дисперсия ≈ 4). Так же QQ-plot может выглядеть для выборки из распределения Стьюдента с большим числом степеней свободы.




На рисунке: Normal QQ-plot для выборки с тяжелыми (относительно нормального закона) хвостами (heavy tails).
Примеры: 2-sided *Pareto*, *Laplace*, *St*, *Cauchy* и тд.




На рисунке: Normal Q-Q-plot для выборки с легкими (относительно нормального закона) хвостами (light tails).
Примеры: распределения с ограниченным носителем.

Postive skew




Normal Q-Q Plot




На рисунке: Normal QQ-plot для выборки из правоскошенного распределения (right-skewed). Примеры: *Gamma*, *LN*, *Poisson*, right-skewed normal.

Negative skew



Normal Q-Q Plot



На рисунке: Normal QQ-plot для выборки из левоскошенного распределения (left-skewed). Примеры: *Inverse-Gamma*, left-skewed normal.

Почему работает QQ-plot

Объясним, почему точки $(F_0^{-1}(\frac{i-0.5}{n}), X_{(i)})$, $i = 1, \dots, n$ должны лежать примерно на одной прямой, если $\{X_i\}_{i=1}^n$ – выборка из $F_0(\frac{x-a}{\sigma})$.

Пусть $\{Y_i\}_{i=1}^n$ – выборка из $F_0(x)$, тогда по теореме о выборочной квантили

$$Y_{(i)} - F_0^{-1}\left(\frac{i}{n}\right) \xrightarrow{P} 0, \quad n \rightarrow \infty,$$

т.е. при достаточно больших n $Y_{(i)} \approx F_0^{-1}(\frac{i-0.5}{n})$. Но $\frac{X_{i-a}}{\sigma} \stackrel{d}{=} Y_i$, откуда $\frac{X_{(i)}-a}{\sigma} \stackrel{d}{=} Y_{(i)} \approx F_0^{-1}(\frac{i-0.5}{n})$, т.е. точки $(F_0^{-1}(\frac{i-0.5}{n}), X_{(i)})$ должны лежать около прямой $y = bx + a$.

Модификация критериев согласия

Один из методов проверки принадлежности распределения выборки какому-либо семейству распределений заключается в применении критериев согласия.

Пусть семейство функций распределения $\{F(x; a, b)\}$ параметризовано параметрами сдвига и масштаба, т.е. $F(x; a, b) = F_0(\frac{x-a}{b})$, где $F_0(x) = F(x; 0, 1)$.

Пусть $\hat{a}$ и $\hat{b}$ – состоятельные оценки параметров a и b соответственно (как правило, методом максимального правдоподобия).

Тогда для проверки гипотезы $H_0 : F \in \{F(x; a, b)\}$ можно воспользоваться критерием согласия, где вместо $F_0(x)$ в статистике критерия нужно подставить $F_0(\frac{x-\hat{a}}{\hat{b}})$.

Критерий Лиллиефорса

В частности, если для семейства нормальных распределений $\{N(a, \sigma^2)\}$ в качестве критерия согласия взять критерий Колмогорова-Смирнова со статистикой $D_n = \sup_x |\hat{F}_n(x) - F_0(x)|$, а в качестве оценок параметров a и σ^2 – выборочное среднее и выборочную дисперсию соответственно, то получим **критерий Лиллиефорса** проверки нормальности выборки.

Замечание. Предельные распределения статистик модифицированных критериев согласия при верности нулевой гипотезы могут существенно зависеть не только от вида семейства распределений, но и от вида выбранных оценок параметров.

Критерий Лиллиефорса

Таблица квантилей уровня $1 - \alpha$ распределений Лиллиефорса и Колмогорова, при $n > 30$ можно пользоваться ими.

Критические значения $\lambda_{\alpha 0}$ для распределений:	Уровень значимости α			
	0,20	0,10	0,05	0,01
Распределение Колмогорова	1,073	1,224	1,358	1,627
Распределение Лиллиефорса	0,736	0,805	0,886	1,031

Обобщенный критерий хи-квадрат

Обобщенный критерий хи-квадрат позволяет проверять гипотезы общего вида

$H_0 : F \in \mathcal{P}_0 = \{P_\theta, \theta \in \Theta\}$, где $\dim(\Theta) = d$,
против альтернативы $H_0 : F \notin \mathcal{P}_0$.

Как и ранее, разобьем $\mathbb{R}$ на несколько интервалов $\{B_i\}_{i=1}^k$, $k > d$, и обозначим $\mu_i = \#\{j : X_j \in B_i\}$,
 $p_i(\theta) = P_\theta(B_i)$, потребовав $\forall \theta \in \Theta$ выполнения
 $p_i(\theta) > c > 0$.

Обобщенный критерий хи-квадрат

Теорема Фишера.

Пусть Θ – открытое множество в $\mathbb{R}^d$. Предположим, что матрица частных производных $\left\| \frac{\partial p_i(\theta)}{\partial \theta_j} \right\|$ имеет ранг d для всех $\theta \in \Theta$. Пусть $\hat{\theta}$ – ОМП по “выборке” $\mu_1, \dots, \mu_k$, т.е.

$$\hat{\theta} = \arg \max_{\theta \in \Theta} \frac{n!}{\mu_1! \dots \mu_k!} \prod_{i=1}^k p_i^{\mu_i}(\theta),$$

или $\hat{\theta}$ – оценка по минимуму хи-квадрат, т.е.

$$\hat{\theta} = \arg \min_{\theta \in \Theta} \sum_{i=1}^k \frac{(\mu_i - np_i(\theta))^2}{np_i(\theta)}.$$

Тогда при условии верности H_0 выполнено

$$\chi(\hat{\theta}) = \sum_{i=1}^k \frac{(\mu_i - np_i(\hat{\theta}))^2}{np_i(\hat{\theta})} \xrightarrow{d} \chi_{k-d-1}^2, n \rightarrow \infty.$$

Проверка нормальности

Критерий (типа) Шапиро-Уилка

Проверяется гипотеза $H_0 : F \in \{N(a, \sigma^2)\}$ против альтернативы $H_1 : F \notin \{N(a, \sigma^2)\}$. Статистика критерия

$$W = \frac{(\sum_{i=1}^n a_i X_{(i)})^2}{\sum_{i=1}^n (X_i - \bar{X})^2},$$

где $(a_1, \dots, a_n) = \frac{m^T V^{-1}}{\|m^T V^{-1}\|^2}$, $(m_1, \dots, m_n)$ – мат. ожидания порядковых статистик выборки размера n из $N(0, 1)$, а V – матрица ковариаций этих порядковых статистик.

При верной гипотезе H_0 статистика W имеет табличное распределение, значения вектора $(a_1, \dots, a_n)$ также табулированы.

Проверка нормальности

Критерий Харке-Бера тоже используется для проверки выборки на нормальность. Рассмотрим статистику

$$JB = \frac{n}{6}((Sk)^2 + \frac{1}{4}(Ku)^2),$$

где $Sk = \frac{m_3}{m_2^{3/2}}$, $Ku = \frac{m_4}{m_2^2} - 3$ и $m_j = \frac{1}{n} \sum_i (X_i - \bar{X})^j$, $j \in \mathbb{N}$ – выборочные центральные моменты.

При $n > 2000$ $JB \approx \chi^2(2)$, при меньших n следует искать квантили в таблицах. Модификацией критерия Харке-Бера является довольно точный комбинированный K^2 -критерий.

Проверка нормальности

Сравнение критериев проверки
нормальности распределения случайных величин

Наименование критерия (раздел)	Характер альтернативного распределения					Ранг
	асимметричное		симметричное		$\approx$ нормальное	
	$\alpha_1 < 3$	$\alpha_1 > 3$	$\alpha_4 < 3$	$\alpha_4 > 3$	$\alpha_4 \approx 3$	
Критерий Шапиро-Уилка (3.2.2.1)	1	1	3	2	2	1
Критерий K^2 (3.2.2.16)	7	8	10	6	4	2
Критерий Дарбина (3.1.2.7)	11	7	7	15	1	3
Критерий Д'Агостино (3.2.2.14)	12	9	4	5	12	4
Критерий α_4 (3.2.2.16)	14	5	2	4	18	5
Критерий Васичека (3.2.2.2)	2	14	8	10	10	6
Критерий Дэвида-Хартли-Пирсона (3.2.2.10)	21	2	1	9	1	7
Критерий χ^2 (3.1.1.1)	9	20	9	8	3	8
Критерий Андерсона-Дарлинга (3.1.2.4)	18	3	5	18	7	9
Критерий Филлибена (3.2.2.5)	3	12	18	1	9	10
Критерий Колмогорова-Смирнова (3.1.2.1)	16	10	6	16	5	11
Критерий Мартинеса-Иглевица (3.2.2.14)	10	16	13	3	15	12
Критерий Лина-Мудхолкара (3.2.2.13)	4	15	12	12	16	13
Критерий α_3 (3.2.2.16)	8	6	21	7	19	14
Критерий Шпигельхальтера (3.2.2.11)	19	13	11	11	8	15
Критерий Саркади (3.2.2.12)	5	18	15	14	13	16
Критерий Смирнова-Крамера-фон Мизеса (3.1.2.2)	17	11	20	17	6	17
Критерий Локка-Спурье (3.2.2.7)	13	4	19	21	17	18
Критерий Оя (3.2.2.8)	20	17	14	13	14	19
Критерий Хегази-Грина (3.2.2.3)	6	19	16	19	21	20
Критерий Муроты-Такеучи (3.2.2.17)	15	21	17	20	20	21

Кобзарь, 3.2.2.19, табл. 80.

Допустим, мы хотим оценить параметр θ с помощью асимптотически нормальной оценки $\hat{\theta}_n$,

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d_\theta} N(0, \sigma^2(\theta)), n \rightarrow \infty.$$

Но реальная дисперсия $\hat{\theta}_n$ при фиксированном n может сильно отличаться от $\sigma^2(\theta)/n$, т.е. вероятность покрытия асимптотическим доверительным интервалом истинного значения θ может быть гораздо ниже заявленной.

Пусть $X_1, \dots, X_n$ – выборка из неизвестной ф.р. F . Тогда возьмем в качестве нового выборочного пространства значения $(X_1, \dots, X_n)$ и положим каждому значению вероятность $1/n$.

Полученное дискретное распределение будет иметь функцию распределения $\hat{F}_n$. Бутстреп – это семплирование одной или нескольких выборок из $\hat{F}_n$. Поскольку $\hat{F}_n$ при больших n близка к F , то бутстрепная выборка будет похожа на выборку из ф.р. F .

Бутстрепная оценка дисперсии

Пусть имеется некоторая статистика

$T_n(X) = T_n(X_1, \dots, X_n)$, найдем оценку её дисперсии с помощью бутстрепа.

Семплируем m бутстрепных выборок

$\{X_{i,1}^*\}_{i=1}^n, \dots, \{X_{i,m}^*\}_{i=1}^n$ из совокупности $\{X_1, \dots, X_n\}$ и найдем $T_{n,j}^* = T_n(X_{1,j}^*, \dots, X_{n,j}^*) \forall j \in \{1 \dots m\}$.

Тогда оценка методом бутстрепа дисперсии статистики $T_n(X)$ будет равна

$$v_{boot}(T) = \frac{1}{m} \sum_{j=1}^m \left(T_{n,j}^* - \frac{1}{m} \sum_{j=1}^m T_{n,j}^* \right)^2.$$

Нормальный интервал

Предположим, что $T_n(X)$ оценивает некий параметр θ ; также предположим, что распределение $T_n(X)$ близко к нормальному.

Тогда можно предложить следующий доверительный интервал уровня доверия $1 - \alpha$ для параметра θ :

$$\left(T_n + z_{\alpha/2} \sqrt{v_{boot}(T)}, T_n + z_{1-\alpha/2} \sqrt{v_{boot}(T)} \right),$$

где z_γ — γ -квантиль $N(0, 1)$.


Центральный интервал

Заметим, что поскольку $T_n(X)$ является оценкой для θ , а $T_{n,1}^*$ — для $T_n(X)$, то $T_{n,1}^* - T_n$ оценивает $T_n - \theta$.

Рассмотрим вариационный ряд совокупности $\{T_{n,1}^*, \dots, T_{n,m}^*\} : T_{(1)}^* \leq T_{(2)}^* \leq \dots \leq T_{(m)}^*$.

Тогда с большой вероятностью $T_n(X) - \theta$ лежит в интервале $(T_{(\lceil m\alpha/2 \rceil)}^* - T_n, T_{(\lceil m(1-\alpha)/2 \rceil)}^* - T_n)$, т.е. получаем следующий доверительный интервал для θ

$$\left(2T_n - T_{(\lceil m(1-\alpha)/2 \rceil)}^*, 2T_n - T_{(\lceil m\alpha/2 \rceil)}^*\right).$$



Сравнение длин асимптотического и бутстрепного доверительного интервала для оценки стандартного отклонения.

Предшественник бутстрепа – метод складного ножа. Пусть имеется выборка $(X_1, \dots, X_n)$ и статистика $T_n(X) = T_n(X_1, \dots, X_n)$. Обозначим

$$\begin{aligned}\hat{T}_1 &= T_{n-1}(X_2, \dots, X_n); \\ \hat{T}_2 &= T_{n-1}(X_1, X_3, \dots, X_n); \dots \\ \hat{T}_n &= T_{n-1}(X_1, \dots, X_{n-1}).\end{aligned}$$

Если T_n – оценка параметра θ , то для оценки смещения $Bias = T_n - \theta$ можно использовать оценку

$$(n-1) \left(\frac{1}{n} \sum_{i=1}^n \hat{T}_i - T_n \right),$$

Также можно оценить дисперсию T_n следующим образом

$$v_{jack} = \frac{n-1}{n} \sum_{i=1}^n \left(\hat{T}_i - \frac{1}{n} \sum_{i=1}^n \hat{T}_i \right)^2.$$

Finita!

Методы современной прикладной статистики

4.1. Выбросы


Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Предварительные замечания

Выброс – результат измерения, выделяющийся из общей выборки, являющийся ошибкой сбора или обработки данных.

Удалять выбросы можно только в том случае, если вы абсолютно уверены, что они не являются значимыми для последующих статистических выводов о данных.



Предварительные замечания

Зачастую выбросы не удаляются из данных, а учитываются при подсчете статистик с меньшим весом, чем остальные наблюдения, как в методах робастной и непараметрической регрессии, или вовсе не учитываются, как в случае использования выборочной медианы.

Удалять выбросы и после этого рассматривать на очищенных данных параметрическую модель не рекомендуется, потому что выброшенные данные могут быть значимыми для модели.

Предварительные замечания

Выбросы можно распознать визуально (с помощью методов понижения размерности понизив размерность данных до 2 или 3), а также с помощью методов кластеризации (если в кластере один объект, то велика вероятность, что это выброс).

Методы машинного обучения для борьбы с выбросами: one-class SVM, robust covariance (расстояние Махаланобиса), isolation forest, local outlier factor.

Предварительные замечания




Рис. 1.1. Корреляционное поле, характеризующее связь между численностью населения ξ и числом установленных телевизионных точек η в США в 1953 г.:

а) в девяти городах; б) в десяти городах

R^2 первой модели равняется 0.18, второй – 0.99. Стоит ли считать Нью-Йорк выбросом в данной модели?


Метод Тьюки работает только для одномерных данных (по-хорошему, нормально распределенных) и используется при построении ящика с усами. Если элемент выборки не попадает в интервал

$$(Q_1 - k(Q_3 - Q_1), Q_3 + k(Q_3 - Q_1)),$$

то он объявляется выбросом. Здесь Q_1 и Q_3 – выборочные 1-я и 3-я квартили соответственно, параметр k , как правило, полагается равным 1.5.

Границы Тьюки

Границы Тьюки адекватно работают, если плотность распределения имеет колоколообразный вид и выброс находится не в середине выборки, а с краю от неё.



Пусть $X_1, \dots, X_n$ – выборка и X_i – некое отстоящее от выборки наблюдение. Если

$$\left| \frac{X_i - \bar{X}}{s} \right| > u_{1-\frac{1}{4n}},$$

то считаем, что X_i является выбросом. Здесь $u_{1-\frac{1}{4n}}$ – квантиль $N(0, 1)$ соответствующего уровня, $\bar{X}$ – выборочное среднее, s – корень из выборочной дисперсии.

Аналогично границам Тьюки, критерий не различает выбросы, находящиеся по центру значений выборки.

Критерий Граббса

Предполагаем, что выборка $X_1, \dots, X_n$ сделана из нормального закона. Рассмотрим статистику Граббса

$$G = \frac{\max_i |X_i - \bar{X}|}{s},$$

где $\bar{X}$, как и ранее, выборочное среднее, s – корень из выборочной дисперсии.

Обозначим через $u_{\alpha/2n}$ квантиль уровня $\frac{\alpha}{2n}$ распределения Стьюдента с $n - 2$ степенями свободы. Тогда если

$$G > \frac{n-1}{\sqrt{n}} \sqrt{\frac{u_{\alpha/2n}^2}{n-2+u_{\alpha/2n}^2}},$$

то отвергаем гипотезу об отсутствии выбросов на уровне значимости α .

В отличие от критерия Шовенэ и Q-критерия Диксона, критерий Граббса является настоящим статистическим критерием.


Кроме того, критерий Граббса можно применить и для удаления нескольких выбросов. Для этого после удаления очередного выброса нужно пересчитывать статистику Граббса и критический уровень с учетом понижения n на единицу.

Алгоритм Isolation forest заключается в построении случайного бинарного решающего дерева. В очередном узле выбирается случайный признак и случайный порог разбиения (выбирается равномерно на отрезке от минимального до максимального значения признака).

Когда число листьев совпадет с числом объектов, алгоритм останавливается. Ответом на листе объявляется его глубина в построенном дереве.

Утверждается, что аномальным точкам/выбросам свойственно оказываться в листьях с низкой глубиной. Окончательный результат усредняется по нескольким запускам алгоритма.

Isolation forest



Пример работы алгоритма Isolation forest. Красным цветом отмечена низкая глубина листа соответствующего объекта, зеленым – высокая.

Алгоритм обладает рядом несомненных преимуществ:

- распознает аномалии разных типов: как изолированные точки, так и кластеры аномалий малых размеров;
- не требует больших затрат по памяти, в отличие от многих метрических алгоритмов, где часто требуется хранить матрицы попарных расстояний;
- обладает только одним параметром, требующим подбора - процент данных, которые нужно отбросить;
- инвариантен к масштабированию признаков;
- устойчив к увеличению размерности пространства признаков.

Метрические методы

Пусть на пространстве признаков задана метрика $\rho(x, y)$.
В качестве anomaly score можно брать


- расстояние до k -того ближайшего соседа или среднее/медиану расстояний до k ближайших соседей;
- значение локальной плотности, заданной непараметрически (например, с помощью ядерных оценок);
- размер кластера, в котором оказалась точка.

Достоинства: результаты легко интерпретируемы.

Недостатки: непонятно, как выбирать k и метрику; даже при наилучшем подборе метрики аппроксимация может оказаться грубой.

Метрические методы

Примеры работы метрических алгоритмов.




Но локальная плотность точки, лежащей в небольшом кластере аномалий, может оказаться выше, чем для любой точки из большого кластера нормальных данных. Эту проблему призван исправить метод Local outlier factor.

Определим $D_k(y)$ – расстояние от точки y до k -того ближайшего соседа. Досягаемостью точки x относительно y называется величина $R_k(x, y) = \max(\rho(x, y), D_k(y))$.

Пусть $AR_k(x)$ – средняя досягаемость x относительно $N_k(x)$, множества k своих ближайших соседей, тогда


$$LOF_k(x) = \frac{1}{k} \sum_{y \in N_k(x)} \frac{AR_k(x)}{AR_k(y)}.$$

Local outlier factor



Значения $LOF \approx 1$ говорят о том, что объект находится в кластере, значительно больше 1 – что объект изолирован, меньше единицы – что объект в области локально высокой плотности.

Local outlier factor



Finita!

Методы современной прикладной статистики

4.2. Множественная проверка гипотез

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Проблема баяниста



5 раз Игорь Владимирович проходил одним подземным переходом, и 5 раз там сидел баянист и не играл. Можно ли отвергнуть гипотезу о том, что баянист играет большую часть времени?

Проблема баяниста



На шестой раз баянист играл. С тех пор он гораздо чаще играл, чем нет. Т.е. была совершена ошибка первого рода. Её можно было избежать, если бы Игорь Владимирович применил метод множественной проверки гипотез (или хотя бы подождал).

Постановка задачи

Пусть имеются данные $X = \{X_i^{(j)}\}$, $1 \leq i \leq n_j$, $1 \leq j \leq m$.

По ним проверяем гипотезы $H_j : P_j \in \mathcal{P}_j$ против альтернатив $H'_j : P_j \notin \mathcal{P}_j$ с помощью статистик $T_j = T_j(X_1^{(j)}, \dots, X_{n_j}^{(j)})$.

Пусть $p_j = p_j(T_j)$ – р-значения критериев.

Постановка задачи

Обозначим $M = \{1, \dots, m\}$, M_0 – индексы верных гипотез, $|M_0| = m_0$, R – число отвергнутых гипотез, V – число ошибок первого рода.

	# верных H_j	# ложных H_j	Всего
# принятых H_j	U	T	m-R
# отвергнутых H_j	V	S	R
Всего	m_0	$m-m_0$	m

Групповая вероятность ошибки I рода (family-wise error rate)

$$FWER = P(V > 0).$$

Контроль над FWER на уровне α означает, что

$$FWER = P(V > 0) \leq \alpha$$

для всех распределений из верных гипотез $H_j, j \in M_0$.

Пусть $\alpha_1, \dots, \alpha_m$ – уровни значимости критериев проверки гипотез $H_1, \dots, H_m$ соответственно. Хотим их выбрать таким образом, чтобы $FWER \leq \alpha$.

Метод Бонферрони: $\alpha_1 = \dots = \alpha_m = \frac{\alpha}{m}$.

Действительно,

$$FWER = P(V > 0) = P(\exists j \in M_0 : p_j \leq \alpha/m) \leq$$

$$\sum_{j \in M_0} P(p_j \leq \alpha/m) \leq m_0 \cdot \frac{\alpha}{m} \leq \alpha.$$

Главный недостаток метода – резкое уменьшение мощности статистической процедуры при $m \rightarrow \infty$.

Метод Шидака: $\alpha_1 = \dots = \alpha_m = 1 - (1 - \alpha)^{1/m}$.

Метод дает $FWER \leq \alpha$ при условии, что статистики T_i независимы или выполнено свойство “положительной зависимости” (при этом критерии должны быть правосторонними):

$$P(T_1 \leq t_1, \dots, T_m \leq t_m) \geq \prod_{i=1}^m P(T_i \leq t_i) \quad \forall \vec{t} \in \mathbb{R}^m.$$

Положительную зависимость, в частности, можно установить с помощью FKG-неравенства: если $f(x)$ и $g(x)$ – возрастающие (убывающие) функции, то $Ef(X)g(X) \geq Ef(X)Eg(X)$.

Нисходящие процедуры

Составим вариационный ряд p -значений

$$p_{(1)} \leq \dots \leq p_{(m)},$$

где $H_{(1)}, \dots, H_{(m)}$ – соответствующие гипотезы. Процедура выглядит так:

- 1 Если $p_{(1)} \geq \alpha_1$, то принимаем все гипотезы $H_{(1)}, \dots, H_{(m)}$ и останавливаемся, иначе отвергаем $H_{(1)}$ и продолжаем;
- 2 Если $p_{(2)} \geq \alpha_2$, то принимаем все гипотезы $H_{(2)}, \dots, H_{(m)}$ и останавливаемся, иначе отвергаем $H_{(2)}$ и продолжаем;
- 3 ...

Метод Холма: нисходящая процедура с уровнями значимости

$$\alpha_1 = \frac{\alpha}{m}, \dots, \alpha_i = \frac{\alpha}{m - i + 1}, \dots, \alpha_m = \alpha.$$

Свойства:

- 1 контролирует FWER на уровне значимости α ;
- 2 равномерно мощнее метода Бонферрони;
- 3 если характер зависимости между статистиками $\{T_i\}$ неизвестен, то нельзя построить процедуру, контролирующую FWER на уровне α , мощнее, чем метод Холма.

Метод Шидака-Холма: нисходящая процедура с уровнями значимости

$$\alpha_1 = 1 - (1 - \alpha)^{\frac{1}{m}}, \dots, \alpha_i = 1 - (1 - \alpha)^{\frac{1}{m-i+1}}, \dots, \alpha_m = \alpha.$$

Свойства:

- 1 контролирует FWER на уровне значимости α , если статистики $\{T_i\}$ **независимы в совокупности**;
- 2 если статистики $\{T_i\}$ независимы в совокупности, то нельзя построить контролирующую FWER на уровне α процедуру мощнее, чем метод Шидака-Холма;
- 3 при больших m мало отличается от метода Холма.

Ожидаемая доля ложных отклонений гипотез (false discovery rate)

$$FDR = E \left(\frac{V}{\max(R, 1)} \right).$$

Контроль над FDR на уровне значимости α означает, что $FDR \leq \alpha$ для всех распределений из верных гипотез H_j , $j \in M_0$.

Поскольку $FDR = E \left(\frac{V}{\max(R, 1)} \right) \leq E I(V > 0) = P(V > 0) = FWER$, то в рамках процедур, контролирующих FDR на уровне α , случается больше ошибок первого рода.

Восходящие процедуры


Пусть, как и ранее, $p_{(1)} \leq \dots \leq p_{(m)}$ – вариационный ряд полученных p -значений, а $H_{(1)}, \dots, H_{(m)}$ – соответствующие им гипотезы.

Процедура выглядит так:

- ① Если $p_{(m)} < \alpha_m$, то отвергаем все гипотезы $H_{(1)}, \dots, H_{(m)}$ и останавливаемся, иначе принимаем $H_{(m)}$ и продолжаем;
- ② Если $p_{(m-1)} < \alpha_{m-1}$, то отвергаем все гипотезы $H_{(1)}, \dots, H_{(m-1)}$ и останавливаемся, иначе принимаем $H_{(m-1)}$ и продолжаем;
- ③ ...

Восходящие процедуры

Очевидно, что восходящая процедура отвергает не меньше гипотез, чем нисходящая с теми же $\{p_i\}$ и $\{\alpha_i\}$.



Метод Бенджамини-Хохберга: восходящая процедура,

$$\text{для которой } \alpha_i = \alpha \cdot \frac{i}{m}, \quad i = 1, \dots, m.$$

Метод контролирует FDR на уровне α , если $\{T_i\}$ независимы или выполнено свойство PRDS:

$$P(X \in D | T_i = x) \text{ не убывает по } x \quad \forall i \in M_0,$$

где D – возрастающее множество, т.е. если $\vec{y} \in D$ и $\vec{z} \geq \vec{y}$, то $\vec{z} \in D$.

В частности, свойство PRDS выполнено, если $X \sim N(a, \Sigma)$, где все элементы ковариационной матрицы Σ неотрицательны.

Метод Бенджамини-Иекутиели: восходящая процедура с уровнями значимости

$$\alpha_i = \alpha \cdot \frac{i}{m} \left(\sum_{j=1}^m \frac{1}{j} \right)^{-1}, \quad i = 1, \dots, m.$$

Метод контролирует FDR на уровне $\frac{m_0}{m} \alpha \leq \alpha$ для любых T_i .

При отсутствии информации о зависимости между статистиками T_i метод не улучшаем.

Модельный эксперимент: пусть имеется $m = 200$ выборок размера $n = 20$ из нормального распределения $N(a, 1)$, причем первые $m_0 = 150$ выборок сделаны из $N(0, 1)$, а последние 50 – из $N(1, 1)$.

Проверим гипотезы $H_i : a = 0$ против альтернатив $H'_i : a \neq 0$, $i = 1, \dots, m$, с помощью t-критерия Стьюдента, полагая $\alpha = 0.1$:

$$\text{если } \left| \sqrt{n} \frac{\bar{X} - a}{\sqrt{s^2}} \right| > t_{1-\alpha/2}, \text{ то отвергнуть } H_i,$$

где $t_{1-\alpha/2} - (1 - \alpha/2)$ -квантиль распределения Стьюдента $St(n - 1)$.

Сравнение методов

Матрицы ошибок модельного эксперимента:

Без поправки

	<i>True</i>	<i>False</i>
<i>Accepted</i>	142	0
<i>Rejected</i>	8	50

Бонферрони

	<i>True</i>	<i>False</i>
<i>Accepted</i>	150	27
<i>Rejected</i>	0	23

Шидак-Холм

	<i>True</i>	<i>False</i>
<i>Accepted</i>	150	24
<i>Rejected</i>	0	26

Бенджамини-Хохберг

	<i>True</i>	<i>False</i>
<i>Accepted</i>	148	4
<i>Rejected</i>	2	46

- 1 Если мы проверяем цепочку идентичных гипотез на выборках из одной генеральной совокупности, то при отклонении одной из гипотез в рамках процедуры множественной проверки стоит остановиться и отклонить все остальные. Например, в модельном эксперименте стоит отвергнуть гипотезу о том, что данные выбраны из стандартного нормального распределения.
- 2 Если мы последовательно проверяем гипотезы о различных наборах данных, то процедура множественной проверки гипотез также необходима, поскольку если поправки не делать, то вероятность того, что произойдет ошибка первого рода, будет расти с количеством проверяемых гипотез.

Finita!

Методы современной прикладной статистики

5. Корреляционный анализ

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Пусть значения признаков X и Y измерены на n объектах, т.е. имеется последовательность независимых одинаково распределенных векторов $(X_1, Y_1), \dots, (X_n, Y_n)$. Хотим измерить величину зависимости между признаками X и Y .

Но независимость признаков проверять чрезвычайно сложно (потому что независимость – континуальное свойство), поэтому вместо этого, как правило, проверяют их некоррелируемость.

Коэффициент корреляции


Напомним, коэффициент корреляции случайных величин X и Y равен

$$\rho(X, Y) = \frac{E[(X - EX)(Y - EY)]}{\sqrt{\text{var}X \cdot \text{var}Y}}.$$

Основное свойство: если коэффициент корреляции не равен нулю, то величины зависимы, обратное верно только в случае, если (X, Y) – гауссовский вектор.
Кроме того, $\rho(X, Y) \in [-1, 1]$.

Корреляция и причинность

Корреляция – статистическая взаимосвязь между случайными величинами. Не стоит думать, что она является достаточным условием причинно-следственной СВЯЗИ.




Коэффициент корреляции Пирсона

Пусть имеются две выборки одинакового размера $(X_1, \dots, X_n)$ и $(Y_1, \dots, Y_n)$. Оценкой $\rho(X, Y)$ служит выборочный **коэффициент корреляции Пирсона**

$$\hat{\rho} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{j=1}^n (Y_j - \bar{Y})^2}}.$$

Коэффициент корреляции Пирсона



Значения коэффициента Пирсона на разных данных.

Критерий Стьюдента

Если выборки $(X_1, \dots, X_n)$ и $(Y_1, \dots, Y_n)$ – нормальные (а точнее, $\{(X_i, Y_i)\}_{i=1}^n$ – выборка гауссовских векторов), то равенство нулю коэффициента корреляции $\rho(X_1, Y_1)$ эквивалентно независимости выборок.

При верности гипотезы $H_0 : \rho(X_1, Y_1) = 0$ выполнено $\frac{\hat{\rho}\sqrt{n-2}}{\sqrt{1-\hat{\rho}^2}} \sim St(n-2)$ (при $n > 10$). Отсюда получаем критерий проверки гипотезы H_0 против альтернативы $H_1 : \rho(X_1, Y_1) \neq 0$:

если $\frac{\hat{\rho}\sqrt{n-2}}{\sqrt{1-\hat{\rho}^2}} \notin (t_{\alpha/2}, t_{1-\alpha/2})$, то отвергнуть H_0 ,

где t_γ – γ -квантиль распределения Стьюдента с $n-2$ степенями свободы.

Коэффициент корреляции Пирсона

Недостатки коэффициента корреляции Пирсона:

- Крайне чувствителен к выбросам (см. квартет Энскомба);
- Служит эффективной мерой только для линейной зависимости;
- В случае отличия выборок от нормальных распределение статистики критерия при верности нулевой гипотезы может сильно отличаться от распределения Стьюдента.

Замечание. При использовании коэффициента Пирсона нормальное распределение данных является желательным, но не строго обязательным условием. Если данные хорошо сгруппированы, т.е. не имеют тяжелых хвостов и выбросов, то коэффициентом Пирсона можно пользоваться.

Коэффициент корреляции Спирмена

Если распределение выборки не является близким к нормальному, то лучше пользоваться ранговыми коэффициентами корреляции.

Напомним, ранг R_i наблюдения X_i – это его номер в вариационном ряду выборки $(X_1, \dots, X_n)$, т.е. $X_i = X_{(R_i)}$.

Пусть R_i – ранг X_i в выборке $(X_1, \dots, X_n)$, S_j – ранг Y_j в выборке $(Y_1, \dots, Y_n)$. Тогда **коэффициент корреляции Спирмена** определяется так

$$\rho_S = \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum_{i=1}^n (R_i - \bar{R})^2 \sum_{j=1}^n (S_j - \bar{S})^2}},$$


где $\bar{R} = \bar{S} = \frac{n+1}{2}$.

- ① Коэффициент корреляции Спирмена – мера монотонной корреляции между признаками X и Y . Он равен коэффициенту корреляции Пирсона между рангами наблюдений.
- ② $\rho_S = 1 - \frac{6}{n^3 - n} \sum_{i=1}^n (R_i - S_i)^2$.
- ③ При верной гипотезе H_0 о независимости признаков $E\rho_S = 0$, $\text{Var } \rho_S = \frac{1}{n-1}$ и $\sqrt{n-1}\rho_S \approx N(0, 1)$ ($n > 10$).
- ④ Более точное приближение: возьмем

$$\tilde{\rho}_S = \frac{1}{2}\rho_S \left(\sqrt{n-1} + \sqrt{\frac{n-2}{1-\rho_S^2}} \right),$$

тогда отвергаем H_0 , если $\tilde{\rho}_S \notin (z_{\alpha/2}, z_{1-\alpha/2})$, где $z_\gamma = (x_\gamma + y_\gamma)/2$, x_γ и y_γ – γ -квантили $N(0, 1)$ и $St(n-2)$ соответственно.

Коэффициент корреляции Спирмена



Значения коэффициента Спирмена на разных данных.

Коэффициент корреляции Кендалла

Будем говорить, что пары (X_i, Y_i) и (X_j, Y_j) согласованны, если

$$\operatorname{sgn}((X_i - X_j)(Y_i - Y_j)) = 1.$$

Обозначим S – число согласованных пар и R – число несогласованных, обозначим также


$$T = S - R = \sum_{i < j} \operatorname{sgn}((X_i - X_j)(Y_i - Y_j)).$$

Легко видеть, что $|T| \leq \frac{n(n-1)}{2}$. **Коэффициент корреляции Кендалла** определяется как

$$\tau = \frac{2}{n(n-1)} T.$$

Свойства τ Кендалла

- 1 $\tau = 1 - \frac{4}{n(n-1)}R$;
- 2 при верной гипотезе H_0 $\frac{\tau}{\sqrt{\text{Var } \tau}} \approx N(0, 1)$ (при $n > 10$),
где $\text{Var } \tau = \frac{2(2n+5)}{9n(n-1)}$;
- 3 $\rho(\rho_S, \tau) > 0.99$ при $n > 4$ и верности H_0 ; если их значения не близки к 1, то, как правило, $\rho_S \approx 1.5\tau$;
- 4 τ стоит использовать в случае многократного применения на одном наборе данных, потому что его проще пересчитывать при увеличении количества наблюдений;
- 5 и ρ_S , и τ являются устойчивыми к выбросам.



Значения τ Кендалла на различных данных.

Бывает так, что наблюдаемая линейная (монотонная) связь между признаками X и Y вызвана влиянием третьего признака Z , и тогда можно выяснить величину зависимости X и Y без учета влияния Z с помощью частной корреляции:

$$\rho_{XY|Z} = \frac{\rho_{XY} - \rho_{XZ}\rho_{YZ}}{\sqrt{(1 - \rho_{XZ}^2)(1 - \rho_{YZ}^2)}},$$

где ρ_{AB} – коэффициент корреляции Пирсона или Спирмена признаков A и B .

В случае, если мы хотим выяснить зависимость признаков X_i и X_j без влияния множества признаков $M \setminus \{X_i, X_j\}$, то пользуемся следующим методом:

$$\rho_{X_i X_j | M \setminus \{X_i, X_j\}} = -\frac{r_{ij}}{\sqrt{r_{ii} r_{jj}}},$$

где Σ – обратимая матрица выборочных корреляций множества признаков M , $R = \Sigma^{-1}$, $R = \|r_{ij}\|$.

Частная корреляция

Проверим гипотезу H_0 о некоррелированности (независимости) признаков X_1 и X_2 без влияния множества признаков $(X_3, \dots, X_M)$. Обозначим $\rho = \rho_{X_1 X_2 | X_3 \dots X_M}$. Тогда статистика

$$T = \frac{\rho \sqrt{n - M}}{\sqrt{1 - \rho^2}}$$

при верности H_0 приближаема распределением Стьюдента с $n - M$ степенями свободы.

Здесь n по-прежнему число объектов, т.е. число элементов в выборках $X_1, X_2, \dots$. Если основой для частного коэффициента корреляции выступает коэффициент Пирсона, то требуем, чтобы $(X_1, \dots, X_M) \sim N(\mu, S)$.

Множественная корреляция

Для того, чтобы оценить величину линейной (монотонной) связи между признаками X и (Y, Z) , пользуются множественным коэффициентом корреляции

$$\rho_{XYZ} = \frac{\rho_{XY}^2 + \rho_{XZ}^2 - 2\rho_{XY}\rho_{YZ}\rho_{XZ}}{1 - \rho_{YZ}^2},$$

где, как и ранее, ρ_{XY} – коэффициент корреляции Пирсона или Спирмена признаков X и Y .

Если имеем больше 2 дополнительных признаков, то используем коэффициент

$$\rho_{X,M} = c^T R c,$$

где M – множество дополнительных признаков, Σ – матрица их выборочных корреляций, $R = \Sigma^{-1}$, а c – вектор корреляций признака X с дополнительными.

Множественная корреляция

Для проверки гипотезы H_0 о некоррелированности (независимости) признака X с множеством дополнительных признаков M используется статистика

$$F = \frac{\rho_{X,M}^2}{1 - \rho_{X,M}^2} \cdot \frac{n - m}{m - 1},$$

где m – число дополнительных признаков. Данная статистика при верности H_0 хорошо приближается распределением Фишера с $m - 1$ и $n - m$ степенями свободы соответственно.

Коэффициент конкордации

Другим методом оценки зависимости нескольких выборок являются коэффициенты конкордации. В отличие от коэффициентов множественной корреляции, в данном методе оценивается не корреляция одного признака с остальными, а общая корреляция признаков между собой.

Определим ранговый коэффициент конкордации Кендалла как

$$W = \frac{12}{k^2(n^3 - n)} \sum_{i=1}^n \left(\sum_{j=1}^k R_{ij} - \frac{k(n+1)}{2} \right)^2,$$

где k – количество выборок, n – число наблюдений в них, R_{ij} – ранг i -того наблюдения в j -той выборке.

- ① Как и коэффициенты множественной корреляции, $W \in [0, 1]$.
- ② Пусть $\bar{\rho}_S$ – среднее арифметическое коэффициентов Спирмена по всем $\frac{k(k-1)}{2}$ парам выборок, тогда $W = \frac{k-1}{k}\bar{\rho}_S + \frac{1}{k}$.
- ③ При $n > 10$ и верной гипотезе о некоррелированности выборок распределение $k(n-1)W$ приближается хи-квадрат распределением с $n-1$ степенью свободы.

Таблицы сопряженности

Обсудим задачу выявления статистической зависимости между категориальными признаками. Пусть признак X принимает m значений, признак Y – k значений.

Образуем таблицу $\|\nu_{ij}\|$, где ν_{ij} – количество случаев, когда признак X принял i -тое значение, а признак Y – j -тое. Такие таблицы называются таблицами сопряженности.

Таблицы сопряженности

Для проверки гипотезы H_0 независимости признаков X и Y используется вариант критерия хи-квадрат. Определим $m_i = \sum_{j=1}^k \nu_{ij}$, $k_j = \sum_{i=1}^m \nu_{ij}$, а $n = \sum_{ij} \nu_{ij}$ – общее количество объектов. Рассмотрим статистику

$$\chi = n \sum_{i=1}^m \sum_{j=1}^k \frac{\left(\nu_{ij} - \frac{m_i k_j}{n} \right)^2}{m_i k_j} = n \left(\sum_{i,j} \frac{\nu_{ij}^2}{m_i k_j} - 1 \right).$$

При верной H_0 и при $\frac{m_i k_j}{n} \geq 5$ хотя бы для 80 процентов ячеек распределение статистики χ приближается распределением хи-квадрат с $(m-1)(k-1)$ степенями свободы.

С помощью предложенного критерия можно проверить гипотезу о независимости 2 произвольных выборок $(X_1, \dots, X_n)$ и $(Y_1, \dots, Y_n)$. Действительно, выберем 2 разбиения $\mathbb{R}$ $\{B_i\}_{i=1}^m$ и $\{C_j\}_{j=1}^k$ и положим $\nu_{ij} = \#\{u : X_u \in B_i, Y_u \in C_j\}$.

Также с помощью критерия можно проверить гипотезу о однородности k выборок $(X_1^1, \dots, X_{n_1}^1), \dots, (X_1^k, \dots, X_{n_k}^k)$ (т.е. гипотезу о том, что все k выборок одинаково распределены). Для этого рассмотрим $\{B_i\}_{i=1}^m$ – разбиение $\mathbb{R}$. Положим $\nu_{ij} = \#\{u : X_u^j \in B_i\}$, тогда малость статистики χ будет означать, что распределение членов выборок по множествам B_i не зависит от номера выборки, что и говорит об одинаковой распределенности данных выборок.

Таблицы сопряженности 2×2

Отдельный случай таблиц сопряженности – таблицы 2×2 , т.е. когда оба признака являются бинарными.

	$X = 0$	$X = 1$	Σ
$Y = 0$	a	b	$a + b$
$Y = 1$	c	d	$c + d$
Σ	$a + c$	$b + d$	n

Как и ранее, хотим проверить гипотезу о независимости признаков X и Y .

Коэффициент контингенции

Рассмотрим статистику

$$V = \frac{n(|ad - bc| - n/2)^2}{(a+b)(a+c)(b+d)(c+d)}$$

Если $V > u_{1-\alpha}$, где $u_{1-\alpha}$ – квантиль χ^2 -распределения с 1 степенью свободы, то отвергаем гипотезу о независимости признаков X и Y .

Точный критерий Фишера

Критерием контингенции можно пользоваться в случае, если $n \geq 40$ и $a, b, c, d \geq 5$. В остальных случаях следует применять точный критерий Фишера.

Пусть количество объектов по строкам и столбцам таблицы фиксировано. Тогда вероятность получить ровно такую таблицу 2×2 равна

$$P(X, Y) = \frac{C_{a+b}^a C_{c+d}^c}{C_n^{a+c}} = \frac{(a+b)!(a+c)!(b+d)!(c+d)!}{n!a!b!c!d!}.$$

Точный критерий Фишера

P-значение критерия определяется как сумма по всем возможным вариантам таблицы с такими же суммами по строкам и столбцам, имеющим вероятность не более чем $P(X, Y)$. В частности, если $ad < bc$, то p-значение ищется по формуле

$$p = \sum_{i=0}^a \frac{C_{a+b}^i C_{c+d}^{a+c-i}}{C_n^{a+c}}.$$

Парадокс хи-квадрат (Симпсона)

Эксперимент: пациенты принимают препарат или плацебо, и по окончании курса определяется, выздоровели они или нет. Есть ли связь между выздоровлением и приемом препарата?

Мужчины	Выздор.	Нет
Препарат	700	800
Плацебо	80	130

Женщины	Выздор.	Нет
Препарат	150	70
Плацебо	300	280

Для мужчин: $V = 5.45$, $p = 0.0195$.

Для женщин: $V = 17.55$, $p = 2.8 \cdot 10^{-5}$.

М+Ж	Выздор.	Нет
Препарат	850	870
Плацебо	380	410

Суммарно: $V = 0.37$, $p = 0.53$.

Парадокс хи-квадрат (Симпсона)

Причины несогласованности выводов – большие отличия в размерах групп пациентов, принимающих плацебо и препарат: основной вклад в выводы вносят женщины, принимавшие плацебо, и мужчины, принимавшие препарат.

Чтобы такого не происходило, плацебо и препарат должны (примерно) поровну распределяться по всем анализируемым подгруппам.

Finita!

Методы современной прикладной статистики

6. Одно- и двухвыборочные критерии.

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Виды задач:

- ① Одновыборочные: среднее (медиана) выборки равно заданному числу;
- ② Двухвыборочные:
 - Средние (медианы) выборок равны;
 - Выборки связанные;
 - Выборки независимые;
 - Дисперсии выборок равны;
 - Распределения выборок совпадают.

t-критерий Стьюдента

Предположим, что $(X_1, \dots, X_n)$ – выборка из $N(\mu, \sigma^2)$. Проверим гипотезу $H_0 : \mu = \mu_0$ против альтернативы $H_1 : \mu \neq \mu_0$. Если

$$\left| \sqrt{n} \frac{\bar{X} - \mu_0}{s} \right| > t_{1-\alpha/2},$$

то отвергаем H_0 на уровне значимости α . Здесь $t_{1-\alpha/2}$ – квантиль распределения Стьюдента с $n - 1$ степенью свободы, s – корень из выборочной дисперсии (ее несмещенного варианта).

Если мы знаем дисперсию выборки, то в критерии s заменяется на σ , квантиль – на квантиль $N(0, 1)$ того же уровня, а сам тест будет называться Z-тестом. Кроме того, если n достаточно велико, то критерием можно пользоваться даже в случае, если выборка не из нормального закона.

Двухвыборочный t-тест

Предположим, что $(X_1, \dots, X_n) \sim N(\mu_1, \sigma^2)$,
 $(Y_1, \dots, Y_m) \sim N(\mu_2, \sigma^2)$, т.е. дисперсии распределений
одинаковы, причем σ неизвестна, и что выборки
независимы. Проверим гипотезу $H_0 : \mu_1 = \mu_2$ против
альтернативы $H_1 : \mu_1 \neq \mu_2$. Если

$$\left| \sqrt{\frac{nm}{n+m}} \cdot \frac{\bar{X} - \bar{Y}}{S} \right| > t_{1-\alpha/2},$$

то отвергаем H_0 на уровне значимости α . Здесь $t_{1-\alpha/2}$ –
квантиль распределения Стьюдента с $n + m - 2$ степенью
свободы, а

$$S = \sqrt{\frac{(n-1)s_X^2 + (m-1)s_Y^2}{n+m-2}}.$$

F-критерий Фишера

Но как проверить, что дисперсии двух нормальных выборок равны? Для этого воспользуемся критерием Фишера.

Пусть $(X_1, \dots, X_n) \sim N(\mu_1, \sigma_1^2)$, $(Y_1, \dots, Y_m) \sim N(\mu_2, \sigma_2^2)$, выборки независимы. Проверим гипотезу $H_0 : \sigma_1 = \sigma_2$ против $H_1 : \sigma_1 \neq \sigma_2$. Если

$$\frac{s_X^2}{s_Y^2} \notin (u_{\alpha/2}, u_{1-\alpha/2}),$$

то отвергаем H_0 . Здесь u_γ – квантиль распределения Фишера с $n - 1$ и $m - 1$ степенями свободы.

Критерий Фишера по сравнению с t-критериями менее чувствителен к отклонению выборок от нормального распределения.

Критерий Аспина-Уэлча

Что делать, если выяснилось, что дисперсии выборок различны? Пусть, как и ранее, $(X_1, \dots, X_n) \sim N(\mu_1, \sigma_1^2)$, $(Y_1, \dots, Y_m) \sim N(\mu_2, \sigma_2^2)$, выборки независимы. Тогда при верной гипотезе $H_0 : \mu_1 = \mu_2$ статистика

$$\frac{\bar{X} - \bar{Y}}{\sqrt{s_X^2/n + s_Y^2/m}}$$

приблизительно распределена по закону Стьюдента с K степенями свободы, где

$$K = \left(\frac{s_X^2}{n} + \frac{s_Y^2}{m} \right)^2 \cdot \left(\frac{s_X^4}{n^2(n-1)} + \frac{s_Y^4}{m^2(m-1)} \right)^{-1} - 2.$$

А что делать, если выборки оказались зависимыми (парными)? В этом случае гипотезу $H_0 : \mu_1 = \mu_2$ можно проверить с помощью одновыборочного t-критерия.

Пусть $(X_1, \dots, X_n) \sim N(\mu_1, \sigma_1^2)$, $(Y_1, \dots, Y_n) \sim N(\mu_2, \sigma_2^2)$, выборки зависимы и одинакового размера. При верной гипотезе H_0 выполнено

$$\sqrt{n} \cdot \frac{\bar{X} - \bar{Y}}{S} \sim St(n-1),$$

где $D_i = X_i - Y_i$ и

$$S = \frac{1}{\sqrt{n-1}} \sqrt{\sum_{i=1}^n (D_i - \bar{D})^2}.$$

Одновыборочный критерий знаков

Обсудим теперь ситуацию, когда выборки не являются нормальными. Проще всего в таком случае перейти к непараметрическим тестам.


Имеем выборку $X = (X_1, \dots, X_n)$, где $X_i \neq m_0$. Хотим проверить гипотезу $H_0 : med(X) = m_0$ против $H_1 : med(X) \neq m_0$, где $med(X)$ – медиана распределения выборки X .

Используем для этого статистику $T(X) = \sum_i \mathbb{1}(X_i > m_0)$. Ясно, что при верной гипотезе H_0

$$T \sim Bin(n, 1/2).$$

Одновыборочный критерий знаков

Пример: (Shervin, 2004) 16 лабораторных мышей были помещены в двухкомнатные клетки, в одной из комнат висело зеркало. Измерялось доля времени, которое каждая мышь проводила в каждой из своих двух клеток.



Постановка задачи:

H_0 : мышам всё равно, висит в клетке зеркало или нет.


H_1 : у мышей есть какие-то предпочтения насчёт зеркала.

Одновыборочный критерий знаков

Будем действовать в рамках такой постановки: H_0 : медиана доли времени, проводимого в клетке с зеркалом, равна $1/2$, H_1 : медиана доли времени, проводимого в клетке с зеркалом, не равна $1/2$.

Редуцированные данные: 0 – мышь провела больше времени в комнате с зеркалом, 1 – в комнате без зеркала.


Статистика: T – число единиц в выборке.



13 из 16 мышей провели больше времени в комнате без зеркала.

Критерий знаков: $p = 0.0213$, 95% доверительный интервал для вероятности (что мышь проведёт больше времени в комнате без зеркала) – $[0.54, 0.96]$.

Одновыборочный критерий знаков



По этой гистограмме видим, что отклонение гипотезы об индифферентности мышей по отношению зеркалам, пожалуй, обосновано.

Двухвыборочный критерий знаков

Пусть зависимость между выборками $(X_1, \dots, X_n)$ и $(Y_1, \dots, Y_n)$ неизвестна, причем (желательно) $X_i \neq Y_i \forall i$.

Хотим проверить гипотезу об отсутствии эффекта

$H_0 : P(X > Y) = 1/2$ против альтернативы

$H_1 : P(X > Y) \neq 1/2$.

Для проверки гипотезы используем статистику

$T(X, Y) = \sum_i \mathbb{1}(X_i > Y_i)$. Ясно, что при верной H_0

$$T(X, Y) \sim \text{Bin}(n, 1/2).$$

Критерий резонно использовать, когда 1) точные разности $X_i - Y_i$ неизвестны, известны только их знаки; 2) разности небольшие по модулю, но систематические по знаку; 3) встречаются разности, очень большие по модулю.

Одновыборочный критерий знаковых рангов Уилкоксона

Более точным по сравнению с критерием знаков является критерий Уилкоксона, однако он требует, чтобы распределение выборки было симметричным.

Имеем выборку $X = (X_1, \dots, X_n)$ из симметричного (относительно m_0) распределения, где $X_i \neq m_0$. Хотим проверить гипотезу $H_0 : \text{med}(X) = m_0$ против $H_1 : \text{med}(X) \neq m_0$.

Рассмотрим статистику

$$W = \sum_i \text{rank}(|X_i - m_0|) \text{sign}(X_i - m_0).$$

Тогда при верной гипотезе H_0 статистика W имеет табличное распределение. При $n > 20$ (и верной H_0) можно использовать аппроксимацию

$$W \sim N(0, n(n+1)(2n+1)/6).$$

Двухвыборочный критерий знаковых рангов Уилкоксона

Пусть зависимость между выборками $(X_1, \dots, X_n)$ и $(Y_1, \dots, Y_n)$ неизвестна, причем (желательно) $X_i \neq Y_i \forall i$. Потребуем, чтобы распределение выборки величин $\{V_i\}_{i=1}^n$, где $V_i = X_i - Y_i$, было симметричным относительно некоторой константы.

Для проверки гипотезы $H_0 : \text{med}(X - Y) = 0$ против альтернативы $H_1 : \text{med}(X - Y) \neq 0$ (или > 0) рассмотрим статистику

$$W = \sum_i \text{rank}(|V_i|) \text{sign}(V_i).$$

Тогда при верной гипотезе H_0 статистика W имеет табличное распределение. При $n > 20$ (и верной H_0) можно использовать ту же аппроксимацию

$$W \sim N(0, n(n+1)(2n+1)/6).$$

Замечания о знаковых тестах

- 1) При $n < 20$ пользоваться нормальной аппроксимацией не рекомендуется, следует использовать табличные значения квантилей (или поправкой Имана, см. Лагутина).
- 2) Чтобы проверить симметричность распределения, можно нанести на график точки (ξ_i, η_i) , где $\xi_i = -V_{(i)} + \hat{\mu}$, $\eta_i = V_{(n-i+1)} - \hat{\mu}$, $i = 1, \dots, [n/2]$, $\hat{\mu}$ – выборочная медиана. Точки должны приближаться прямой $y = x$.
- 3) Если некоторые V_i (или другие разности) равны 0, то отбрасываем их и уменьшаем n .
- 4) Если среди $|V_i|$ есть совпадения, то следует использовать средние ранги (дисперсия нормального приближения тоже изменится, см. Лагутина).
- 5) Вместо статистики W в критерии знаковых рангов Уилкоксона может использоваться статистика $T = \sum_i \text{rank}(|V_i|) \mathbb{1}(V_i > 0)$ и при верной H_0 использовать аппроксимацию

$$T \sim N(n(n+1)/4, n(n+1)(2n+1)/24).$$

Критерий Манна-Уитни

Пусть $(X_1, \dots, X_n)$ и $(Y_1, \dots, Y_m)$ – 2 независимые выборки с функциями распределения F_X и F_Y соответственно, причем $F_X(x - \theta) = F_Y(x)$ (или $F_X(x) \leq F_Y(x) \forall x \in \mathbb{R}$). Проверим гипотезу об отсутствии сдвига $H_0 : \theta = 0$ против $H_1 : \theta \neq 0$.

Составим вариационный ряд объединенной совокупности $(X_1, \dots, X_n, Y_1, \dots, Y_m)$ и обозначим через R_i ранг наблюдения X_i в этом вариационном ряду. Определим статистику Манна-Уитни

$$W = \sum_{i=1}^n R_i.$$

Тогда при верной H_0 W имеет табличное распределение.

Критерий Манна-Уитни

1) При $n, m > 20$ и верности гипотезы H_0 можно пользоваться нормальной аппроксимацией

$$W \sim N \left(\frac{n(n+m+1)}{2}, \frac{nm(n+m+1)}{2} \right).$$

В остальных случаях стоит пользоваться табличными значениями квантилей критерия.


2) Если некоторые наблюдения совпадают (т.е. им присвоены средние ранги), то в аппроксимации следует заменить дисперсию на следующую:

$$\frac{mn(m+n+1)}{2} \left(1 - \frac{\sum_{i=1}^k t_i(t_i^2 - 1)}{(m+n)((m+n)^2 - 1)} \right),$$

где k – число групп совпавших величин и t_i – число величин в i -той группе.

Критерий Манна-Уитни

Пример. RER (респираторный обмен) – соотношение числа молекул CO_2 и O_2 в выдыхаемом воздухе. Является косвенным признаком того, из жиров или углеводов вырабатывается энергия в момент измерения. Изучалось влияние кофеина на мышечный метаболизм. В эксперименте принимало участие 18 испытуемых, респираторный обмен которых измерялся в процессе физических упражнений. За час до этого 9 из них получили таблетку кофеина, оставшиеся 9 – плацебо. Повлиял ли кофеин на значение показателя респираторного обмена?



H_0 : среднее значение RER не отличается в двух группах.

H_1 : среднее значение RER отличается в двух группах.

Критерий Манна-Уитни(-Уилкоксона)

Ранг	Наблюдение	Номер наблюдения	Наблюдение	Ранг
16.5	105	1	96	9
18	119	2	99	13
14	100	3	94	5.5
11	97	4	89	3
9	96	5	96	9
15	101	6	93	4
5.5	94	7	88	1.5
7	95	8	105	16.5
12	98	9	88	1.5

Статистика W – сумма рангов одной из групп (т.к. $n = m = 9$, то неважно, какой).

$p = 0.0521$, 95% доверительный интервал для медианной разности – $[-0.00005, 1.2]$.

Критерий Зигеля-Тьюки

С помощью ранговых методов возможно даже проверить гипотезу о равенстве дисперсий двух выборок. Пусть $(X_1, \dots, X_n)$ и $(Y_1, \dots, Y_m)$ – две независимые выборки. Проверим гипотезу $H_0 : \text{Var } X_1 = \text{Var } X_2$ против альтернативы $H_1 : \text{Var } X_1 \neq \text{Var } X_2$.

Пусть $N = n + m$, $n < m$. Рассмотрим вариационный ряд объединенной совокупности $\{Z_i\}_{i=1}^N = \{X_j\}_{j=1}^n \cup \{Y_k\}_{k=1}^m$ (при этом лучше сместить их так, чтобы $\bar{X} = \bar{Y}$), причем ранги наблюдениям будем присваивать следующим образом:

$$\begin{array}{ccccccc} \widetilde{Z_{(i)}} & Z_{(1)} & Z_{(2)} & Z_{(3)} & \dots & Z_{(N-2)} & Z_{(N-1)} & Z_{(N)} \\ \text{rank}(Z_i) & 1 & 4 & 5 & & 6 & 3 & 2 \end{array}$$

Критерий Зигеля-Тьюки

При верности H_0 статистика

$$R = \sum_{j=1}^n \widetilde{rank}(X_j)$$

имеет табличное распределение. Критерий должен быть двусторонним.

При $m \geq n > 20$ и верности гипотезы H_0 можно пользоваться нормальной аппроксимацией

$$R \sim N \left(\frac{n(n+m+1)}{2}, \frac{nm(n+m+1)}{2} \right).$$


В остальных случаях стоит пользоваться табличными значениями квантилей критерия (которые совпадают с квантилями критерия Манна-Уитни).

Пусть имеются две (не обязательно независимые) выборки $(X_1, \dots, X_n)$ и $(Y_1, \dots, Y_m)$ с функциями распределения F и G соответственно. Допустим, мы хотим проверить гипотезу $H_0 : F = G \left(\frac{x-a}{\sigma} \right)$.

General QQ-plot – это график, на который нанесены точки $\left(\tilde{F}_n^{-1} \left(\frac{j}{m+1} \right), Y_{(j)} \right), j = 1, \dots, m$, и $\left(X_{(i)}, \tilde{G}_m^{-1} \left(\frac{i}{n+1} \right) \right), i = 1, \dots, n$. Если точки лежат примерно на одной прямой, то гипотеза H_0 близка к верности.

$\tilde{F}_n$ (как и $\tilde{G}_m$) – кусочно-линейная функция, соединяющая точки $\left(X_{(i)}, \frac{i}{n+1} \right), i = 1, \dots, n$. Она, как и стандартная эмпирическая функция распределения, является оценкой для F .

General QQ-plot



Обсудим теперь критерии проверки двух выборок на однородность. Для решения этой задачи можно адаптировать критерии согласия, например, критерий Колмогорова.

Пусть $(X_1, \dots, X_n)$ и $(Y_1, \dots, Y_m)$ – две независимые выборки с непрерывными ф.р. F и G соответственно, а $\hat{F}_n(x)$ и $\hat{G}_m(x)$ – эмпирические функции распределения этих выборок. Определим

$$D_{n,m} = \sup_x |\hat{F}_n(x) - \hat{G}_m(x)|,$$

тогда при верной гипотезе $H_0 : F = G$ статистика $\sqrt{\frac{nm}{n+m}} D_{n,m}$ имеет табличное распределение. При $n, m \geq 20$ оно приближается распределением Колмогорова с ф.р. $F_K(z) = \sum_{k \in \mathbb{Z}} (-1)^k e^{-2k^2 z^2}$.

ω^2 -критерий Розенблатта

Также для проверки гипотезы $H_0 : F = G$ можно воспользоваться модификацией критерия Крамера-фон Мизеса. Определим

$$\hat{H}_{m,n}(x) = \frac{n}{n+m} \hat{F}_n(x) + \frac{m}{n+m} \hat{G}_m(x),$$

эмпирическую функцию распределения совокупности $(X_1, \dots, X_n, Y_1, \dots, Y_m)$, и статистику критерия

$$\omega_{m,n}^2 = \int_{\mathbb{R}} (\hat{F}_n(x) - \hat{G}_m(x))^2 d\hat{H}_{m,n}(x).$$

Тогда при верной гипотезе H_0 и достаточно больших n, m статистика $Z := \frac{nm}{n+m} \omega_{m,n}^2$ приближается распределением A_1 , приведем таблицу квантилей этого распределения:

α	0.5	0.85	0.9	0.95	0.975	0.99
y_α	0.12	0.28	0.35	0.46	0.58	0.74

ω^2 -критерий Розенблатта

1) Статистику критерия Розенблатта можно представить в явной форме

$$Z = \frac{1}{n+m} \left[\frac{1}{6} + \frac{1}{m} \sum_{i=1}^n (R_i - i)^2 + \frac{1}{n} \sum_{j=1}^m (S_j - j)^2 \right] - \frac{2nm}{3(n+m)},$$
 где R_i и S_j – ранги наблюдений $X_{(i)}$ и $Y_{(j)}$ в объединенной совокупности.

2) Известно, что $\mathbb{E}Z = \frac{1}{6} \left(1 + \frac{1}{n+m} \right),$
 $\text{Var } Z = \frac{1}{45} \left(1 + \frac{1}{n+m} \right) \left(1 + \frac{1}{n+m} - \frac{3}{4} \frac{n+m}{nm} \right).$

Тогда статистика

$$Z^* = \frac{Z - \mathbb{E}Z}{\sqrt{45\text{Var } Z}} + \frac{1}{6}$$

хорошо приближается распределением A_1 уже при $n, m \geq 7.$

Общий критерий Андерсона-Дарлинга

Проблема критерия Розенблатта в том, что он не реализован в Python. Зато реализован критерий Андерсона-Дарлинга для нескольких ($k \geq 2$) выборок.

Пусть $(X_1^{(1)}, \dots, X_{n_1}^{(1)}), \dots, (X_1^{(k)}, \dots, X_{n_k}^{(k)})$ – k независимых выборок с функциями распределений $F_1, \dots, F_k$ соответственно. Пусть $\hat{F}_1, \dots, \hat{F}_k$ – эмпирические функции распределения этих выборок и $\hat{H}_N(x)$, $N = \sum_i n_i$, – эмпирическая функция распределения общей совокупности наблюдений.

Общий критерий Андерсона-Дарлингга

Тогда статистика

$$\Omega^2 = \sum_{i=1}^k n_i \int_{\mathbb{R}} \frac{(\hat{F}_i(x) - \hat{H}_N(x))^2}{\hat{H}_N(x)(1 - \hat{H}_N(x))} d\hat{H}_N(x)$$

имеет табличное распределение при верной гипотезе $H_0 : F_1 = \dots = F_k$.

Finita!

Методы современной прикладной статистики

7. Дисперсионный анализ.

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Однофакторный дисперсионный анализ

Пусть имеются наблюдения признака X на $N = \sum_i n_i$ объектах.

Хотим проверить, зависят ли значения признака X (а точнее, его среднее) от некого фактора A , принимающего значения (уровни) $(A_1, \dots, A_k)$.

Пусть при $A = A_j$ значения признака X заданы выборкой $\{X_{ij}\}_{i=1}^{n_j}$, $1 \leq j \leq k$.

Однофакторный дисперсионный анализ

Линейная (т.н. однофакторная) модель:

$$X_{ij} = \mu + \alpha_j + \varepsilon_{ij},$$

$$i = 1, \dots, n_j, j = 1, \dots, k.$$

μ – глобальное среднее признака X ;

α_j – отклонение от μ , вызванное влиянием j -того уровня фактора A ;

ε_{ij} – н.о.р. случайные ошибки.

Т.е. средние значения X во всех выборках одинаковы тогда и только тогда, когда $\alpha_1 = \dots = \alpha_k$.

Однофакторный дисперсионный анализ

Идея: рассмотрим две компоненты разброса значений X_{ij} относительно глобального среднего признака X :

$$X_{ij} - \bar{X} = (X_{ij} - \bar{X}_j) + (\bar{X}_j - \bar{X}),$$

где $\bar{X}_j$ – среднее по j -той выборке.

Тогда (аналогично bias-variance trade-off) имеем

$$\sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X})^2 = \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_j)^2 + \sum_{j=1}^k n_j (\bar{X}_j - \bar{X})^2.$$

Если средние между группами значительно отличаются, преобладает вторая компонента, если же они примерно одинаковы – первая.

Для проверки гипотезы $H_0 : \alpha_1 = \dots = \alpha_k$ против альтернативы $H_1 : H_0$ неверна используется статистика

$$F = \frac{\sum_{j=1}^k n_j (\bar{X}_j - \bar{X})^2}{\sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_j)^2} \cdot \frac{N - k}{k - 1}.$$

В случае выполнения гипотезы H_0 и предположений метода

$$F \sim F(k - 1, N - k).$$

Критерий выбирается правосторонним.



Предположения метода:

- 1 выборочные распределения средних значений признака во всех группах нормальны;
- 2 дисперсия значений признака во всех выборках одинакова;
- 3 наблюдения независимы.

- Первое предположение считается выполненным, если распределение признака во всех группах нормально, или если объёмы выборок примерно одинаковы и $N - k - 1 \geq 20$, или если объёмы выборок большие.
- Второе предположение считается выполненным, если отношение наибольшей выборочной дисперсии к наименьшей не превосходит 10.
- При $n_1 = \dots = n_k$ метод устойчив к нарушению первых двух предположений.
- Если объёмы выборок различаются, нарушение предположения о равенстве дисперсий может привести к росту вероятности ошибки первого рода.
- Выбросы могут оказывать существенное влияние на результат.

Критерий Фишера

Пример: исследуется эффективность четырёх жаропонижающих средств, в составе которых один и тот же активный ингредиент присутствует в разных дозировках. Для каждой из четырёх групп из 15 морских свинок известно изменение температуры после введения жаропонижающего. Есть ли различия в действии препаратов?



Критерий Фишера проверки гипотезы H_0 об отсутствии различий в действии препаратов дает $p\text{-value} = 5.43 \times 10^{-14}$.

Критерий Краскела-Уоллиса

Пусть $\{X_{ij}\}$, $1 \leq i \leq n_j$, $1 \leq j \leq k$ – независимые выборки с ф.р. $F_j(x) = F(x - \alpha_j)$. Проверим гипотезу об отсутствии сдвига $H_0 : \alpha_1 = \dots = \alpha_k$ против альтернативы $H_1 : H_0$ неверна.

Пусть $R_{ij} = R(X_{ij})$ – ранг наблюдения X_{ij} в общей совокупности, $\bar{R}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} R_{ij}$, $\bar{R} = \frac{1}{N} \sum_{i,j} R_{ij} = \frac{N+1}{2}$.

Статистика критерия Краскела-Уоллиса

$$W = (N - 1) \frac{\sum_{j=1}^k n_j (\bar{R}_j - \bar{R})^2}{\sum_{j=1}^k \sum_{i=1}^{n_j} (R_{ij} - \bar{R})^2}$$

имеет табличное распределение (при верной H_0), которое при $n_j > 5 \forall j$ приближается распределением χ_{k-1}^2 .

Критерий Джонкхиера

Данный критерий используется для проверки гипотезы $H_0 : \alpha_1 = \dots = \alpha_k$ против альтернативы $H'_1 : \alpha_1 \leq \dots \leq \alpha_k$.
Статистика критерия

$$S = \sum_{j=1}^k \sum_{i=1}^{n_j} a_{ij},$$

где a_{ij} – количество наблюдений из первых $j - 1$ выборок, меньших X_{ij} . При верности гипотезы H_0 имеет табличное распределение.

На альтернативе H'_1 критерий Джонкхиера имеет большую мощность, чем критерий Краскела-Уоллиса, чем и объясняется его использование.

Кроме того, оба этих критерия являются устойчивыми к наличию выбросов в данных.

Виды эффектов модели

Прежде чем переходить к вопросу, средние (медианы) в каких группах отличаются (вне зависимости от того, отклонили мы гипотезу однородности или нет), следует понять, чем вызваны различия между выборками.

Наиболее популярными являются 2 модели: *модель со случайным эффектом*

$$X_{ij} = a_j + \varepsilon_{ij},$$

где $\{a_j\}$ – н.о.р. случайные величины (как правило, нормальные) со средним μ и дисперсией σ_a^2 , независимые с $\{\varepsilon_{ij}\}$, и *модель с фиксированным эффектом*

$$X_{ij} = \mu + a_j + \varepsilon_{ij},$$

где a_j – неслучайны.

Модель со случайным эффектом

Свойства модели:

- 1) Характеристика, определяющая разбиение на группы, не представляет непосредственного интереса.
- 2) Группы случайно выбраны из множества возможных.
- 3) Если между группами есть неоднородность, ожидается, что она сохранится при повторе эксперимента, но соотношения между средними могут измениться.

Пример. Наблюдаем вкусовые качества персиков с 10 различных деревьев; планируется сравнить различия во вкусовых качествах персиков с разных деревьев с различиями у персиков с одного (“лучшего”) дерева. Если последние больше (что эквивалентно принятию гипотезы однородности, см. слайд 5), то бессмысленно выбирать для размножения дерево с лучшей средней оценкой.

Модель с фиксированным эффектом

Проверять гипотезы об однородности пар выборок внутри совокупности в модели со случайным эффектом бессмысленно, потому что различия будут вызваны случаем. Однако в модели с фиксированным эффектом такая задача интересна.

Свойства модели:

- 1) Разбиение на группы определено до получения данных.
- 2) При повторе эксперимента ожидается, что соотношения между средними групп сохраняются.
- 3) Если между средними есть различия, на следующем этапе анализируется, какие именно группы различаются.

Различия эффектов

ANOVA: переменные

Факторы

FIXED



Исследователь:
Сравню-ка я
эффективность
анальгина и лекарства
СтопБобо, под контролем
плацебо!



Как бы ни было поставлено это
исследование, группы будут три, и
именно эти, **других нет**.

RANDOM



Исследователь:
Изучу-ка я,
различается ли
масса лягушек в
разных прудах!



Количество прудов в исследовании
может быть разным, **существуют
неисследованные** пруды.

Модель с фиксированным эффектом

Если используется модель с фиксированным эффектом, то в случае отклонения гипотезы однородности проводятся дополнительные проверки с целью уточнения характера различий. Проверка может быть:

- запланированной, когда группы для дальнейшего сравнения отобраны до начала сбора данных.
- незапланированной, когда группы для сравнения выбираются по результатам первичного анализа данных.

Для запланированного попарного сравнения групп можно просто использовать подходящий двухвыборочный критерий. Для незапланированного сравнения всё сложнее, потому что номера выбранных для сравнения групп по сути являются случайными величинами.

Пусть $\{X_{ij}\}_{i=1}^{n_j} \sim N(\mu + \alpha_j, \sigma^2)$, $1 \leq j \leq k$. Критерий проверяет гипотезу $H_0 : \sum_j c_j \alpha_j = 0$, где $\sum_j c_j = 0$, а средние выборок α_j упорядочены по возрастанию выборочных средних $\bar{X}_j$. Введем статистику

$$S = \frac{(\sum_{j=1}^k c_j \bar{X}_j)^2}{(k-1)S_{in}^2(\sum_{j=1}^k c_j^2/n_j)},$$

где $S_{in}^2 = \frac{1}{N-k} \sum_{j=1}^k \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_j)^2$. При верной H_0 $S \sim F(k-1, N-k)$, используется правосторонний критерий.

Критерий Шеффе является более грубым, чем критерий LSD Фишера, однако более устойчив к нарушению предположения о равенстве дисперсий.

Пусть $\{X_{ij}\}_{i=1}^{n_j} \sim N(\mu + \alpha_j, \sigma^2)$, $1 \leq j \leq k$. Критерий проверяет гипотезы $H_{0j} : \alpha_j = \alpha_{j+1}$, где α_j снова упорядочены по возрастанию выборочных средних $\bar{X}_j$. Рассмотрим

$$LSD_j = t_{1-\alpha} \sqrt{\frac{n_j + n_{j+1}}{n_j n_{j+1}}} \sqrt{\frac{(n_j - 1)S_j^2 + (n_{j+1} - 1)S_{j+1}^2}{n_j + n_{j+1} - 2}}.$$

где t_γ – γ -квантиль распределения Стьюдента с $n_j + n_{j+1} - 2$ степенями свободы, S_j^2 и S_{j+1}^2 – выборочные дисперсии j -той и $(j + 1)$ -ой выборки соответственно.

Если $\bar{X}_{j+1} - \bar{X}_j > LSD_j$, то частная нулевая гипотеза $H_{0j} : \alpha_j = \alpha_{j+1}$ отклоняется в пользу двусторонней альтернативы. LSD можно использовать только в случае отклонения общей гипотезы однородности, и при этом стоит применять множественную проверку гипотез.

Непараметрический аналог критерия HSD Тьюки. Пусть в каждой из k выборок n наблюдений. Пусть R_{ij} – ранг наблюдения X_{ij} в общей совокупности, $\bar{R}_j = \frac{1}{n} \sum_i R_{ij}$ – средний ранг по j -той выборке.


Введем

$$CD = q'_{1-\alpha} \frac{k+1}{6n},$$

где q'_γ – γ -квантиль из распределения студентизированного размаха с k степенями свободы.

Проверим серию гипотез $H_{0j} : \alpha_j = \alpha_{j+1}$, где α_j упорядочены по возрастанию $\bar{R}_j$. Если $\bar{R}_{j+1} - \bar{R}_j > CD$, то отвергаем гипотезу H_{0j} . Для проверки H_{0j} следует пользоваться методами множественной проверки гипотез.

Действие жаропонижающих на морских свинок:



LSD Фишера

T_1 vs. T_3	0.9983
T_3 vs. T_2	3.5×10^{-8}
T_2 vs. T_4	0.2949

Критерий Неманьи

T_1 vs. T_3	0.9999
T_3 vs. T_2	1.8×10^{-4}
T_2 vs. T_4	0.7942

Критерий Бартлетта

Пусть $\{X_{ij}\}_{i=1}^{n_j} \sim N(\mu_j, \sigma_j^2)$, $1 \leq j \leq k$. Критерий проверяет гипотезу $H_0 : \sigma_1^2 = \dots = \sigma_k^2$ против альтернативы $H_1 : H_0$ неверна. Статистика критерия

$$B = \frac{1}{C} \left((N - k) \ln \left(\frac{1}{N - k} \sum_{j=1}^k (n_j - 1) s_j^2 \right) - \sum_{j=1}^k (n_j - 1) \ln s_j^2 \right),$$

где $C = 1 + \frac{1}{3k+1} \left(\sum_j \frac{1}{n_j-1} - \frac{1}{N-k} \right)$. При $n_j > 3 \forall j$ и верной H_0 распределение статистики B приближается распределением χ_{k-1}^2 .

Критерий крайне чувствителен к отклонению от нормальности распределений выборок (в отличие от критерия Левина). Если есть малейшие сомнения в нормальности данных, то критерием пользоваться не стоит.

Критерий Флайнера-Киллиана

Пусть $\{X_{ij}\}_{i=1}^{n_j}$, $1 \leq j \leq k$ – независимые выборки с ф.р.
 $F_j(x) = F(\mu_j + \sigma_j x)$. Проверим гипотезу $H_0 : \sigma_1 = \dots = \sigma_k$
против $H_1 : H_0$ неверна.

Определим R_{ij} – ранг $|X_{ij} - \hat{\mu}_j|$ в общей совокупности, где
 $\hat{\mu}_j$ – выборочная медиана j -той выборки,

$$a_{ij} = \Phi^{-1} \left(\frac{1}{2} + \frac{R_{ij}}{2(N+1)} \right), \quad \bar{a}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} a_{ij}, \quad \bar{a} = \frac{1}{N} \sum_{j=1}^k \sum_{i=1}^{n_j} a_{ij} \quad \text{и}$$

$$V^2 = \frac{1}{N-1} \sum_{j=1}^k \sum_{i=1}^{n_j} (a_{ij} - \bar{a})^2,$$

где $\Phi(x)$ – ф.р. $N(0, 1)$. Тогда при верной H_0 статистика

$$\chi = \frac{1}{V^2} \sum_{j=1}^k n_j (\bar{a}_j - \bar{a})^2$$

приближается распределением χ_{k-1}^2 .

Двухфакторный дисперсионный анализ

Пусть имеются наблюдения признака X на N объектах. Хотим проверить, зависят ли значения признака X (а точнее, его среднее или медиана) от факторов A и B , принимающих значения $(A_1, \dots, A_k)$ и $(B_1, \dots, B_m)$ соответственно.

Пусть при $A = A_j$ и $B = B_l$ значения признака X заданы выборкой $\{X_{ijl}\}_{i=1}^{n_{jl}}, 1 \leq j \leq k, 1 \leq l \leq m$.

Поскольку двухфакторный анализ для выборок разного размера довольно сложен, будет считать, что $n_{11} = \dots = n_{km} = n$. Часто будем полагать, что $n = 1$.

Двухфакторный дисперсионный анализ

Линейная двухфакторная модель:

$$X_{ijl} = \mu + \alpha_j + \beta_l + \gamma_{jl} + \varepsilon_{ijl},$$

$$i = 1, \dots, n; j = 1, \dots, k; l = 1, \dots, m.$$

μ – глобальное среднее признака X ;

α_j – воздействие j -того уровня фактора A ;

β_l – воздействие l -того уровня фактора B ;

γ_{jl} – дополнительное воздействие комбинации уровней j и l факторов A и B соответственно;

ε_{ijl} – н.о.р. случайные ошибки.

Двухфакторный дисперсионный анализ

Если $\gamma_{jl} = 0 \forall j, l$, то решить задачу дисперсионного анализа гораздо проще (ведь задачу однофакторного анализа для связанных выборок можно рассматривать как задачу двухфакторного анализа, см. далее). Иначе приходится рассматривать следующие гипотезы:



$H_0^1 : \alpha_j = 0 \forall j$ (т.е. фактор A не влияет на значения признака X) против $H_1^1 : H_0^1$ неверна,

$H_0^2 : \beta_l = 0 \forall l$ (т.е. фактор B не влияет на значения признака X) против $H_1^2 : H_0^2$ неверна,

$H_0^{12} : \gamma_{jl} = 0 \forall j, l$ (т.е. между факторами A и B нет взаимодействия) против $H_1^{12} : H_0^{12}$ неверна.

Двухфакторный дисперсионный анализ

Пример: X – успешность решения кейса командой (в баллах от 0 до 10), f_1 – размер команды (1 – маленькая, 2 – средняя, 3 – большая), f_2 – наличие назначенного лидера (1 – нет, 2 – есть).



Нормальный двухфакторный дисперсионный анализ

Пусть $X_{ijl} \sim N(\mu_{jl}, \sigma^2)$, $\mu_{jl} = \mu + \alpha_j + \beta_l + \gamma_{jl}$. Обозначим

$\bar{X}_{jl}$ – выборочное среднее по ячейке;

$\bar{X}_{j*}$ – выборочное среднее по значению фактора $A = A_j$;

$\bar{X}_{*l}$ – выборочное среднее по значению фактора $B = B_l$;

$\bar{X}$ – выборочное среднее по всей таблице.

Внутрифакторные дисперсии:

$$S_1^2 = \frac{nm}{(k-1)} \sum_{j=1}^k (\bar{X}_{j*} - \bar{X})^2, \quad S_2^2 = \frac{nk}{(m-1)} \sum_{l=1}^m (\bar{X}_{*l} - \bar{X})^2,$$

$$S_{12}^2 = \frac{n}{(k-1)(m-1)} \sum_{j,l} (\bar{X}_{jl} - \bar{X}_{j*} - \bar{X}_{*l} + \bar{X})^2,$$

$$S_{int}^2 = \frac{1}{km(n-1)} \sum_{i=1}^n \sum_{j,l} (X_{ijl} - \bar{X}_{jl})^2.$$

Нормальный двухфакторный дисперсионный анализ

Проверка значимости факторов и взаимодействия между ними:

1) при $n > 1$

$$F_1 = \frac{S_1^2}{S_{int}^2} \sim F(k-1, km(n-1)) \text{ при верной } H_0^1;$$

$$F_2 = \frac{S_2^2}{S_{int}^2} \sim F(m-1, km(n-1)) \text{ при верной } H_0^2;$$

$$F_{12} = \frac{S_{12}^2}{S_{int}^2} \sim F((k-1)(m-1), km(n-1)) \text{ при верной } H_0^{12};$$

2) при $n = 1$ (предполагаем, что гипотеза H_0^{12} верна)

$$F_1 = \frac{S_1^2}{S_{12}^2} \sim F(k-1, (k-1)(m-1)) \text{ при верной } H_0^1;$$



$$F_2 = \frac{S_2^2}{S_{12}^2} \sim F(m-1, (k-1)(m-1)) \text{ при верной } H_0^2.$$

Изучалось воздействие марихуаны на скорость реакции. В качестве испытуемых были выбраны по 12 человек из каждой категории:

- никогда не пробовали марихуану;
- иногда употребляют марихуану;
- регулярно употребляют марихуану.

Испытуемые были разделены на две равные группы; половине из них дали выкурить две сигареты с марихуаной, вторая половина выкурила две обычные сигареты с запахом и вкусом марихуаны. Сразу после этого все испытуемые прошли тест на скорость реакции.

Требуется оценить влияние марихуаны на скорость реакции, учитывая фактор предыдущего опыта употребления.



H_0^1 : средняя скорость реакции одинакова при употреблении марихуаны, и сигарет;

H_0^2 : средняя скорость реакции не зависит от предыдущего опыта употребления марихуаны;


H_0^{12} : отсутствует межфакторное взаимодействие между употребляемым веществом и предыдущим опытом употребления марихуаны.

Source	F	p-value
Group	17.58	0.0002
Past use	2.02	0.15
Interaction	2.02	0.15

Вывод: гипотеза о том, что предыдущий опыт употребления не влияет на скорость реакции, не отклоняется – значит, данные по группам можно объединить.

Для объединенных данных:

- 1) p-value однофакторного дисперсионного анализа – 0.00036;
- 2) p-value критерия Манна-Уитни – 0.00059;
- 3) p-value двухвыборочного t-критерия – 0.00018.



Пусть $\{X_{ij}\}$, $i = 1, \dots, n$, $j = 1, \dots, k$, – наблюдения признака X на n объектах при разных значениях фактора A . Рассмотрим линейную модель

$$X_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij},$$

где μ – глобальное среднее значение признака X ,

α_i – отклонение от μ , вызванное влиянием особенностей i -го объекта,

β_j – отклонение от $\mu + \alpha_i$, вызванное влиянием j -го уровня фактора A ,

ε_{ij} – случайные н.о.р. ошибки.

Хотим понять, влияет ли фактор A на значения признака X на разных объектах.

Для этого проверим гипотезу $H_0 : \beta_1 = \dots = \beta_k$ против альтернативы $H_1 : H_0$ неверна. Рассмотрим статистику

$$F = \frac{n(n-1) \sum_j (\bar{X}_j - \bar{X})^2}{\sum_i \sum_j (X_{ij} - \bar{X})^2 - k \sum_i (\bar{X}_i - \bar{X})^2},$$

где $\bar{X}_i = \frac{1}{k} \sum_j X_{ij}$, $\bar{X}_j = \frac{1}{n} \sum_i X_{ij}$, $\bar{X} = \frac{1}{nk} \sum_{i,j} X_{ij}$.

В случае выполнения предположений метода и верности гипотезы H_0 распределение статистики критерия аппроксимируется распределением $F(k-1, (n-1)(k-1))$.

Предположения метода:

- 1) $\{\varepsilon_{ij}\}$ имеют нормальное распределение с нулевым средним и независимы в совокупности;
- 2) свойство сферичности: $\forall j_1 \neq j_2 \forall i$ выполнено $\text{Var}(X_{ij_1} - X_{ij_2}) = \sigma^2$.

Предположение сферичности на практике нарушается наиболее часто, причём это может привести к росту вероятности ошибки первого рода. Проверить гипотезу сферичности можно с помощью критерия Маухли. Если она отвергается, то следует изменить число степеней свободы распределения Фишера в критерии.

Критерий Фридмана

По-прежнему рассматриваем линейную модель и гипотезу $H_0 : \beta_1 = \dots = \beta_k$ против альтернативы $H_1 : H_0$ неверна. Нормальность выборок не предполагается.

Обозначим R_{ij} – ранг j -того элемента в i -той строке, $R_j = \sum_i R_{ij}$. Распределение статистики

$$F = \frac{12}{kn(n+1)} \sum_{j=1}^k R_j^2 - 3k(n+1)$$

при верной H_0 и при $n > 15, k > 20$ приближается распределением χ^2_{k-1} . Более точная аппроксимация

$$\frac{(n-1)F}{n(k-1) - F} \sim F(n-1, (k-1)(n-1)).$$

Критерий проверяет гипотезу $H_0 : \beta_1 = \dots = \beta_k$ против альтернативы $H'_1 : \beta_1 \leq \dots \leq \beta_k$. Статистика критерия

$$L = \sum_{j=1}^k jR_j.$$

В случае выполнения гипотезы H_0 при $k > 15$ и $n > 10$ можно пользоваться аппроксимацией

$$L^* = \frac{L - \frac{1}{4}nk(k+1)^2}{\sqrt{\frac{1}{144(k-1)}n(k^3 - k)^2}} \sim N(0, 1).$$

- 1) В случае невыполнения предположений критерия Фишера стоит пользоваться ранговыми критериями Фридмана и Пейджа.
- 2) Все три критерия подходят и для проверки гипотез об отсутствии эффекта в рамках двухфакторного анализа с независимыми выборками в случае, если между факторами нет взаимодействия.
- 3) На альтернативе H'_1 критерий Пейджа мощнее критерия Фридмана.

Finita!

Методы современной прикладной статистики

8. Регрессионный анализ.

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Постановка задачи

Пусть есть n объектов, на которых мы наблюдаем значения признаков (объясняющих переменных, предикторов) $X_1, \dots, X_k$ и отклика (зависимой переменной, таргета) Y .

Хотим найти такую функцию $f(x_1, \dots, x_k)$, что на всех объектах $Y \approx f(X_1, \dots, X_k)$. По теореме о наилучшем квадратичном прогнозе,

$$\arg \min_f \mathbb{E}(Y - f(X_1, \dots, X_k))^2 = \mathbb{E}(Y|X_1, \dots, X_k),$$

однако на практике найти оценку $\mathbb{E}(Y|X_1, \dots, X_k)$ по n наблюдениям отклика Y и признаков $X_1, \dots, X_k$ оказывается не так просто.

Поэтому рассмотрим сначала модель линейной регрессии

$$\mathbb{E}(Y|X_1, \dots, X_k) = \beta_0 + \sum_j \beta_j X_j.$$

Обозначим $Y = (y_1, \dots, y_n)^T$, $X = \|x_{ij}\|$, $1 \leq i \leq n$,
 $0 \leq j \leq k$, – наблюдения отклика Y и признаков
 $(X_0, X_1, \dots, X_k)$ соответственно на n объектах, причем
 $X_0 \equiv 1$, т.е. $x_{i0} = 1$.

Тогда регрессионная задача переформулируется так: найти
по Y и X оценку вектора параметров $\beta = (\beta_0, \dots, \beta_k)^T$ в
модели

$$Y = X\beta + \varepsilon,$$

где ε – вектор ошибок с нулевым средним.

Метод наименьших квадратов

Наиболее популярный метод решения регрессионной задачи - это метод наименьших квадратов, в котором оценка есть

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n \left(y_i - \sum_{j=0}^k \beta_j x_{ij} \right)^2.$$

Из курса статистики мы знаем, что $\hat{\beta} = (X^T X)^{-1} X^T Y$, а оценка вектора откликов Y равна $\hat{Y} = X \hat{\beta}$.

Предположения Гаусса-Маркова

- 1) Линейность отклика: $Y = X\beta + \varepsilon$.
- 2) Случайность выборки: наблюдения $(x_{i1}, \dots, x_{ik}, y_i)$ есть независимые реализации вектора $(X_1, \dots, X_k, Y)$.
- 3) Полнота ранга: $\text{rank}(X) = k + 1$.
- 4) Случайность ошибки: $\mathbb{E}\varepsilon = 0$.
- 5) Гомоскедастичность: $\text{Var } \varepsilon = \sigma^2 I_n$, где $I_n = \text{diag}\{1, \dots, 1\}$.

Теорема Гаусса-Маркова.

В предположениях 1)-5) оценка $\hat{\beta}$ является несмещенной и имеет наименьшую дисперсию среди несмещенных линейных по Y оценок параметра β .

Кроме того, в рамках предположений Гаусса-Маркова $\hat{\beta}$ – состоятельная оценка вектора β и $\text{Var} \hat{\beta} = \sigma^2 (X^T X)^{-1}$.

Категориальные признаки

Понятно, что если признак является бинарным, т.е. принимает только 2 значения, то эти значения можно кодировать 0 и 1. Что делать, если признак принимает m значений?

Пусть y – средний уровень зарплаты служащих, а x – тип должности (рабочий, инженер или управляющий). Закодируем рабочих как 1, инженеров – 2, управляющих – 3, и построим регрессию $y = \beta_0 + \beta_1 x$. Тогда для указанных должностей получаем следующие модели:

$$y_{\text{раб.}} = \beta_0 + \beta_1, \quad y_{\text{инж.}} = \beta_0 + 2\beta_1, \quad y_{\text{упр.}} = \beta_0 + 3\beta_1.$$

Т.е., согласно нашей модели, разница в средней зарплате рабочего и инженера в точности равна разнице между зарплатами инженера и управляющего.

Категориальные признаки

Верный способ использования категориальных признаков в регрессии – введение бинарных фиктивных переменных (dummy variables). Пусть признак x_j принимает m различных значений, тогда для его кодирования необходима $m - 1$ фиктивная переменная.

Способы кодирования:

	Dummy		Deviation	
Должность	x_1	x_2	x_1	x_2
Рабочий	0	0	1	0
Инженер	1	0	0	1
Управляющий	0	1	-1	-1

Категориальные признаки

Рассмотрим новую модель с учетом таких кодировок категориального признака

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2.$$

- При dummy-кодировании коэффициенты β_1 , β_2 оценивают среднюю разницу в уровнях зарплат инженера и управляющего с рабочим.
- При deviation-кодировании коэффициенты β_1 , β_2 оценивают среднюю разницу в уровнях зарплат рабочего и инженера со средним по всем должностям.

Другие способы кодирования

Пусть кодируется категориальный признак X , принимающий значения $\{x_i\}$.

- С помощью среднего значения другой, непрерывной переменной при фиксированном значении X ;
- С помощью замены x_i на количество раз, когда признак X принял значение x_i ;
- Хэширование.

- 1 Все ли признаки значимы (т.е. проверить гипотезу $H_0 : \beta_j = 0$)?
- 2 Как предсказать значение отклика на новом объекте x_{n+1} (т.е. найти доверительный интервал для отклика)?
- 3 Как проверить адекватность (качество) полученной модели?

Далее будем работать в рамках гауссовской линейной модели, т.е. считаем, что $\varepsilon \sim N(0, \sigma^2 I_n)$. В этом случае $\hat{\beta}$ – оптимальная оценка вектора параметров β .

Значимость признака

Проверим гипотезу $H_0 : \beta_j = 0$ о значимости j -того признака. Мы знаем, что $\hat{\beta} \sim N(\beta, \sigma^2(X^T X)^{-1})$, отсюда $\forall c \in \mathbb{R}^k \quad c^T(\hat{\beta} - \beta) \sim N(0, \sigma^2 c^T(X^T X)^{-1}c)$.

Оценкой для параметра σ^2 в линейной модели служит

$$\hat{\sigma}^2 = \frac{1}{n - k - 1} \|Y - X\hat{\beta}\|^2 = \frac{1}{n - k - 1} \sum_{i=1}^k \left(y_i - \sum_{j=0}^k x_{ij} \hat{\beta}_j \right)^2.$$

Используя её, получаем

$$\frac{c^T(\hat{\beta} - \beta)}{\hat{\sigma} \sqrt{c^T(X^T X)^{-1}c}} \sim St(n - k - 1). \quad (1)$$

Значимость признака

Для проверки гипотезы $H_0 : \beta_j = 0$ выберем c_j – вектор с единицей на j -том месте и остальными нулями, тогда

$$\frac{\hat{\beta}_j - \beta_j}{\hat{\sigma} \sqrt{a_{jj}}} \sim St(n - k - 1),$$

где $a_{jj} = ((X^T X)^{-1})_{jj}$, откуда получаем доверительный интервал для j -того коэффициента линейной регрессии:

$$\left(\hat{\beta}_j - t_{1-\frac{\alpha}{2}} \hat{\sigma} \sqrt{a_{jj}}; \hat{\beta}_j + t_{1-\frac{\alpha}{2}} \hat{\sigma} \sqrt{a_{jj}} \right)$$

где $t_{1-\alpha/2} - (1 - \alpha/2)$ -квантиль распределения $St(n - k - 1)$. Таким образом, если 0 не попадает в этот доверительный интервал, то отвергаем гипотезу H_0 и признаем признак значимым для нашей модели.

Коэффициент детерминации

Прежде чем проверять гипотезу о значимости нескольких признаков, введем необходимые обозначения:

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2 \text{ (Total Sum of Squares);}$$

$$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \text{ (Explained Sum of Squares);}$$

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \text{ (Residual Sum of Squares);}$$

В случае, если мы пользуемся методом наименьших квадратов и один из признаков – константа, верна формула

$$TSS = ESS + RSS.$$

Кроме того, видим, что $\hat{\sigma}^2 = RSS / (n - k - 1)$.

Коэффициент детерминации

Коэффициент детерминации:

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}.$$

По сути, R^2 – это квадрат коэффициента множественной корреляции (Пирсона) Y с X .

Логично, что чем меньше RSS , точнее, отношение $\frac{RSS}{TSS}$, тем лучше мы оценили Y и тем лучше качество нашей модели. Однако не всё так просто, как мы увидим далее.

Кроме того, $R^2 = 1 - \frac{RSS}{TSS}$ может оказаться отрицательным в случае модели без константного признака, что говорит о крайней неадекватности модели, потому что даже константа ($= \bar{y}$) приближает данные лучше.

Значимость нескольких признаков

Проверим гипотезу $H_0 : \beta_1 = \dots = \beta_m = 0$, $m \leq k$, о значимости нескольких признаков. Пусть RSS_{H_0} построена по модели, в которой отсутствуют признаки $X_1, \dots, X_m$, т.е. $\hat{Y} = X_{H_0}(X_{H_0}^T X_{H_0})^{-1} X_{H_0}^T Y$, где X_{H_0} – матрица признаков, откуда выбросили столбцы с номерами $1, \dots, m$. Если H_0 верна, то

$$\frac{RSS_{H_0} - RSS}{RSS} \cdot \frac{n - k - 1}{m} \sim F_{m, n-k-1}.$$

Этот критерий называется критерием Фишера. Для проверки гипотезы $H_0 : \beta_1 = \dots = \beta_k = 0$ (т.е. что все неконстантные признаки не влияют на модель) можно использовать такой критерий: при верной H_0

$$\frac{R^2}{1-R^2} \cdot \frac{n-k-1}{k} \sim F_{k, n-k-1}.$$

Связь между критериями Фишера и Стьюдента

1) Если $m = 1$, критерий Фишера эквивалентен критерию Стьюдента для двусторонней альтернативы.

2) Иногда критерий Фишера отвергает гипотезу о незначимости признаков $\mathbf{X} = (X_1, \dots, X_m)$, а критерий Стьюдента не признаёт значимым ни один из них.

Возможные объяснения:

- отдельные признаки из $\mathbf{X}$ недостаточно хорошо объясняют Y , но совокупный эффект значим;
- незначимость признаков $\mathbf{X}$ – результат множественной проверки гипотез.

Связь между критериями Фишера и Стьюдента

Иногда критерий Фишера не отвергает гипотезу о незначимости признаков X , а критерий Стьюдента признаёт значимыми некоторые из них. Возможные объяснения:

- незначимые признаки в X маскируют влияние значимых;
- признаки в X мультиколлинеарны.

Для веса ребёнка при рождении имеется следующая модель:

$$weight = \beta_0 + \beta_1cigs + \beta_2parity + \beta_3inc + \beta_4med + \beta_5fed + \varepsilon,$$

где *cigs* – среднее число сигарет, выкуриваемых матерью за один день беременности, *parity* – номер ребёнка у матери, *inc* – среднемесячный доход семьи, *med* – длительность в годах получения образования матерью, *fed* – отцом.

Данные имеются для 1191 детей.

- 1) Зависит ли вес ребёнка при рождении от уровня образования родителей? Для проверки этого рассмотрим $H_0 : \beta_4 = \beta_5 = 0$ против альтернативы $H_1 : H_0$ неверна. В такой постановке задачи с помощью критерия Фишера получаем $p\text{-value} = 0.242$, т.е. два этих признака можно отбросить.

- 2) Имеет ли вообще смысл модель веса ребёнка при рождении, рассмотренная выше? Рассмотрим $H_0 : \beta_1 = \dots = \beta_5 = 0$ против альтернативы $H_1 : H_0$ неверна. В этом случае $p\text{-значение}$ критерия Фишера равно $6.033 \cdot 10^{-9}$, т.е. модель следует признать значимой.

ДИ для отклика на новом объекте

Значение отклика на новом наблюдении x_0 мы можем предсказать как $y(x_0) = x_0^T \beta + \varepsilon(x_0)$. Предположим, что $\varepsilon(x_0) \sim N(0, \sigma^2)$ – так же, как и предыдущие ошибки в нашей модели.


Для получения доверительного интервала для отклика $y(x_0)$ воспользуемся формулой (1) и подставим x_0 вместо вектора s . Получаем следующий доверительный интервал

$$\left(x_0^T \hat{\beta} - t_{1-\frac{\alpha}{2}} \hat{\sigma} \sqrt{D+1}; x_0^T \hat{\beta} + t_{1-\frac{\alpha}{2}} \hat{\sigma} \sqrt{D+1} \right),$$

где, как и ранее, $t_{1-\alpha/2}$ – $(1 - \alpha/2)$ -квантиль распределения $St(n - k - 1)$, а $D = x_0^T (X^T X)^{-1} x_0$.

Доверительная лента

Если рассматривать полученные доверительные границы как функцию от x_0 , то можно получить т.н. доверительную ленту для отклика.



Адекватность модели и feature selection

Видим (по графику, по критериям, о которых позже, по R^2), что модель плохо описывает данные. Возможные варианты действий:

- 1) Замена переменной: попробовать к признакам из матрицы X или к Y применить какие-нибудь функции. Возможные варианты функций: $\ln x$, $e^{\alpha x}$, x^α и так далее. При этом стоит проверить, что новые остатки ε_i останутся после замены переменной независимыми и, желательно, нормально распределенными.
- 2) Добавление переменных вида X_i^k . Может привести к переобучению, т.е. нестабильности решения на новых объектах.
- 3) Удаление переменных с помощью различных процедур.

Информационные критерии

Прежде чем переходить к методам добавления и удаления признаков, обсудим методы оценки качества модели.

Критерий Акаике

$$AIC = 2k + n \left(\ln \frac{RSS}{n} + 1 \right).$$

Критерий Шварца

$$BIC = 2k \ln n + n \left(\ln \frac{RSS}{n} + 1 \right).$$

Выбирается та модель, у которой AIC или BIC меньше. В случае, если сравниваем модели с разным количеством признаков, предпочтительно использовать BIC .

Информационные критерии не являются статистическими критериями проверки гипотез, это просто числовые показатели качества модели.

Сравнение невложенных моделей

Пусть имеются 2 невложенные модели, скажем,

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon, \quad (1)$$

$$y = \gamma_0 + \gamma_1 \ln x_1 + \gamma_2 \ln x_2 + \varepsilon, \quad (2)$$

Как определить, какая из них лучше? Пусть $\hat{y}$ – оценка отклика по первой модели, $\tilde{y}$ – по второй. Подставим эти оценки как признаки в “чужие” модели:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 \tilde{y} + \varepsilon,$$

$$y = \gamma_0 + \gamma_1 \ln x_1 + \gamma_2 \ln x_2 + \gamma_3 \hat{y} + \varepsilon,$$

Критерий Давидсона-Маккиннона

При помощи критерия Стьюдента проверим гипотезы

$$H_{01} : \beta_3 = 0, \quad H_{11} : \beta_3 \neq 0,$$

$$H_{02} : \gamma_3 = 0, \quad H_{12} : \gamma_3 \neq 0.$$

	H_{01} принята	H_{01} отвергнута
H_{02} принята	Обе модели хороши	Модель (2) значимо лучше
H_{02} отвергнута	Модель (1) значимо лучше	Обе модели плохи

Неправильное определение модели

1) **Недоопределение:** если зависимая переменная определяется моделью

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_{j-1} x_{j-1} + \beta_j x_j + \beta_{j+1} x_{j+1} + \dots + \beta_k x_k + \varepsilon,$$

а вместо этого используется модель

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_{j-1} x_{j-1} + \beta_{j+1} x_{j+1} + \dots + \beta_k x_k + \varepsilon,$$

то МНК-оценки $\hat{\beta}_0, \dots, \hat{\beta}_{j-1}, \hat{\beta}_{j+1}, \dots, \hat{\beta}_k$ являются смещёнными и несостоятельными оценками $\beta_0, \dots, \beta_{j-1}, \beta_{j+1}, \dots, \beta_k$ соответственно.

2) **Переопределение:** если признак x_j не влияет на y , т.е. $\beta_j = 0$, то МНК-оценка $\hat{\beta}$ остаётся несмещённой состоятельной оценкой вектора параметров β , но дисперсия её возрастает.

Критерий RESET Рэмси

Критерий в рамках линейной гауссовской модели проверяет предположение $\mathbb{E}\varepsilon_i = 0 \forall i$. Это условие эквивалентно тому, что оценка отклика является несмещенной. С помощью этого критерия можно выявить:

- 1) наличие пропущенных, значимых для регрессии факторов;
- 2) неправильную функциональную форму регрессии;
- 3) наличие корреляции между факторами (мультиколлинеарность).

Правда, после отклонения гипотезы критерия нельзя с уверенностью сказать, что именно мы выявили.

Критерий RESET Рэмси

Пусть $\hat{y}_i$ – оценки отклика в рассматриваемой модели линейной регрессии методом наименьших квадратов.

Рассмотрим вспомогательную модель

$$y_i = \sum_{j=0}^k \beta_j x_{ij} + \gamma (\hat{y}_i)^2 + \eta_i, \quad i = 1, \dots, n,$$

где η_i – ошибки с нулевым матожиданием, и проверим гипотезу $H_0 : \gamma = 0$. Вычислим оценки откликов $\tilde{y}_i$ по новой модели (с помощью МНК) и посчитаем по ним RSS_{new} . Тогда при верной гипотезе H_0

$$F = \frac{RSS - RSS_{new}}{RSS/(n - k - 1)} \approx F_{1, n-k-1}.$$

Отбор признаков (feature selection)

Для отбора признаков в линейной модели можно использовать следующие методы:

- 1) приведенный коэффициент детерминации;
- 2) одномерный отбор признаков;
- 3) пошаговая регрессия;
- 4) методы понижения размерности (например, метод главных компонент);
- 5) отбор на основе важности признаков (например, ExtraTreesClassifier, RandomForestClassifier, Boruta);
- 6) новые методы типа SHAP.

Приведенный коэффициент детерминации

1) Стандартный коэффициент детерминации R^2 всегда увеличивается при добавлении новых признаков в модель, поэтому для отбора признаков его использовать нельзя.

Для сравнения моделей, содержащих разное число признаков, можно использовать приведённый коэффициент детерминации:

$$R_a^2 = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}.$$

Одномерный отбор признаков

Метод заключается в том, чтобы найти признаки, имеющие наиболее выраженную взаимосвязь с откликом, с помощью статистических тестов.

В частности, можно воспользоваться коэффициентами корреляции, критерием Стьюдента для проверки значимости линейной модели. В случае, если отклик и/или признак дискретны/категориальны, можно воспользоваться критерием хи-квадрат для таблиц сопряженности.

С помощью функции `SelectKBest` (или руками) отбирается m признаков, имеющие наибольшую взаимосвязь с откликом (т.е. наименьшие p -значения в задаче проверки гипотез об отсутствии влияния).

Пошаговая регрессия

Выберем 2 пороговых уровня $p_{in} < p_{out}$, например, $p_{in} = 0.05$ и $p_{out} = 0.1$.

Шаг 0. Настраиваем модель только с константой, а также все модели с одной переменной. Выбирается модель с наименьшим p-value (пусть это модель с признаком X_{i_1}), например, по критерию Фишера (см. слайд 14). Если это p-value меньше p_{in} , то включаем признак в модель.

Шаг 2N-1. Если есть признак, при добавлении которого критерий Фишера дает p-value $< p_{in}$, то добавляем в модель признак, на котором достигается наименьшее p-value.

Шаг 2N. Если есть признак, при удалении которого критерий Фишера дает p-value $> p_{out}$, то удаляем признак, на котором достигается наибольшее p-value.

Недостатки метода:

- 1) метод пошаговой регрессии не позволяет выводить оптимальные уравнения регрессии с точки зрения получения наибольшего коэффициента детерминации R^2 для данного количества признаков;
- 2) p-value зависят от результатов предшествующих тестов, что усложняет их интерпретацию;
- 3) метод несовместим с процедурами множественной проверки гипотез;
- 4) тесты являются смещенными, так как проводятся на одних и тех же данных.

Однако метод дает хорошие результаты в ситуации, когда количество признаков достаточно велико.

Finita!

Методы современной прикладной статистики

9. Регрессионный анализ II.

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Проверка предположений Гаусса-Маркова

Напомним, мы предполагали, что в рамках гауссовской линейной модели выполнены предположения

- 1 $\mathbb{E} \varepsilon = 0$,
- 2 $\text{Var} \varepsilon = \sigma^2 I_n$,
- 3 $\{\varepsilon_i\}_{i=1}^n$ независимы в совокупности,
- 4 ε_i имеют нормальное распределение,
- 5 $X^T X$ обратима.

Если хотя бы одно из этих предположений нарушено, то оценки коэффициентов регрессии $\{\beta_j\}$ могут оказаться смещенными и неустойчивыми, а доверительные интервалы для откликов на новых объектах будут иметь заниженные уровни доверия. Обсудим методы проверки этих предположений.

Предположение $\mathbb{E}\varepsilon = 0$ относится к выбору оптимальной модели в линейной регрессии, что мы обсуждали ранее.

Проверить предсказательную силу модели можно с помощью LOO-метода (leave-one-out): пусть $\hat{Y}_i$ – предсказание отклика на объекте x_i , полученное с помощью обучения модели по всем объектам, кроме x_i . Качество оценивается с помощью функции

$$LOO = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2.$$

Но при большом количестве объектов LOO работает крайне медленно, в этом случае используется метод k-fold CV.

Кросс-валидация по блокам отличается от LOO тем, что мы разбиваем данные на k блоков (обычно k от 3 до 5) и получаем предсказание на объектах i -того блока с помощью модели, обученной по всем блокам, кроме i -того.

Проверка гомоскедастичности

Перейдем к проверке **условия гомоскедастичности** $\text{Var } \varepsilon = \sigma^2 I_n$. Если условие не выполнено, то такая ситуация называется **гетероскедастичностью**.

Оценивать ошибки ε_i мы будем с помощью **остатков** $e_i = Y_i - \hat{Y}_i$, где $\hat{Y}_i = (X(X^T X)^{-1} X^T Y)_i$ – i -тая координата оценки отклика.

Заметим, что если $\mathbb{E}\varepsilon = 0$, то

$$\mathbb{E}e = \mathbb{E}(Y - \hat{Y}) = \mathbb{E}(Y - X\hat{\beta}) = X\beta - X\beta = 0.$$

Далее, можем представить вектор остатков в виде $e = (I - H)Y$, где $H = X(X^T X)^{-1}X^T$. Поскольку $H^2 = H$ и $H^T = H$, то

$$\text{Var}[e] = \text{Var}[(I - H)Y] = (I - H)\text{Var}[Y](I - H)^T = \sigma^2(I - H).$$

Т.е. $\text{Var } e_i = \sigma^2(1 - h_{ii})$, где $H = \|h_{ij}\|$. Чтобы унифицировать все остатки по распределению, перейдем к нормированным остаткам $\tilde{e}_i = \frac{e_i}{\sqrt{\text{Var } e_i}} = \frac{e_i}{\sigma\sqrt{1 - h_{ii}}}$.

Но σ^2 неизвестно, поэтому заменим σ^2 на её оценку $\frac{1}{n-k}RSS$, тем самым переходя к рассмотрению **студентизированных остатков**

$$d_i = \frac{e_i}{\sqrt{\frac{RSS}{n-k}} \sqrt{1 - h_{ii}}}.$$

Заметим, что $\sum_i h_{ii} = \text{tr}(H) = k$, действительно,

$$\text{tr}(H) = \text{tr}(X(X^T X)^{-1} X^T) = \text{tr}((X^T X)^{-1} X^T X) = \text{tr}(I_k) = k.$$


Поэтому если k много меньше n , то можно считать $h_{ii} \approx 0$ и перейти к рассмотрению **стандартизированных остатков**

$$\tilde{\varepsilon}_i = \frac{e_i}{\sqrt{\frac{RSS}{n-k}}}.$$


Хотя стандартизированные остатки являются зависимыми, при больших n их поведение схоже с поведением вектора независимых $N(0, 1)$ случайных величин (при условии, что $\varepsilon \sim N(0, \sigma^2 I_n)$).

Визуальный анализ остатков

Строится график $\tilde{\varepsilon}_i$ от $\hat{y}_i$, x_{ij} при фиксированном j или просто от i .




Визуальный анализ остатков




Возможно, в данных имеются выбросы.

Визуальный анализ остатков




В данных имеется тренд (не учтен признак времени).

Визуальный анализ остатков



Гетероскедастичность данных.

Визуальный анализ остатков



В пространство признаков стоит добавить признак $(x_j)^2$.

Критерий Голдфелда-Квандта

Итак, проверим гипотезу гомоскедастичности

$H_0 : \varepsilon \sim N(0, \sigma^2 I_n)$ (но критерий устойчив и к небольшому отклонению от нормальности распределения ε).

Упорядочим наблюдения по возможному возрастанию дисперсий ошибок и отбросим r центральных наблюдений. Построим 2 регрессионных модели: по первым $(n - r)/2$ наблюдениям и по последним $(n - r)/2$, вычислим по ним RSS_1 и RSS_2 соответственно. Если H_0 верна, то

$$F = \frac{RSS_2}{RSS_1} \sim F_{\frac{n-r}{2}-k, \frac{n-r}{2}-k}$$

Гипотезу H_0 следует отвергать, если $F > u_{1-\alpha}$, где $u_{1-\alpha}$ – квантиль данного распределения Фишера.

Рассмотрим вспомогательную модель

$$e_i^2 = \alpha_0 + \sum_{j=1}^k \alpha_j x_{ij} + \sum_{j=1}^k \gamma_j x_{ij}^2 + \nu_i,$$

где e_i – обычные остатки в линейной регрессии. Проверим гипотезу $H_0 : \alpha_j = \gamma_j = 0 \ \forall j \neq 0$.

Обозначим через $\tilde{R}^2$ коэффициент детерминации вспомогательной модели. При верной гипотезе H_0 и достаточно большом n

$$n\tilde{R}^2 \approx \chi_{2k}^2.$$

Если во введенной модели сразу полагать $\gamma_j = 0 \ \forall j$, то мы получим **критерий Бройша-Пагана**, и тогда при верной гипотезе $H'_0 : \alpha_j = 0 \ \forall j \neq 0$ выполнено $n\tilde{R}^2 \approx \chi_k^2$.

Гетероскедастичность

Гетероскедастичность может быть следствием недоопределенности модели, тогда следует её доопределить с помощью рассмотренных методов.

От гетероскедастичности можно избавиться с помощью взвешенного МНК, давая разным объектам подходящие веса, если соотношения между дисперсиями известны заранее (или они явно определяются по графикам остатков).

Последствия гетероскедастичности:

- 1) нарушаются предположения критериев Стьюдента и Фишера и методов построения доверительных интервалов для σ^2 , β и отклика на новом объекте (независимо от объёма выборки);
- 2) однако МНК-оценка β остается несмещённой и состоятельной.

Устойчивая оценка дисперсии Уайта

Если от гетероскедастичности избавиться не удаётся, для оценки значимости признаков (и не только) можно использовать критерии, основанные на оценке HCE (White heteroscedasticity-consistent estimator, HC0) матрицы ковариаций вектора $\hat{\beta}$

$$\hat{\Omega} = (X^T X)^{-1} (X^T \text{diag}\{e_1^2, \dots, e_n^2\} X) (X^T X)^{-1}.$$

Если $\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, \Omega)$ при $n \rightarrow +\infty$, то $n\hat{\Omega}$ является состоятельной оценкой Ω .

Также вместо e_i^2 в выражение для оценки $\hat{\Omega}$ можно подставлять $\frac{ne_i^2}{n-k}$, $\frac{e_i^2}{1-h_{ii}}$ или $\frac{e_i^2}{(1-h_{ii})^2}$ (поправки Маккиннона-Уайта), что будет увеличивать мощность наших критериев.

Проверка остатков на нормальность и независимость

Проверка остатков на нормальность, как правило, проводится не очень точными методами, такими, как визуальный анализ гистограммы и QQ-plot, и критериями типа Харке-Бера, потому что стандартизированные остатки зависимы.

Проверить остатки на независимость, по сути, невозможно. Если вдруг кажется, что остатки образуют временной ряд, то можно проверить остатки на наличие тренда (критериями случайности или просто построив линейную регрессию по времени) и автокоррелированность (например, критериями Дарбина–Уотсона или Льюнга–Бокса), что мы обсудим в лекции про временные ряды.

Преобразование Бокса-Кокса

Если всё же $\{\tilde{\varepsilon}_i\}$ не очень похожи на выборку из $N(0, 1)$, то стоит задуматься о применении преобразования Бокса-Кокса к откликам модели.

Пусть все $Y_i > 0$, иначе возьмем $Y'_i = Y_i - \min_i Y_i$.
Применим к вектору Y преобразование

$$V(y, \lambda) = \begin{cases} \frac{y^\lambda - 1}{\lambda(\dot{y})^{\lambda-1}}, & \lambda \neq 0, \\ \dot{y} \ln y, & \lambda = 0, \end{cases}$$

где $\dot{y} = (\prod_{i=1}^n Y_i)^{1/n}$ – среднее геометрическое отклика.

Преобразование Бокса-Кокса

Как выбирать оптимальное значение λ ?

- 1) с помощью критериев проверки нормальности;
- 2) методом максимального правдоподобия для нормального распределения;
- 3) методом Бокса-Кокса: пусть $\lambda \in (-a, a)$, для каждого λ из этого интервала (по сетке) строим регрессию отклика $V(Y, \lambda)$ по признакам X и получаем $RSS(\lambda)$, по нему строим график $R^2(\lambda)$ и по графику выбираем оптимальное λ . Если значение $R^2(\lambda)$ не сильно отличается от $R^2(1)$, то выполнять преобразование не имеет смысла.

Мультиколлинеарность

Ситуация, когда матрица $X^T X$ является плохо обратимой, называется мультиколлинеарностью. Эта ситуация возникает, когда столбцы матрицы X близки к линейно зависимым, т.е. есть сильная совместная корреляция между признаками.

Критерием плохой обратимости, или плохой обусловленности, матрицы является ситуация, когда $\lambda_{max}/\lambda_{min} > 100$, где λ_{max} и λ_{min} – максимальное и минимальное собственные значения матрицы $X^T X$ соответственно.

Мультиколлинеарность чревата тем, что оценки откликов на новых объектах будут крайне неустойчивыми, поскольку $\hat{\beta} \sim N(\beta, \sigma^2(X^T X)^{-1})$ и у некоторых коэффициентов будет очень большая дисперсия.

Методы борьбы с мультиколлинеарностью:

- ① Нормировка данных и их преобразование (например, методом Грама-Шмидта);
- ② Variance inflation factor (VIF);
- ③ Методы понижения размерности (например, метод главных компонент);
- ④ Регуляризация.

Бывает так, что вектор-признак X_j имеет небольшой разброс значений и потому будет очень похож на константный признак X_0 . В этой ситуации стоит перейти к стандартизированным данным

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{\sqrt{s_j^2}}$$

и центрировать отклик.

В принципе, общая рекомендация при работе с регрессионными задачами – стандартизация признаков и отклика, что помогает избежать, в частности, вычислительных ошибок и неадекватных предсказаний модели.

Метод ортогонализации Грама-Шмидта

Пусть X представима в виде $X = GR$, где R – верхнетреугольная матрица размера $k \times k$, а G – ортогональная матрица размера $n \times k$, т.е. $G^T G = I_k$.
Таких разложений бесконечно много. Имея одно из них, можем найти псевдообратную матрицу в виде

$$X^+ = (R^T G^T G R)^{-1} R^T G^T = R^{-1} (R^{-1})^T R^T G^T = R^{-1} G^T.$$

Обозначим $\bar{v} = v / \|v\|$ для любого вектора v .

Процесс ортогонализации Грама-Шмидта строит ортогональные векторы $(g_1, \dots, g_k)$, линейная оболочка которых совпадает с $(X_1, \dots, X_k)$.

Метод ортогонализации Грама-Шмидта

Процесс устроен следующим образом:

$$g_1 = X_1,$$

$$g_2 = X_2 - (\bar{g}_1, X_2)\bar{g}_1$$

...

$$g_k = X_k - (\bar{g}_1, X_k)\bar{g}_1 - \dots - (\bar{g}_{k-1}, X_k)\bar{g}_{k-1}.$$

Тогда матрица $G = (\bar{g}_1, \dots, \bar{g}_k)$ является ортонормированной, а R – верхнетреугольная матрица, для $i \leq j$

$$r_{ij} = \begin{cases} \bar{g}_i^T X_j, & i < j, \\ \|g_j\|, & i = j. \end{cases}$$

Существует также модификация алгоритма (см. лекции Воронцова по линейной регрессии), которая позволяет не только избавиться от мультиколлинеарности, но и произвести отбор признаков.

Variance Inflation Factor

Рассмотрим величину

$$VIF_j = \frac{1}{1 - R_j^2},$$

где R_j^2 – коэффициент детерминации модели

$$X_j = c_0 + c_1 X_1 + \dots + c_{j-1} X_{j-1} + c_{j+1} X_{j+1} + \dots + c_k X_k.$$

Логично, что если R_j^2 высок, то признак X_j хорошо объясняется остальными признаками, и его надо удалить. Рекомендуется удалять признак, если $VIF_j > 5$.

Всё это время мы искали оценки коэффициентов регрессии как точку минимума функционала

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n \left(y_i - \sum_{j=0}^k \beta_j x_{ij} \right)^2 = \arg \min_{\beta} \|Y - X\beta\|^2.$$

Решение $\hat{\beta} = (X^T X)^{-1} X^T Y$ может иметь очень большую норму из-за плохой обусловленности матрицы $X^T X$, поэтому для большей устойчивости решения можно штрафовать большие значения нормы вектора весов β .
Итак, определим для $\tau > 0$

$$\hat{\beta}_{ridge} = \arg \min_{\beta} (\|Y - X\beta\|^2 + \tau \|\beta\|^2).$$

Оценку весов $\hat{\beta}_{ridge}$ легко найти в явном виде,

$$\hat{\beta}_{ridge} = (X^T X + \tau I_k)^{-1} X^T Y.$$

Добавление “гребня” τI_k к матрице $X^T X$ увеличивает все её собственные значения на τ , но не изменяет её собственных векторов. В результате матрица становится хорошо обусловленной, оставаясь в то же время “похожей” на исходную.

Недостаток метода в том, что $\mathbb{E}\hat{\beta}_{ridge} = (I_k - \tau W)\beta$, где $W = (X^T X + \tau I_k)^{-1}$, т.е. чем больше λ , тем больше смещение оценки вектора весов. Но зато норма матрицы ковариаций $Var\hat{\beta}_{ridge} = \sigma^2 W X^T X W$ с ростом τ уменьшается.

Как выбирать оптимальное значение τ ?

Теорема. $\exists \tau : \mathbb{E}\|\hat{\beta}_{ridge} - \beta\|^2 < \mathbb{E}\|\hat{\beta} - \beta\|^2$.

Единственная проблема, что на практике такое значение τ находить пока не научились, поэтому τ выбирается по следующему правилу: фиксируют некое не очень большое M и полагают τ таким, что $\frac{\lambda_{max} + \tau}{\lambda_{min} + \tau} = M$. Ну или берут τ от 0.1 до 0.4, если матрица X стандартизирована.

Least absolute shrinkage and selection operator

Помимо L_2 -, существует ещё масса регуляризаций, наиболее популярной из которых является L_1 -регуляризация, или LASSO,

$$\hat{\beta}_{lasso} = \arg \min_{\beta} (\|Y - X\beta\|^2), \quad \sum_{j=1}^k |\beta_j| < \kappa.$$

К сожалению, явной формы оценки $\hat{\beta}_{lasso}$ не существует.





При больших значениях κ решение совпадает с решением по методу наименьших квадратов. Чем меньше κ , тем больше коэффициентов β_j обнулятся (по теореме Куна-Такера) и тем меньше признаков войдут в уравнение регрессии. Т.е. по сути происходит отбор (селекция) признаков, что выгодно отличает LASSO от остальных видов регуляризации.

Не секрет, что при наличии выбросов в данных качество приближения в линейной регрессии может сильно ухудшиться (см. тот же квартет Энскомба). Методы решения этой проблемы:

- 1) удалить выбросы (например, с помощью расстояния Кука);
- 2) воспользоваться методами построения регрессии, которые устойчивы к выбросам (например, робастными регрессионными моделями или методом Тейла).

Проблема выбросов

Искажение регрессионной модели при наличии выбросов.



Грубо говоря, это мера воздействия j -того объекта на уравнение регрессии:

$$D_j = \frac{\sum_{i=1}^n (\hat{Y}_i - \hat{Y}_{i\setminus j})^2}{RSS(k+1)} = \frac{e_j^2}{RSS(k+1)} \frac{h_{jj}}{(1 - h_{jj})^2},$$

где предсказание $\hat{Y}_{i\setminus j}$ получено по модели, обученной по всем объектам, кроме j -того, а h_{jj} – элемент матрицы $H = X(X^T X)^{-1} X^T$.

Выбирать, какие объекты выбрасывать, можно по методу крутого склона (отсекать те объекты, D_j которых значительно больше остальных) или по тому, превысил ли D_j заранее заданный порог. Варианты порогов: $D_j > 1$, $D_j > 4/n$, $D_j > 3\bar{D}$. Или по графику зависимости D_j от $\hat{Y}_j$.

В рамках регрессионной модели

$$y_i = \beta_0 + \sum_{j=1}^k \beta_j x_{ij} + \varepsilon_i, \quad 1 \leq i \leq n,$$

выбираем

$$\hat{\beta}_j = \text{med} \left\{ \frac{y_i - y_k}{x_{ij} - x_{kj}}, \quad i \neq k \right\}, \quad \hat{\beta}_0 = \text{med} \left\{ y_i - \sum_{j=1}^k \hat{\beta}_j x_{ij} \right\}.$$

Поскольку используется медиана, данный метод является устойчивым к выбросам. Однако он плохо реагирует на мультиколлинеарность и большое количество признаков.

Робастные регрессионные модели

Ранее для поиска оценки вектора параметров в линейной модели мы использовали метод наименьших квадратов

$$\hat{\beta} = \arg \min_{\beta} \mathcal{R}(Y - X\beta), \text{ где } \mathcal{R}(x) = \|x\|^2.$$

Почему бы не использовать другие функции $\mathcal{R}$, для которых оценка вектора параметров будет не так сильно зависеть от выбросов, как в случае оценки методом наименьших квадратов? Будем считать, что

$$\mathcal{R}(x) = \sum_{i=1}^n \rho(x_i).$$

Требуем, чтобы такие функции $\rho(x)$ были: 1) симметричными, 2) неотрицательными, 3) монотонно неубывающими при $x > 0$.

Робастные регрессионные модели

Если ρ дифференцируема, то $\psi = \rho'$ называют функцией влияния. С помощью неё поиск оценки можно проводить, решая систему уравнений

$$\sum_{i=1}^n \psi \left(y_i - \sum_{j=1}^k x_{ij} \beta_j \right) x_{ij} = 0, \quad 1 \leq j \leq k.$$

Чтобы метод был устойчивым к выбросам, выбирают модели с ограниченной функцией влияния (в МНК функция влияния равна $2x$ и не ограничена). Проблема в том, что для решения такой системы методы линейной алгебры, как правило, не помогают, и приходится обращаться к методам численной оптимизации.

Робастные регрессионные модели

Примеры функций ρ :

1) L_1 : $\rho(x) = |x|$;

2) Хьюбер: $\rho(x) = \frac{x^2}{2}I(|x| \leq k) + k(|x| - \frac{k}{2})I(|x| > k)$;

3) L_p : $\rho(x) = |x|^p/p$;

4) Коши: $\rho(x) = \frac{c^2}{2} \ln(1 + (\frac{x}{c})^2)$;

5) Мешалкин: $\rho(x) = 1 - \exp(-\frac{x^2}{2\sigma})$;

6) German-Macclure: $\rho(x) = \frac{x^2}{2(1+x^2)}$;

В моделях L_1 , Коши и Макклера решение не обязательно единственно. Параметр в модели Хьюбера обычно выбирают равным $k = 1.345$, кроме того, оценки методом Хьюбера близки к асимптотически эффективным.

Finita!

Методы современной прикладной статистики

10. Ядерные оценки плотности и непараметрическая регрессия.

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Ядерная оценка плотности

Для произвольной функции распределения её оценкой является эмпирическая функция распределения $\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}(X_i \leq x)$. Хотелось бы получить оценку и для плотности.

Знаем, что оценкой для плотности является гистограмма, но хотелось бы чего-то более точного, например, аналога $\frac{\partial}{\partial x} \hat{F}_n(x)$.

Но $\hat{F}_n(x)$ – дискретная функция распределения, поэтому сгладим её с помощью свёртки с непрерывной функцией распределения.

Ядерная оценка плотности

Рассмотрим случайную величину

$$Z_n = X + h_n Y,$$

где X – случайная величина с ф.р. F , плотность $p(x)$ которой мы хотим оценить, Y независима с X и имеет известную плотность $q(y)$, h_n – последовательность, стремящаяся к 0, n – размер выборки.

Плотность $h_n Y$ равна $\frac{1}{h_n} q(y/h_n)$, тогда по формуле свертки

$$p_{Z_n}(z) = \frac{1}{h_n} \int_{\mathbb{R}} q\left(\frac{z-x}{h_n}\right) dF(x) = \frac{1}{h_n} \int_{\mathbb{R}} q\left(\frac{z-x}{h_n}\right) p(x) dx. \quad (1)$$

Оценка Розенблатта-Парзена

Поскольку $Z_n \xrightarrow{P} X$ при $h_n \rightarrow 0$, то (при некоторых дополнительных условиях) $p_{Z_n}(x) \rightarrow p(x)$.

Заменяем теперь в формуле (1) F на эмпирическую функцию распределения $\hat{F}_n$, получая тем самым **ядерную оценку** для $p(x)$:

$$\hat{p}_n(z) = \frac{1}{h_n} \int_{\mathbb{R}} q\left(\frac{z-x}{h_n}\right) \hat{F}_n(dx) = \frac{1}{nh_n} \sum_{i=1}^n q\left(\frac{z-X_i}{h_n}\right),$$

а функцию q будем называть **ядром**.

Theorem

Пусть выполнены следующие условия

- 1 $q(y)$ – непрерывна и ограничена;
- 2 $\alpha = \int q^2(y)dy < +\infty$;
- 3 $h_n \rightarrow 0$ и $h_n n \rightarrow +\infty$ при $n \rightarrow +\infty$.

Тогда

$$\hat{p}_n(z) = p_{Z_n}(z) + \frac{\xi_n(z)}{\sqrt{nh_n}},$$

где $p_{Z_n}(z) \rightarrow p(z)$ почти всюду, а

$$\xi_n(z) \xrightarrow{d} \xi(z) \sim N(0, \alpha p(z)).$$

Наилучшая скорость сходимости в теореме достигается при $h_n = Cn^{-1/5}$, таким образом, скорость сходимости в теореме равна $n^{2/5}$. Это неплохо, потому что скорость сходимости в ЦПТ равна $\sqrt{n}$, и выше вряд ли могло бы быть.

Однако на практике h_n выбирается эмпирически, исходя из сгруппированности данных и их количества.

На ядре Епанечникова $q^*(y) = \frac{3}{4}(1 - y^2)I(|y| \leq 1)$ в теореме достигается наилучшая скорость сходимости (при некоторых условиях, налагаемых на ядро), но существует много ядер, на которых скорость сходимости близка к наилучшей.

1) Ядро Епанечникова

$$q^*(y) = \frac{3}{4}(1 - y^2)I(|y| \leq 1).$$

Если предположить, что у ядра носитель A , который является конечным интервалом, что оно дважды непрерывно дифференцируемо с условием $\int_A [q''(y)]^2 dy = \gamma < +\infty$ и что второй момент $\beta = \int y^2 q(y) dy < +\infty$, то ядро Епанечникова среди них наилучшее.

2) Квартическое ядро

$$q(z) = \frac{15}{16}(1 - y^2)^2 I(|y| \leq 1).$$

В отличие от ядра Епанечникова, дифференцируемо в точках 1 и -1 .

3) Треугольное ядро $q(y) = (1 - |y|)I(|y| \leq 1)$.
Позволяет быстро пересчитывать $\hat{p}_n(z)$ в случае увеличения z с фиксированным шагом Δz .

4) Ядро Гаусса

$$q(y) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$


Бесконечно дифференцируемо, но оценка $\hat{p}_n(z)$ высчитывается медленно из-за многократного подсчета значений экспонент.

5) Прямоугольное ядро

$$q(y) = \frac{1}{2}I(|y| \leq 1).$$

По сути, ядром не является, поскольку имеются разрывы в точках 1 и -1 , но его можно приблизить трапециями. Его основным преимуществом является очень простой вид.

Как на практике выбирать h_n ?



На рисунке – выборка размера 100 с плотностью $p(z) = 2(\mathbb{1}(z \in [0.1, 0.4]) + \mathbb{1}(z \in [0.6, 0.8]))$, вычислены $\hat{p}_n(z)$ для $h_n = 0.1, 0.02, 0.5$.

Видим, что выбор малого h_n ведет к быстро меняющейся, неустойчивой оценке, так как $\hat{p}_n(z)$ опирается лишь на небольшое количество наблюдений в узкой окрестности z , а слишком большие значения h_n ведут к чрезмерному сглаживанию плотности.

Можно выбирать h_n следующим образом:

- 1 $h_n(x) = \inf\{h : \#\{X_i : |X_i - x| < h\} = K\}$, т.е. чтобы оценка в любой точке всегда строилась по K элементам выборки.
- 2 $h_n = \frac{1}{n} \sum_{i=1}^n d_{iK}$, где d_{iK} – расстояние от X_i до K -того ближайшего соседа.

Непараметрическая регрессия

Рассмотрим модель

$$Y_i = m(X_i) + \varepsilon_i,$$

где X_i – значение признака на i -том объекте (будем пока считать, что признак один), $\{\varepsilon_i\}$ – н.о.р. случайные ошибки, $\mathbb{E}\varepsilon_i = 0$, $\text{Var } \varepsilon_i = \sigma^2$.

Наша задача – оценить функцию m . На предыдущих двух лекциях решалась задача, когда $m(x)$ являлась линейной функцией от x , теперь же решим её в общем случае.

Непараметрическая регрессия

С помощью метода локального усреднения имеем

$$\hat{m}(x) = \frac{\sum_{i=1}^n \omega_i(x) Y_i}{\sum_{i=1}^n \omega_i(x)},$$

где веса $\omega_i(x)$ велики для X_i , близких к x , и малы для остальных X_i .

Определим $\omega_i(x)$ с помощью применения ядерных оценок. Пусть $q(y)$ – ядро, выберем

$$\omega_i(x) = \frac{1}{h} q\left(\frac{x - X_i}{h}\right),$$

где $h = h_n$ – окно пропускания (bandwidth).

Оценка Надарая-Ватсона

Подставляя значения весов в формулу локального усреднения, получаем оценку Надарая-Ватсона

$$\hat{m}(x) = \frac{\sum_{i=1}^n q\left(\frac{x-X_i}{h}\right) Y_i}{\sum_{i=1}^n q\left(\frac{x-X_i}{h}\right)},$$

в знаменателе которой, как легко заметить, стоит ядерная оценка плотности выборки X_i , умноженная на nh .

Оценка Надарая-Ватсона




Рис.: График зависимости между процентом бедного населения и средней ценой квартиры в кварталах Бостона.

Другие методы определения весов

1) Менее популярным методом задания весов является метод Гассера-Мюллера. Определим

$$\tilde{\omega}_i(x) = \frac{1}{h} \int_{X_{(i-1)}}^{X_{(i)}} q\left(\frac{x-y}{h}\right) dy,$$

где $-\infty = X_{(0)} < X_{(1)} < \dots < X_{(n)} < X_{(n+1)} = +\infty$ – вариационный ряд значений признака X .

2) В случае, если признаков в регрессионной модели – k , можно взять

$$\omega_i(x) = \frac{1}{h^k} \prod_{j=1}^k q\left(\frac{x_j - X_{ij}}{h}\right) \text{ или } \omega_i(x) = \frac{1}{h} q\left(\frac{\|x - X_i\|}{h}\right).$$

Theorem

Пусть выполнены следующие условия:

- 1) $\{(X_i, Y_i)\}$ – н.о.р. случайные векторы (размерности 2);
- 2) ядро q таково, что $\int_{\mathbb{R}} |q(y)| dy < \infty$ и $yq(y) \rightarrow 0$ при $y \rightarrow \infty$;
- 3) $\mathbb{E}(Y^2|X = x) < \infty \forall x$;
- 4) последовательность h_n такова, что $h_n \rightarrow 0$ и $h_n n \rightarrow +\infty$ при $n \rightarrow +\infty$.

Тогда в точках непрерывности $p(x)$

$$\hat{m}(x) \xrightarrow{P} m(x) = \mathbb{E}(Y|X = x).$$

1) LOO-метод (leave-one-out):

$$h_n = \arg \min_h \sum_{i=1}^n (\tilde{m}_i(X_i) - Y_i)^2,$$

где оценка $\tilde{m}_i(x)$ получена по выборке $\{X_j\}_{j=1}^n$, откуда мы удалили наблюдение X_i . Также, можно воспользоваться кросс-валидацией, если выборка большая.

2) KNN-метод. Можно воспользоваться одним из методов со слайда 10, например, таким:

$$h_n(x) = \inf \{h : \#\{X_i : |X_i - x| < h\} = K\},$$

а дальше найти оптимальное K с помощью LOO или кросс-валидации.

Проблема краевых эффектов

В задаче непараметрической регрессии часто наблюдается значительное смещение $\hat{m}(x)$ от истинной зависимости $m(x)$ вблизи минимального и максимального значений $\{X_i\}$.

Смещение возникает, поскольку объекты выборки $\{X_i\}$ располагаются “по одну сторону” от x – т.е. отсутствие объектов “по другую сторону” никак не учитывается.

В этом случае вместо аппроксимации регрессионной зависимости в окрестности x числом будем аппроксимировать зависимость линейной функцией (или многочленом).

Проблема краевых эффектов

Итак, оценим $m(x)$ вблизи краевых точек как $\hat{a}(x) + \hat{b}(x)x$, где

$$\hat{a}(x), \hat{b}(x) =$$

$$\arg \min_{a(x), b(x)} \frac{1}{h(x)} \sum_{i=1}^n q\left(\frac{X_i - x}{h(x)}\right) (Y_i - a(x) - b(x)(X_i - x))^2.$$

Название метода – local linear regression model. Если положить $b(x) = 0$, то получим оценку Надарая-Ватсона.

Проблема краевых эффектов

Если в методе локальной линейной регрессии заменить выражение $Y_i - a(x) - b(x)(X_i - x)$ на

$$Y_i - a(x) - \sum_{j=1}^d b_j(x)(X_i - x)^j,$$

то мы получим метод локальных полиномов (local polynomial regression model), который точнее предыдущего, но не всегда его применение осмысленно.

В многомерном случае метод локальной регрессии требует решать задачу линейной регрессии $Y = a(x) + B(X - x)$ в каждой точке x , что требует значительных вычислительных затрат.

Проблема выбросов

Оценка Надарая-Ватсона крайне чувствительна к большим одиночным выбросам. Это проблема решается с помощью алгоритма LOWESS (локально взвешенное сглаживание). Обозначим $q_h(x) = \frac{1}{h}q(x/h)$, где q – ядро (возможно, многомерное).

1) Положим $\gamma_i = 1$ для всех $i \in \{1, \dots, n\}$;

2*N*) Вычисляем оценки скользящего контроля на каждом объекте,

$$a_i = \hat{m}(X_i, X \setminus X_i) = \frac{\sum_{j \neq i} Y_j \gamma_j q_h(x_i)(X_i - X_j)}{\sum_{j \neq i} \gamma_j q_h(x_i)(X_i - X_j)};$$

2*N* + 1) Вычисляем коэффициенты $\gamma_i = \bar{q}(a_i - Y_i)$, где $\bar{q}$ – какое-нибудь другое ядро.

Алгоритм продолжает свою работу до тех пор, пока γ_i не стабилизируются. Сходится алгоритм достаточно быстро. Результатом алгоритма является следующая оценка регрессии

$$\hat{m}(x) = \frac{\sum_{j=1}^n Y_j \gamma_j q_{h(x)}(X_j - x)}{\sum_{j=1}^n \gamma_j q_{h(x)}(X_j - x)}.$$

Варианты выбора ядра $\bar{q}$:

1) на $2N + 1$ шаге строится вариационный ряд ошибок $\varepsilon_i = |a_i - Y_i|$: $\varepsilon_{(1)} \leq \dots \leq \varepsilon_{(n)}$, тогда $\bar{q}(\varepsilon) = I(\varepsilon \leq \varepsilon_{(n-k)})$ (жесткая фильтрация);

2) $\bar{q}(\varepsilon) = q_Q \left(\frac{\varepsilon}{6 \text{med}\{\varepsilon_i\}} \right)$, где q_Q – кватрическое ядро (мягкая фильтрация).

Нелинейные обобщения линейной регрессии

Предположение о том, что модель регрессии линейна по параметрам, удобно для построения численных методов, но не всегда хорошо согласуется со знаниями о предметной области.

Пусть задана нелинейная модель регрессии $Y = f(X, \alpha) + \varepsilon$, хотим минимизировать функционал качества

$$Q(\alpha) = \sum_{i=1}^n (f(x_i, \alpha) - y_i)^2$$

по вектору параметров $\alpha \in \mathbb{R}^p$, чтобы найти оценку отклика.

Сведем решение нелинейной задачи к решению последовательности линейных задач.

Метод Ньютона-Рафсона

Для минимизации $Q(\alpha)$ воспользуемся методом Ньютона-Рафсона. Выберем начальное приближение $\alpha^0 = (\alpha_1^0, \dots, \alpha_p^0)$ и организуем итерационный процесс

$$\alpha^{t+1} := \alpha^t - h_t(Q''(\alpha^t))^{-1}Q'(\alpha^t),$$

где Q' – градиент Q по α , Q'' – матрица вторых производных (гессиан) Q по α , h_t – величина шага, в самом простом варианте метода равная 1.

Обращать матрицу Q'' , а тем более много раз, не очень хочется, поэтому желательно придумать метод, упрощающий это действие.

Метод Ньютона-Рафсона

Выпишем компоненты градиента

$$\frac{\partial}{\partial \alpha_j} Q(\alpha) = 2 \sum_{i=1}^n (f(x_i, \alpha) - y_i) \frac{\partial f}{\partial \alpha_j}(x_i, \alpha).$$

Выпишем компоненты гессиана (вместо $f(x_i, \alpha)$ пишем $f(x_i)$)

$$\frac{\partial^2}{\partial \alpha_j \partial \alpha_k} Q(\alpha) = 2 \sum_{i=1}^n \frac{\partial f(x_i)}{\partial \alpha_j} \frac{\partial f(x_i)}{\partial \alpha_k} - 2 \sum_{i=1}^n (f(x_i) - y_i) \frac{\partial^2 f(x_i)}{\partial \alpha_j \partial \alpha_k}.$$

Было бы неплохо, если бы второе слагаемое обратилось в 0, тогда гессиан равнялся бы произведению двух матриц и обращать его стало бы гораздо проще.

Метод Ньютона-Гаусса

Предположим, что f дважды непрерывно дифференцируема, тогда её можно линеаризовать в окрестности α^t ,

$$f(x_i, \alpha^t) = f(x_i, \alpha) + \sum_{j=1}^p \frac{\partial f(x_i)}{\partial \alpha_j}(x_i, \alpha)(\alpha_j^t - \alpha_j).$$

Тогда если заменить в гессиане функцию f на её линеаризацию, то вторые производные от f обратятся в 0.

Данный метод называется методом Ньютона-Гаусса, в остальном он ничем не отличается от метода Ньютона-Рафсона. Скорость сходимости у него тоже практически такая же, как у метода Ньютона-Рафсона.

Метод Ньютона-Гаусса

Обозначим $F_t = (\frac{\partial f}{\partial \alpha_j}(x_i, \alpha^t))$, $1 \leq i \leq n$, $1 \leq j \leq p$, – матрица первых производных на t -й итерации,
 $f_t = (f(x_i, \alpha^t))_{i=1}^n$ – вектор значений аппроксимирующей функции на t -й итерации.

Тогда формула t -й итерации метода Ньютона-Гаусса в матричной записи примет вид

$$\alpha^{t+1} = \alpha^t - h_t(F_t^T F_t)^{-1} F_t^T (f_t - Y).$$

Легко заметить, что в правой части записано решение линейной регрессионной задачи $\|(f_t - Y) - F_t \delta\|^2 \rightarrow \min_{\delta}$, т.е. мы свели решение задачи нелинейной регрессии к последовательности линейных регрессионных задач.

Нелинейные преобразования признаков

На практике встречаются ситуации, когда линейная модель регрессии представляется необоснованной, но предложить адекватную нелинейную модель $f(x, \alpha)$ также не удаётся. Тогда в качестве компромисса строится модель (известная как обобщенная аддитивная модель, или GAM) вида

$$f(X, \alpha) = \sum_{j=1}^k \varphi_j(X_j),$$

где $\varphi_j : \mathbb{R} \rightarrow \mathbb{R}$ – некоторые преобразования исходных признаков, в общем случае нелинейные. Будем подбирать оптимальные $\{\varphi_j\}$ с точки зрения минимизации квадратичной функции потерь.

Алгоритм настройки с возвращением

На первом шаге полагаем $\varphi_j(x) = \alpha_j x$, коэффициенты α_j находятся с помощью линейной регрессии.

На каждом последующем шаге выбирается одна из функций φ_j , все остальные фиксируются, и выбранная функция строится заново. Для этого решается стандартная задача наименьших квадратов

$$\varphi_j = \arg \min_{\varphi} \sum_{i=1}^n (\varphi(x_{ij}) - z_i)^2,$$

где $z_i = y_i - \sum_{k \neq j} \varphi_k(x_{ik})$ – не зависит от φ_j . К решению этой задачи приводит использование, например, оценки Надарая-Ватсона, можно также приближать φ_j полиномами или рядом Фурье.

Finita!


Методы современной прикладной статистики

11. Методы понижения размерности.

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Задача: распознать цифры на картинке, для чего нужно выбрать компактное признаковое описание изображения.



Выбор признакового пространства


Прямой способ решения: вытянуть интенсивности каждой точки изображения в вектор.

Такой способ описания данных не является адекватным по следующим причинам:

- Слишком большое число признаков (для картинки 28×28 – 784 признака). Как следствие, большое время обработки, проблемы переобучения и т.д.
- Близкие в пространстве признаков объекты часто лежат в разных классах. Гипотеза компактности является одним из основных предположений большинства методов распознавания.


Гипотеза компактности

Близкие в пространстве признаков объекты не являются объектами одного класса.



Преобразование пространства признаков

После применения метода главных компонент количество признаков уменьшается (с 784 до нескольких десятков), причем объекты одного класса образуют компактные области в пространстве признаков.



Снижение размерности данных

Пусть имеются признаки $X = \{X_j\}_{j=1}^k$, $X_j \in \mathbb{R}^n \ \forall j$. Цель – выбрать пространство меньшей размерности $m < k$ так, чтобы схожие объекты оставались схожими и образовывали компактные области. Причины понижения размерности

- уменьшение вычислительных затрат;
- борьба с переобучением;
- сжатие данных для более эффективного хранения информации;
- визуализация и интерпретация данных;
- извлечение признаков;
- борьба с мультиколлинеарностью;
- ...

Метод главных компонент (PCA)

Метод является ещё одним способом борьбы с проблемой мультиколлинеарности признаков в задаче линейной регрессии. Идея метода состоит в том, чтобы подвергнуть исходные признаки некому линейному преобразованию так, чтобы новые признаки были ортогональны, а число их уменьшилось.

Несмотря на очевидные плюсы метода, он обладает и недостатками: в частности, новые признаки зачастую не являются наглядными. Также метод дает не самые лучшие результаты, если данные расположены на некоем многообразии, плохо приближающемся гиперплоскостью.

Постановка задачи

Пусть $X_1, \dots, X_k$ – исходные признаки модели размерности n (т.е. значения признаков посчитаны на n объектах).

Обозначим через $X = \|x_{ij}\|$ матрицу признаков размера $n \times k$. Хотим перейти от признаков X к новым признакам $Z = \|z_{ij}\|$, где Z – матрица размера $n \times m$, $m < k$.

Кроме того, потребуем, чтобы старые признаки по новым восстанавливались с приемлемой точностью, т.е. $\exists$

$U_m = \|u_{jl}\|$ размера $k \times m$ такая, что $\hat{X}_j = \sum_{l=1}^m u_{jl} Z_l$ было бы хорошим приближением признака X_j . Получается, мы хотим решить следующую задачу

$$\Delta^2(Z, U_m) = \sum_{j=1}^k \|\hat{X}_j - X_j\|^2 = \|ZU_m^T - X\|^2 \rightarrow \min_{U_m, Z}.$$

Теорема. Если $m < \text{rank}(X)$, то минимум $\Delta^2(Z, U_m)$ достигается, когда столбцы матрицы U_m есть собственные вектора матрицы $X^T X$, соответствующие m максимальным собственным значениям этой матрицы. При этом $Z = XU_m$, а матрицы U_m и Z – ортогональны.

Свойства матриц U_m и Z :

- 1) Матрица U_m ортонормирована, т.е. $U_m^T U_m = I_m$;
- 2) $Z^T Z = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$, где $\lambda_1 \geq \dots \geq \lambda_m$ – m максимальных собственных значений матрицы $X^T X$.
- 3) $X^T X U_m = U_m \Lambda$, $XX^T Z = Z\Lambda$;
- 4) $\|ZU_m^T - X\|^2 = \|X\|^2 - \text{tr}\Lambda = \sum_{j=m+1}^k \lambda_j$.

Главные компоненты – это собственные векторы матрицы $X^T X$, соответствующие m максимальным собственным значениям этой матрицы. В качестве новых признаков описаний объектов мы выбираем проекции старых объектов на эти собственные векторы. Тогда

5) Проекции объектов на первую главную компоненту c_1 имеют наибольшую выборочную дисперсию среди проекций на всевозможные направления $d \in \mathbb{R}^k$. Далее, $\forall j \geq 2$ проекции объектов на c_j – j -тую главную компоненту – имеют наибольшую выборочную дисперсию среди проекций на всевозможные направления $d \in \mathbb{R}^k$, перпендикулярные $c_1, \dots, c_{j-1}$.

Выбор количества признаков

Из свойства 4 вытекает, что чем меньше

$E_m = \sum_{j=m+1}^k \lambda_j / \sum_{j=1}^k \lambda_j$, тем лучше новые признаки приближают старые.

Отсюда количество новых признаков можно выбирать так: $\tilde{m} := \min_m \{E_m < \varepsilon\}$, $\tilde{m}$ называется эффективной размерностью пространства признаков X .

Также m можно выбрать с помощью **метода крутого склона**: если E_{m+1} достаточно мало и $E_m \gg E_{m+1}$, то в качестве эффективной размерности берем m .

Наконец, **метод сломанной трости** состоит в следующем. Обозначим $C = \sum_{j=1}^k \lambda_j$, введем $l_i = \frac{1}{n} \sum_{j=i}^n \frac{1}{j}$. Тогда

$$\bar{m} = \inf \left\{ k : \frac{\lambda_k}{C} < l_k \right\}.$$

Подготовка данных к применению метода

- 1) Выбросы могут сильно помешать работе алгоритма (потому что метод линейный), поэтому стоит их удалить.
- 2) Если 2 признака имеют очень большую корреляцию ($\rho > 0.95$), то один из признаков тоже стоит удалить, иначе матрицы будут плохо обращаться.
- 3) Если признаки – в различных шкалах (например, литры и метры), то стандартизация данных **обязательна!**

Задача регрессии в новых признаках

Посмотрим, как будет выглядеть постановка задачи линейной регрессии для новых признаков. Заменяя X на ZU_m^T , имеем

$$\|Y - ZU_m^T\beta\|^2 = \|Y - Z\theta\|^2 \rightarrow \min_{\theta},$$

где $\theta = U_m^T\beta$.

Тогда решение записывается как $\hat{\theta} = \Lambda^{-1}Z^TY = D_mV^TY$,

$$\hat{\beta} = U_mD_mV^TY = \sum_{j=1}^m \frac{1}{\sqrt{\lambda_j}} u_j(v_j^TY),$$

где $D_m = \text{diag}\{(\lambda_1)^{-1/2}, \dots, (\lambda_m)^{-1/2}\}$ – матрица размера $m \times n$, а матрица V появляется в сингулярном разложении, к которому сейчас и перейдем.

Сингулярное разложение (SVD)

Известно, что любая матрица размера $n \times k$ (ранга k) представима в виде $X = VDU^T$, где

- 1) V – ортогональная матрица размера $n \times n$, ее столбцы – собственные векторы матрицы XX^T ;
- 2) D – матрица размера $n \times k$, $d_{ii} = \sqrt{\lambda_i}$, $d_{ij} = 0$, если $i \neq j$, где $\{\lambda_i\}_{i=1}^k$ – собственные числа матрицы $X^T X$ (и ненулевые собственные значения матрицы XX^T);
- 3) U – ортогональная матрица размера $k \times k$, её столбцы – собственные векторы матрицы $X^T X$.

Сингулярное разложение

Тогда решение метода наименьших квадратов линейной регрессии выглядит так:

$$\hat{\beta} = (X^T X)^{-1} X^T Y = (UD^T V^T VDU^T)^{-1} UD^T V^T Y = \\ U(D^T)^{-1} V^T Y = \sum_{j=1}^k \frac{1}{\sqrt{\lambda_j}} u_j (V^T Y)_j,$$

где $(D^T)^{-1}$ – матрица размера $k \times n$, на диагонали которой стоят числа $\frac{1}{\sqrt{\lambda_i}}$, $i = 1, \dots, k$, а все остальные элементы нулевые.

Если есть сингулярное разложение, то в методе главных компонент $Z = VD_m^T$, где D_m – матрица размера $m \times n$, на диагонали которой стоят числа $\frac{1}{\sqrt{\lambda_i}}$, $i = 1, \dots, m$, а все остальные элементы нулевые, а U_m – это матрица U , у которой убрали $k - m$ последних столбцов.

В случае, если n и k являются большими, то довольно сложно найти собственные числа и собственные векторы матрицы $X^T X$. В этом случае, чтобы понизить размерность, можно воспользоваться степенным методом вычисления главных компонент.

Пусть есть произвольная симметричная матрица A размера n , а её собственные числа $|\lambda_1| \geq |\lambda_2| \geq \dots$, c_1 – собственный вектор, соответствующий λ_1 , и для некоторого $x_0 \in \mathbb{R}^n$ скалярное произведение $(c_1, x_0) \neq 0$. Положим $x_{k+1} = Ax_k$, $k \geq 0$.

Теорема.

$$t_{k+1} = \frac{(x_k, x_{k+1})}{|x_k|^2} \rightarrow \lambda_1 \text{ при } k \rightarrow \infty.$$

Алгоритм вычисления λ_k и c_k (в предположении, что $\{\lambda_i\}_{i=1}^{k-1}$ и $\{c_i\}_{i=1}^{k-1}$ известны или уже найдены):


- 1) выбираем произвольное $x_0 \in \mathbb{R}^n$, кладем $t_0 = 0$;
- 2) (для $i \geq 1$ и $k \geq 2$) ортогонализируем x_i по векторам $(c_1, \dots, c_{k-1}) : y_i = x_i - (c_1, x_i)c_1 - \dots - (c_{k-1}, x_i)c_{k-1}$;
- 3) нормируем $y_i : e_i = y_i/|y_i|$;
- 4) вычисляем $x_{i+1} = Ae_i$ и $t_{i+1} = (x_{i+1}, e_i)$;
- 5) нормируем $x_{i+1} : z_{i+1} = x_{i+1}/|x_{i+1}|$;
- 6) если $|t_i - t_{i+1}| \leq \varepsilon$, то полагаем $\lambda_k = e_{i+1}$ и $c_k = z_{i+1}$ и заканчиваем процесс; если нет, то полагаем $x_{i+1} = z_{i+1}$ и возвращаемся к шагу 2.

Скорость сходимости алгоритма экспоненциальная.


Недостатки метода главных компонент

- 1) Метод главных компонент способен находить только линейные подпространства исходного пространства, которые “объясняют” данные с высокой точностью. На практике поверхность, вдоль которой располагаются данные, может сильно отличаться от линейной.
- 2) PCA является инвариантным относительно поворота координат в пространстве переменных. Это означает, что восстановление значений исходных переменных является неоднозначным.
- 3) Если некоторые собственные значения матрицы $X^T X$, совпали, то новое пространство признаков может определяться неоднозначно.


Нелинейные методы понижения размерности




(a) Swiss roll dataset.



(b) Helix dataset.



(c) Twinpeaks dataset.



(d) Broken Swiss roll dataset.

Типовые датасеты, на которых проверяется качество нелинейных алгоритмов понижения размерности и на которых РСА плохо работает. Реальные данные бывают устроены гораздо сложнее.

Ядерный PCA (Kernel PCA)



Kernel PCA основан на том же принципе, что и обычный PCA, однако он позволяет создавать новые признаки с помощью более сложных, нелинейных преобразований старых признаков.

Заметим, что в PCA мы работаем только с матрицей $X^T X$, которая (при условии стандартизации X) является матрицей корреляций признаков $X_1, \dots, X_k$.

Если мы вместо обычного скалярного произведения (x, y) в пространстве $\mathbb{R}^n$ в PCA рассмотрим скалярное произведение $K(x, y) = (\Phi(x), \Phi(y))$, где $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^N$, $N > n$, то как раз и получим метод Kernel PCA. Для его применения знать явный вид Φ не нужно.

Зачем нужны ядра (повышение размерности)

Иногда данные в задаче не являются линейно разделимыми. Однако, после некоторого нелинейного преобразования признаков удастся разделить данные прямой. Ядро - это и есть то самое нелинейное преобразование.



- Линейное (приводит к обычному PCA);
- Полиномиальные (например, квадратичное ядро $K(x, y) = ((x, y) + 1)^2$);
- Гауссово (RBF) $K(x, y) = \exp\left(-\frac{\|x-y\|^2}{2\sigma^2}\right)$;
- ...

Многомерное шкалирование (MDS)

Многомерное шкалирование (multi-dimensional scaling), как и метод главных компонент, относится к так называемым глобальным методам, т.е. сохраняющим глобальные свойства объектов.

Цель метода: минимизировать суммарное расхождение между расстояниями между объектами, $d_{ij} = \rho(x_i, x_j)$, и расстояниями между объектами в новом пространстве признаков, $\delta_{ij} = \rho(z_i, z_j)$.

Выделяют подходы

- 1) классический: $F_0 = \sum_{i < j} (d_{ij} - \delta_{ij})^2 \rightarrow \min_{\delta}$;
- 2) метод Сэммона: $F_1 = \sum_{i < j} \frac{(d_{ij} - \delta_{ij})^2}{d_{ij}} \rightarrow \min_{\delta}$.

- 1) Прежде чем применять метод многомерного шкалирования, нужно стандартизировать данные, если они померяны в разных шкалах.
- 2) Возможные виды расстояний: а) евклидово; б) метрика Манхэттена: $\rho(x, y) = \sum_i |x_i - y_i|$, в) равномерная метрика: $\rho(x, y) = \max_i |x_i - y_i|$ и другие.
- 3) В случае, если мы используем классическое MDS для евклидовой метрики, то результат метода будет совпадать с применением PCA.
- 4) Метод Сэммона более точно передает небольшие различия и менее точно – большие (действительно, ведь при отображении бóльших расстояний допустимы бóльшие ошибки). Также метод устойчив к наличию пропусков в данных.

5) Готового способа выяснить, какие признаки вносят вклад в новые признаки и коррелируют с ними, нет.

6) Выбирать размерность пространства новых признаков m можно следующим образом: если величина $\text{stress} = \sqrt{F_0 / \sum_{i < j} \delta_{ij}^2} < 0.2$, то приближение считается приемлемым.

7) Минимум функционалов F_0 и F_1 ищется градиентными методами. Начальное приближение для них можно выбрать так: либо спроектировать исходное пространство признаков на произвольное подпространство размерности m , либо воспользоваться для выбора этого подпространства РСА.

Метод сопряженных градиентов

Хотим найти $x_{min} = \arg \min_x F(x)$, $x \in \mathbb{R}^{nm}$.

1) Определим $\bar{p}_t$ в пространстве $\mathbb{R}^{nm}$ по формулам

$$p_1 = -g_1, \quad p_t = -g_t + \beta_t p_{t-1} \text{ при } t \geq 2,$$

где p_{t-1} – направление на предыдущем шаге,

$$\beta_t = \|g_t / g_{t-1}\|^2, \text{ а } g_t = \left(\frac{\partial F}{\partial x_{11}}, \dots, \frac{\partial F}{\partial x_{nm}} \right) \Big|_{x=x_t}.$$

2) Перемещаемся из x_t в x_{t+1} по следующему правилу:

$$x_{t+1} = x_t + \alpha_t p_t,$$

где $\alpha_t = \arg \min_{\alpha > 0} F(x_t + \alpha p_t)$.

3) Если $|g_{t+1}| < \varepsilon$, то заканчиваем.

Метод сопряженных градиентов



1) На втором шаге алгоритма можно выбрать

$$\alpha_t = \frac{((x_t - x_{t-1}), (g_t - g_{t-1}))}{\|g_t - g_{t-1}\|^2}.$$


2) Если брать на первом шаге $\beta_t = 0$ (метод наискорейшего спуска), то процесс рискует никогда не остановиться.

3) В **методе стохастического градиента** на t -м шаге алгоритма берем $g_t = (0, \dots, 0, \frac{\partial F}{\partial x_{ij}}, 0, \dots, 0)$, где i и j выбираются случайно. Метод сходится медленнее, но не требует больших вычислительных затрат.

Малые значения d_{ij} не всегда должны влечь за собой малые значения δ_{ij} . Как исправить этот недостаток?



В методе Isomap минимизируется суммарное расхождение между расстояниями между объектами в пространстве новых признаков и расстояниями по поверхности (по геодезическим) в исходном пространстве.



Алгоритм устроен следующим образом:


- 1) Для каждой точки находятся M её ближайших соседей, после чего строится взвешенный неориентированный граф только по расстояниям до этих ближайших соседей.
- 2) Используя алгоритм поиска кратчайших расстояний в графе, например, алгоритм Дейкстры, находятся кратчайшие расстояния (обозначим их $\|x_i - x_j\|_G$) между каждой парой вершин по графу, построенному в предыдущем пункте.
- 3) Применяем алгоритм MDS для расстояния $\|x_i - x_j\|_G$ и евклидовой нормы $\|z_i - z_j\|$.

Алгоритм определения места нового объекта в новых признаках:

- 1) Находит M ближайших соседей нового объекта из набора для обучения.
- 2) Строит граф, отображающий геодезические расстояния от данной точки до точек обучающей выборки. Для этого взвешенный неориентированный граф расстояний до ближайших соседей нового объекта дополняется графом, полученным на шаге 2) алгоритма, а затем по этому графу находятся кратчайшие расстояния от нового объекта до каждой точки обучающего набора.
- 3) Вектор, содержащий кратчайшие геодезические расстояния от нового объекта до каждой точки обучающего набора, подаётся на вход алгоритма MDS, обученного на шаге 3) алгоритма. После этого MDS возвращает точку в K -мерном пространстве.

- 1) Выбросы, лежащие между далекими частями поверхности в исходном пространстве признаков, могут сделать эти далекие части близкими в пространстве новых признаков. В таком случае нужно убрать мешающие алгоритму объекты (например, с помощью Isolation Forest).
- 2) Выбор M : слишком малое значение M ведет к плохой аппроксимации геодезического расстояния, а слишком большое может привести к “зацикливанию” через объекты из пункта 1.

Пример работы алгоритма:



t-SNE (t-distributed stochastic neighbor embedding) – один из лучших алгоритмов понижения размерности, существующих на настоящий момент, в частности, хорошо подходящий для визуализации данных.

Вначале вычислим меру “похожести” объектов x_i и x_j в исходном пространстве. Определим

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)},$$

и положим $p_{ij} = \frac{1}{2n}(p_{j|i} + p_{i|j})$, т.е. чем дальше друг от друга x_i и x_j , тем экспоненциально меньше мера их близости. Параметр σ_i выбирается исходя из равенства энтропии условного распределения $\{p_{\cdot|i}\}$ заранее фиксированному значению, не зависящему от i .

Далее, определим объекты $\{z_i\}_{i=1}^n$ в пространстве меньшей размерности (размерность можно выбрать с помощью PCA) так, чтобы они отражали меру похожести объектов $\{x_i\}_{i=1}^n$. Обозначим

$$q_{ij} = \frac{(1 + \|z_i - z_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|z_k - z_l\|^2)^{-1}}.$$

Видим, что удаленность объектов в пространстве меньшей размерности штрафует меньше. Расположение объектов $\{z_i\}_{i=1}^n$ определяется с помощью минимизации градиентным спуском расстояния Кульбака-Лейблера “распределения” Q от “распределения” P

$$KL(P||Q) = \sum_{i \neq j} p_{ij} \ln \frac{p_{ij}}{q_{ij}}.$$

Алгоритм предложен в 2018 году с целью получить аналог t-SNE, но с более сильным математическим обоснованием. Определим для каждого объекта x_i множество k его ближайших соседей $T_i = \{t_{i1}, \dots, t_{ik}\}$.

Определим также $\rho_i = \min_{t \in T_i} d(x_i, t)$ – расстояние до ближайшего соседа для i -того объекта – и величину σ_i , заданную уравнением

$$\sum_{t \in T_i} \exp \left(-\frac{d(x_i, t) - \rho_i}{\sigma_i} \right) = \log_2 k.$$

Сначала алгоритм выполняет построение взвешенного ориентированного графа, где ребра соединяют объекты с его k ближайшими соседями.

Вес ребра $(x_i \rightarrow t_{ij})$ рассчитывается как

$$w(x_i \rightarrow t_{ij}) = \exp \left(-\frac{d(x_i, t_{ij}) - \rho_i}{\sigma_i} \right).$$

Видим, что сумма этих весов для каждого i равна $\log_2 k$.

Вполне могло оказаться так, что между 2 объектами есть 2 ребра с разными весами. Но хочется интерпретировать вес ребра как вероятность того, что 2 объекта соединены ребром.

Поэтому объединим такие ребра в одно с весом, равным вероятности существования хотя бы одного ребра:

$$w_{ij} = w(x_i \rightarrow x_j) + w(x_j \rightarrow x_i) - w(x_i \rightarrow x_j)w(x_j \rightarrow x_i).$$

Так мы получаем взвешенный неориентированный граф (по аналогии с Isomap).

Последний шаг алгоритма создает новый граф в низкоразмерном пространстве и приближает множество его ребер к исходному, минимизируя сумму расстояний Кульбака-Лейблера:

$$\sum_{i < j} \left(w_{ij} \log \frac{w_{ij}}{\tilde{w}_{ij}} + (1 - w_{ij}) \log \frac{1 - w_{ij}}{1 - \tilde{w}_{ij}} \right) \rightarrow \min_{\tilde{w}},$$

где $\tilde{w}_{ij}$ – веса (вероятности) ребер в новом пространстве признаков меньшей размерности.

Минимизация проводится с помощью стохастического градиентного спуска. Полученные веса ребер определяют расположение объектов в новом пространстве.

Локальное линейное погружение (LLE)

Наряду с t-SNE и UMAP, методы, основанные на LLE (local linear embedding), показывают наилучшие результаты при снижении размерности данных. Алгоритм построен на простой идее – методе взвешенного среднего.

Итак, найдем для каждого объекта x_i M его ближайших соседей $x_{i(1)}, \dots, x_{i(M)}$ и найдем такие веса $\{w_{ij}\}_{j=1}^M$, что

$$L(w) = \sum_{j=1}^M (x_i - w_{ij}x_{i(j)})^2 \rightarrow \min_w$$

при условии $\sum_j w_{ij} = 1$.

Локальное линейное погружение (LLE)

Чтобы определить объекты $\{z_i\}_{i=1}^n$ в пространстве меньшей размерности, решим задачу оптимизации

$$\sum_{i=1}^n \left(z_i - \sum_{j=1}^M w_{ij} z_{i(j)} \right)^2 \rightarrow \min_z.$$

Существуют разновидности метода LLE (например, Hessian LLE и Modified LLE), которые работают лучше обычного LLE, но, в отличие от HLLE, MLLE не сильно отличается по вычислительной сложности от LLE.

Ещё одной модификацией LLE является метод Laplacian eigenmaps, где в качестве весов выбираются

$$w_{ij} = \exp \left(-\frac{\|x_i - x_j\|^2}{2\sigma^2} \right),$$

где $j \in \{i(1), \dots, i(M)\}$, а затем объекты в пространстве меньшей размерности выбираются с помощью решения задачи оптимизации

$$\sum_{i=1}^n \sum_{j \in \{i(1), \dots, i(M)\}} w_{ij} (z_i - z_j)^2 \rightarrow \min_z.$$

Замечания о локальных методах

- 1) “Зацикливание” (short-circuiting) может произойти только на маленьких участках поверхности и не будет затрагивать всю поверхность;
- 2) Локальные методы, основанные на KNN, склонны к проклятию размерности;
- 3) Локальные методы склонны к переобучению на выбросах (когда они являются ближайшими соседями для каких-то точек поверхности).
- 4) В случае, если $\lambda_{max} \gg \lambda_{min}$, решение задачи оптимизации может быть неустойчивым.

Свойства методов

Technique	Convex	Parameters	Computational	Memory
PCA	yes	none	$O(D^3)$	$O(D^2)$
MDS	yes	none	$O(N^3)$	$O(N^2)$
Isomap	yes	K	$O(N^3)$	$O(N^2)$
MVU	yes	K	$O((NK)^3)$	$O((NK)^3)$
Kernel PCA	yes	kernel	$O(N^3)$	$O(N^2)$
Diffusion maps	yes	σ, T	$O(N^3)$	$O(N^2)$
Autoencoders	no	network shape	$O(INW)$	$O(W)$
LLE	yes	K	$O(pN^2)$	$O(pN^2)$
Laplacian eigenmaps	yes	K, σ	$O(pN^2)$	$O(pN^2)$

Обозначения: D – размерность исходного пространства, N – количество объектов, K – кол-во ближайших соседей, σ – параметр гауссова ядра, p – доля ненулевых элементов в матрице весов.

Видим, что по вычислительной сложности PCA вне конкуренции, потом идут локальные методы (LLE и Laplacian eigenmaps), а потом все остальные (t-SNE там же).

Сравнение глобальных и локальных методов

Глобальные методы стремятся сохранить общую структуру данных

- 1) в целом менее эффективны;
- 2) шумовые точки могут испортить всю картину в целом.

Локальные методы стремятся сохранить только локальные свойства поверхности, вдоль которой расположены данные

- 1) в целом более эффективны;
- 2) эффект от шумовых точек остается локальным и не распространяется на все данные.

Finita!

Методы современной прикладной статистики

12. Анализ временных рядов.

Родионов Игорь Владимирович
vecsell@gmail.com

ШАД

Постановка задачи

Временным рядом называется случайная последовательность $\{y_n\}_{n \geq 1}$, зависящая от n (т.е. от времени).

Задача прогнозирования: найти такую функцию f , что



$$y_{n+d} \approx f(y_1, \dots, y_n, d) = \hat{y}_{n+d}, \quad d = 1, \dots, D.$$

Часто также стоит задача сделать прогноз не только по предыдущим значениям ряда, но и по другим имеющимся признакам.



Простейшие методы типа добавить в модель в качестве признака время не всегда помогают, потому что наблюдения могут быть сильно зависимыми от своих соседей во временном ряду.

Регрессия по времени

Сделаем регрессию по времени для наблюдений временного ряда



Видим, что остатки далеки от однородности



Компоненты временного ряда

- Тренд – плавное долгосрочное изменение уровня ряда.
- Сезонность – циклические изменения уровня ряда с постоянным периодом.
- Циклы – изменения уровня ряда с переменным периодом (цикл жизни товара, экономические волны, периоды солнечной активности).
- Ошибка – непрогнозируемая случайная компонента ряда.


STL-разложение (STL-decomposition) – полезный визуальный метод анализа временных рядов.

Выделение тренда (+циклической составляющей) и сезонной компоненты основано на алгоритме loess (предшественнике LOWESS) робастной непараметрической регрессии.

После выделения тренда сезонность определяется с помощью сглаживающего среднего по нескольким циклам. Здесь используется входной параметр, задающий длину сезона, что является небольшим недостатком метода.

Ещё одним недостатком алгоритма является то, что он применим только для аддитивных моделей временных рядов.

STL-разложение



Критерии случайности

Если после визуального анализа всё же остаются сомнения в том, что перед нами временной ряд, то можно применить критерии случайности. Проверим гипотезу $H_0 : \{X_i\}_{i=1}^n$ образуют выборку.

1) **Критерий инверсий.** Определим $\mathbb{I} = \sum_{i < j} \mathbb{I}(X_i > X_j)$. Тогда при $n \geq 20$ и верной H_0

$$\mathbb{I} \approx N \left(\frac{n(n-1)}{4}, \frac{2n^3 + 3n^2 - 5n}{72} \right).$$

2) **Критерий Вальда-Волфовитца.** Пусть $\hat{\mu}$ – выборочная медиана $\{X_i\}_{i=1}^n$. Определим $Y_i = \mathbb{I}(X_i \geq \hat{\mu})$ и $W = \sum_i \mathbb{I}(Y_i \neq Y_{i+1})$. Пусть n_0 и n_1 – количество 0 и 1 в ряду $\{Y_i\}_{i=1}^n$. Тогда при верной H_0 и $n_0, n_1 > 20$

$$W \approx N \left(\frac{2n_0n_1}{n_0 + n_1}, \frac{2n_0n_1(2n_0n_1 + n_0 + n_1)}{(n_0 + n_1)^2(n_0 + n_1 - 1)} \right).$$

Ряд $\{X_n\}_{n \geq 1}$ – **стационарный в узком смысле**, если $\forall s$
 $\forall t_1, \dots, t_k$ выполнено

$$(X_{t_1}, \dots, X_{t_k}) \stackrel{d}{=} (X_{t_1+s}, \dots, X_{t_k+s}).$$

Ряд $\{X_n\}_{n \geq 1}$ – **стационарный в широком смысле**, если
 $\mathbb{E}X_n = \text{const}$ и $\text{cov}(X_n, X_m) = r(n - m)$, где $r(\cdot)$
симметрична и неотрицательно определена.


Как правило, пытаются сделать так, чтобы остатки
временного ряда были нормальными, в этом случае первое
и второе определения совпадают.

Нормальность проверяется с помощью простых критериев
типа Харке-Бера, потому что остатки могут быть сильно
зависимы.

Ряды с трендом или сезонностью не стационарны. Ряды с непериодическими циклами стационарны, поскольку нельзя предсказать заранее, где будут находиться максимумы и минимумы.

Стационарность так важна по той причине, что по стационарному ряду просто строить прогноз, так как мы полагаем, что его будущие статистические характеристики не будут отличаться от наблюдаемых текущих.

Какие из рядов на следующем рисунке являются стационарными?



Как убрать нестационарность?

Путь первый (простой):

Пусть по графику ряда видно, что тренд похож на линейный, а период ряда явно просматривается и равен d . В таком случае строится ряд

$$MA_i = \frac{1}{d} \sum_{j=i-\lfloor d/2 \rfloor}^{i+\lceil d/2 \rceil} X_j.$$

Если разброс значений ряда не зависит от его значений, то стоит использовать аддитивную модель и вычесть из значений ряда MA_i там, где MA_i определен. Если зависит прямо пропорционально, то X_i делим на MA_i . После этой операции получаем значения Y_i .

Как убрать нестационарность?

Далее, периодическая компонента вычисляется как

$$S_j = \frac{1}{[n/d] - 1} \sum_{i=j+dk, k \geq 0} Y_i,$$

$j = 0, \dots, d - 1$, по тем значениям i , где Y_i определены.

После этого предсказания новых значений строятся следующим образом: строится регрессия MA_i по времени, получаем предсказания $\widehat{MA}_i$, $i > n$. Если модель аддитивная, то к $\widehat{MA}_i$ прибавляем $S_{i(mod\ d)}$, если мультипликативная, то домножаем.

Метод дает удовлетворительный результат, если остатки модели много меньше её основных компонент или если данных довольно мало.

Как убрать нестационарность?

Путь второй (сложный):

1) Пусть период ряда равен d . Сезонным дифференцированием называется преобразование $Y_t = X_t - X_{t-d}$. Оно, как правило, помогает избавиться от сезонности в данных.

2) Дифференцированием ряда называется операция $\Delta X_t = X_t - X_{t-1}$. Если после этой операции ряд не стал стационарным, то нужно попробовать продифференцировать его ещё раз.

3) Можно попробовать убрать нестационарность с помощью регрессии значений ряда по времени, лагам и (если они есть) другим признакам. k -тым лагом значения X_t называется $Y_t^{(k)} = X_t - X_{t-k}$.

Сезонное дифференцирование стоит делать вначале – возможно, что после него ряд уже будет стационарным.

Тест Дики-Фуллера

Рассмотрим модель AR(1) стационарного временного ряда: $X_t = aX_{t-1} + \varepsilon_t$, где ε_t – ошибка, не зависящая от значений временного ряда. В случае, если $|a| = 1$, ряд перестает быть стационарным (об этом чуть позже) – тогда говорят, что процесс имеет **единичный корень**.


Рассмотрим теперь модель $\Delta X_t = bX_{t-1} + \varepsilon_t$. Если $a = 1$, то $b = 0$. Тест Дики-Фуллера (DF-test) проверяет гипотезу $H_0 : b = 0$ для приведенной модели авторегрессии.

Статистика теста – обычная t-статистика для значимости коэффициентов линейной регрессии, однако распределение статистики при верности H_0 будет другим.


Тест Дики-Фуллера

Объясним, почему наличие единичного корня у процесса так важно. Сгенерируем процесс по модели

$X_t = \rho X_{t-1} + e_t$, где $\{e_t\}_{t \geq 1}$ – независимые стандартные нормальные случайные величины. Случай, когда $|\rho| > 1$ (“взрывной” процесс) легко распознаваем визуально, поэтому не будем его рассматривать.



Тест Дики-Фуллера



Видим, что при $\rho = 1$ процесс не возвращается к своему среднему значению, а значит, не является стационарным.

Другие тесты проверки стационарности

Если единичных корней у ряда несколько (т.е. чтобы достичь стационарности, нужно несколько раз продифференцировать ряд), то следует пользоваться расширенным тестом Дики-Фуллера (ADF).

Ещё одним тестом проверки стационарности является критерий KPSS (Kwiatkowski-Phillips-Schmidt-Shin test). Критерий проверяет стационарность аддитивной модели временного ряда $X_t = c_t + \delta t + e_t$, $c_t = c_{t-1} + u_t$, где e_t – некий стационарный ряд, $u_t \stackrel{d}{=} e_t$, независим с e_t , $\mathbb{E}u_t = 0$, $\text{var } u_t = \sigma^2$.

Перейдем теперь к вопросу, сколько раз нужно дифференцировать ряд, чтобы он стал похож на стационарный. Нам потребуется ввести несколько определений.

Процесс ε_t такой, что $\mathbb{E}\varepsilon_t = 0 \ \forall t$, $\text{cov}(X_t, X_s) = \sigma_\varepsilon^2 \delta(t - s)$, где $\delta(x)$ – символ Кронекера, называется **белым шумом**. В случае, если процесс является гауссовским, этот процесс имеет независимые значения.

Модели авторегрессии

Процесс авторегрессии порядка p ($AR(p)$) – это процесс, задаваемый как

$$X_t = a_1 X_{t-1} + \dots + a_p X_{t-p} + \varepsilon_t,$$

$a_p \neq 0$, ε_t – процесс белого шума, $\mathbb{E}\varepsilon_t = 0$, $\text{var } \varepsilon_t = \sigma_\varepsilon^2$, некоррелируемый с X_t .

Введем оператор запаздывания $L : LX_t = X_{t-1}$, тогда определение процесса $AR(p)$ можно записать так:

$$a(L)X_t = \varepsilon_t,$$

где $a(L) = 1 - (a_1 L + \dots + a_p L^p)$.

Процесс авторегрессии $AR(p)$ является стационарным (в широком смысле) тогда и только тогда, когда корни уравнения $a(z) = 0$ лежат вне круга $|z| \leq 1$ на комплексной плоскости.

Процесс

$$X_t = \varepsilon_t + b_1\varepsilon_{t-1} + \dots + b_q\varepsilon_{t-q} = b(L)\varepsilon_t,$$

$b_q \neq 0$, где ε_t – процесс белого шума, называется **процессом скользящего среднего порядка q** ($MA(q)$). Такой процесс всегда является стационарным.

Теорема.

- 1) Любой стационарный процесс $AR(p)$, заданный соотношением $a(L)(X_t - \mu) = \varepsilon_t$, можно представить в виде процесса $MA(\infty)$.
- 2) Обратно, если процесс X_t удовлетворяет MA -представлению $X_t - \mu = b(L)\varepsilon_t$ и все корни уравнения $b(z) = 0$ в комплексной плоскости по модулю больше 1, то X_t представим в виде процесса $AR(\infty)$. Такой процесс называется **инвертируемым**.

Модели авторегрессии

Будем называть X_t смешанным процессом авторегрессии ($ARMA(p, q)$), если $\mathbb{E}X_t = \text{const}$ и $a(L)X_t = b(L)\varepsilon_t$, т.е.

$$X_t = \sum_{j=1}^p a_j X_{t-j} + \sum_{k=0}^q b_k \varepsilon_{t-k},$$

где $b_0 = 1$, $a_p, b_q \neq 0$.

Теорема (разложение Вольда).

Любой центрированный стационарный в широком смысле процесс X_t может быть представлен в виде

$$X_t = \sum_{j=1}^{+\infty} a_j X_{t-j} + \sum_{k=0}^{+\infty} b_k \varepsilon_{t-k},$$

где ε_t – процесс белого шума, $\text{cov}(X_t, \varepsilon_{t-j}) = 0 \ \forall t, j$.

Отсюда следует, что любой стационарный временной ряд можно приблизить моделью $ARMA(p, q)$ сколь угодно точно.

Временной ряд описывается моделью $ARIMA(p, q, d)$, если ряд его дифференцирований $\nabla^d X_t = (1 - L)^d X_t$ описывается моделью $ARMA(p, q)$, т.е.

$$a(L)\nabla^d X_t = b(L)\varepsilon_t.$$

Видим, что у данной модели d единичных корней, т.е. исходный процесс X_t не является стационарным. Если в модель добавить ещё и сезонное дифференцирование, то получится модель $SARIMA$.

Как оптимальным образом выбирать параметры p, q, d и длину периода?

Пусть имеются наблюдения временного ряда $\{x_t\}_{t=1}^T$.

Автокорреляционной функцией (или автокорреляцией, ACF) этого ряда называется функция

$$r_\tau = \frac{\sum_{t=1}^{T-\tau} (x_t - \bar{x})(x_{t+\tau} - \bar{x})}{\sum_{t=1}^T (x_t - \bar{x})^2},$$

где $\bar{x} = \frac{1}{T} \sum_{t=1}^T x_t$. Легко заметить, что всегда $r_0 = 1$.

Частичная автокорреляция

Частичной автокорреляционной функцией (PACF) ряда $\{x_t\}_{t=1}^T$ называется функция

$$\varphi_h = \begin{cases} r_h = r(x_t, x_{t+h}), & h = 1 \\ r(x_{t+h} - x_{t+h}^{h-1}, x_t - x_t^{h-1}), & h > 1, \end{cases}$$

где r – автокорреляционная функция с предыдущего слайда, x_t^{h-1} и x_{t+h}^{h-1} – линейная регрессия x_t и x_{t+h} соответственно по признакам $x_{t+1}, \dots, x_{t+h-1}$. По сути, $PACF(h)$ – мера того, как сильно X_t влияет на X_{t+h} без учета значений ряда между ними.

Анализ ACF и PACF – основной метод при определении параметров p , d и q модели ARIMA.

Определение параметров ARIMA

1) Если один из лагов PACF близок к 1, то стоит сделать дифференцирование ряда (если это первый лаг, то обычное дифференцирование, если это s -тый лаг при условии, что он значимее, чем первый, то сезонное).

Операцию следует повторять, пока не останется лагов, близких к единице. Для уверенности в том, что перед нами теперь стационарный ряд, стоит пользоваться тестами Дики-Фуллера и KPSS.

2) После приведения ряда к стационарному можно определить параметры p и q модели ARIMA. Параметр p равняется номеру последнего значимого лага функции PACF (после которого лаги экспоненциально убывают). Параметр q равняется номеру последнего значимого лага функции ACF.

Определение качества модели

Пусть мы получили оценки членов временного ряда с помощью некоторой модели, и остатки в этой модели $\{e_i\}_{i=1}^T$. Определим $\hat{\sigma}^2 = \frac{1}{T} \sum_{i=1}^T e_i^2$ – фактически, это оценка дисперсии ошибок. Пусть для описания ряда мы выбрали модель $ARIMA(p, d, q)$.


Критерий Акаике:

$$AIC_c = \ln \hat{\sigma}^2 + \frac{2(p + q + 1)(p + q + 2)}{T - q - p - 2}.$$


Критерий Шварца:

$$BIC = \ln \hat{\sigma}^2 + \frac{(\ln T - 2)(p + q + 1)}{T}.$$


Как и ранее, чем меньше AIC (BIC), тем лучше считается модель.




Видим почти единичный лаг PACF. Тест Дики-Фуллера дает р-значение 0.19, это значит, что есть единичный корень и ряд нестационарный, да и видно, что есть сезонность. Кроме того, есть гетероскедастичность - её можно попробовать исправить с помощью преобразования Бокса-Кокса.




После применения преобразования Бокса-Кокса дисперсия стабилизировалась, но в остальном мало что изменилось. Р-значение теста Дики-Фуллера равно 0.07. Возьмем сезонное дифференцирование ряда.




Теперь тест Дики-Фуллера отвергает гипотезу о нестационарности, но ACF выглядит плохо и в PACF остался лаг, близкий к 1. Сделаем обычное дифференцирование ряда.



Наконец, мы получили стационарный ряд, причем стоит выбрать $p \leq 4$ и $q \leq 4$, выбор можно осуществлять полным перебором. Выбор оптимальной модели можно осуществлять с помощью информационных критериев AIC и BIC или с помощью кросс-валидации. Коэффициенты модели можно определять, например, с помощью линейной регрессии.



Оптимальными (с точки зрения BIC) параметрами модели оказались $p = 4$ и $q = 3$, причем в модель нужно не забыть внести то, что мы делали сезонное и обычное дифференцирования. То, что первые L лагов автокорреляции получились незначимыми, можно проверить с помощью Q-критерия Льюнга-Бокса.



Прогноз строится следующим образом: мы последовательно вычисляем $\hat{x}_{T+1}, \hat{x}_{T+2}, \dots$, новые ошибки $\varepsilon_{T+1}, \dots$ полагаем равными 0, а вместо старых ошибок используем остатки модели. В итоге мы получили довольно точную модель, но суммарные затраты на приведение модели к адекватному виду могли такой точности и не стоить.

Как уже упоминалось, затраты на настройку модели SARIMA часто не окупаются, и порой даже не удается привести модель к адекватному виду. Поэтому стоит рассмотреть другие возможности по предсказанию временных рядов.

Одним из таких путей является использование модели линейной регрессии. Из временного ряда вычленяется набор признаков-лагов, кроме того, из признака времени можно вычленить категориальные признаки дней недели, часов и тд. Модель приобретает больший смысл, если кроме самих значений временного ряда у нас есть и другие признаки. Хотя предположения Гаусса-Маркова, очевидно, не выполнены из-за автокоррелированности значений ряда, модель может давать неплохие результаты.

Экспоненциальное сглаживание


Другим выходом является использование моделей экспоненциального сглаживания. Различают аддитивные и мультипликативные модели, мы же рассмотрим аддитивную модель тройного экспоненциального сглаживания Хольта-Винтерса.

$$\begin{cases} l_t = \alpha(x_t - s_{t-L}) + (1 - \alpha)(l_{t-1} + b_{t-1}); \\ b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}; \\ s_t = \gamma(x_t - l_t) + (1 - \gamma)s_{t-L}; \\ \hat{x}_{t+m} = l_t + mb_t + s_{t-L+1+((m-1) \bmod L)}. \end{cases}$$

Если занулить s_t , то получим модель двойного экспоненциального сглаживания, если занулить ещё и b_t , то получится модель простого экспоненциального сглаживания Брауна.

Экспоненциальное сглаживание


В модели Хольта-Винтерса I_t (level, intercept) отвечает за “уровень” ряда, b_t (trend, slope) – за тренд, s_t – за сезонность. Если сезонности нет, то лучше перейти к двойному экспоненциальному сглаживанию.



Судя по графику, модель неплохо описала исходный временной ряд, уловив недельную и дневную сезонность, и даже смогла поймать аномальные снижения, вышедшие за пределы доверительных интервалов.

Экспоненциальное сглаживание

Если посмотреть на смоделированное отклонение, хорошо видно, что модель достаточно резко реагирует на значительные изменения в структуре ряда, но при этом быстро возвращает дисперсию к обычным значениям, “забывая” прошлое. Такая особенность позволяет неплохо и без значительных затрат на подготовку-обучение модели настроить систему по детектированию аномалий даже в достаточно шумных рядах.



Finita!